Previsão de Churn (Abandono) emTelecom

IF702 - Redes Neurais

Discentes: Caio Ferreira(cfgs), José Janailson(jjac)

Centro de Informática UFPE
Universidade Federal de Pernambuco

Introdução e Objetivo

- Contexto: Previsão de Churn em Telecom utilizando a base de dados do Kaggle



kaggle

Introdução e Objetivo

- Objetivo: Investigar diferentes topologias e classificadores para encontrar a melhor separação entre clientes que abandonam e clientes que permanecem

Preparação e Particionamento dos dados

Divisão de dados:

1. Dados divididos em duas classes, classe 0: Churn = “No” e classe 1: Churn = “Yes”.
2. Divide as duas classes, cada uma é dividida em treino (50%), validação (25%) e teste (25%).
3. Depois é feito um balanceamento, onde o treino e validação da classe 1 é copiado aleatoriamente até ficar com o mesmo tamanho do treino e validação da classe 0 respectivamente.
4. Junta os conjuntos de dados de treino, validação e teste da classe 0 com os da classe 1, depois os dados de cada conjunto são aleatorizados.

Preparação e Particionamento dos dados

Tratamento de dados:

1. Trata dados faltando: remove linhas com dados faltando.
2. Muda target Feature de "Yes"/"No" para 1/0.
3. Fix Inconsistências: TotalCharges de string para numérico.
4. Tratando dados:
    - 4.1. Dados binários: de "Yes"/"No" para 1/0.
    - 4.2. Genero de “Male”/”Female para 1/0.
    - 4.3. Faz one-hot encoding nos dados categóricos (InternetService, Contract, PaymentMethod).
    - 4.4. Remove ruído agregando serviços em uma única feature (num_services).

Preparação e Particionamento dos dados

Tratamento de dados (continuação):

5. Add novas features:
   5.1. AvgMonthlyCharge = média do valor que o cliente paga por mês.
   5.2. is_new_customer = indica se cliente está inscrito a 6 meses ou menos.
6. Separa target features do resto dos dados.
7. Faz o pré processamento dos dados, escalonando todos os dado que não fazem parte do one-hot, escalonamento feito com base apenas nos dados de treino para não ter vazamento de dados.

Algoritmos

- Fizemos o treinamento com 7 distintos algoritmos na seguinte ordem:
- MLP
- XGBoost
- STAB
- TabPFN
- Mitra
- KAN
- TabKANet

MLP

Treino 1: MLPClassifier

- Treino de teste do modelo
- Esse treino usou um tratamento de dados antigo que era pior.
- Treino realizado com optuna para buscar melhores parâmetros e depois treino é refeito em um novo modelo com os melhores parâmetros encontrados
- Foram feitos 50 trials do optuna

MLP

Treino 1: MLPClassifier

Parâmetros passados para o optuna:

- hidden layers = 1 a 8
- layer sizes = 16 a 256
- learning rate = 1e-5 a 1e-2
- activation functions = "relu", "tanh" e "logistic"
- optimizators = "lbfgs", "sgd" e "adam"
- L2 regularization = 1e-5 a 1e-2
- batch size = 30 a 300
- epochs = 10000
- patience = 10

Melhores parâmetros encontrados:

- hidden layers: 3
- unidades na layer 0: 143
- unidades na layer 1: 16
- unidades na layer 2: 84
- learning rate inicial: 0.006917822802406749
- activation function : 'tanh'
- optimizator: 'lbfgs'
- L2 regularization: 0.00010191560773786016
- batch size: 68

MLP

Treino 1 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.79      0.78      0.78      2587
           1       0.78      0.79      0.78      2587

    accuracy                           0.78      5174
   macro avg       0.78      0.78      0.78      5174
weighted avg       0.78      0.78      0.78      5174

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.75      0.74      0.75      1293
           1       0.75      0.75      0.75      1293

    accuracy                           0.75      2586
   macro avg       0.75      0.75      0.75      2586
weighted avg       0.75      0.75      0.75      2586

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.89      0.76      0.82      1294
           1       0.52      0.74      0.61       468
...
    accuracy                           0.75      1762
   macro avg       0.71      0.75      0.71      1762
weighted avg       0.79      0.75      0.76      1762
```

Erro Médio Quadrado:

- MSE Treino: 0.21743332044839583
- MSE Validação: 0.25019334880123745
- MSE Teste: 0.24858115777525538

Entropia Cruzada:

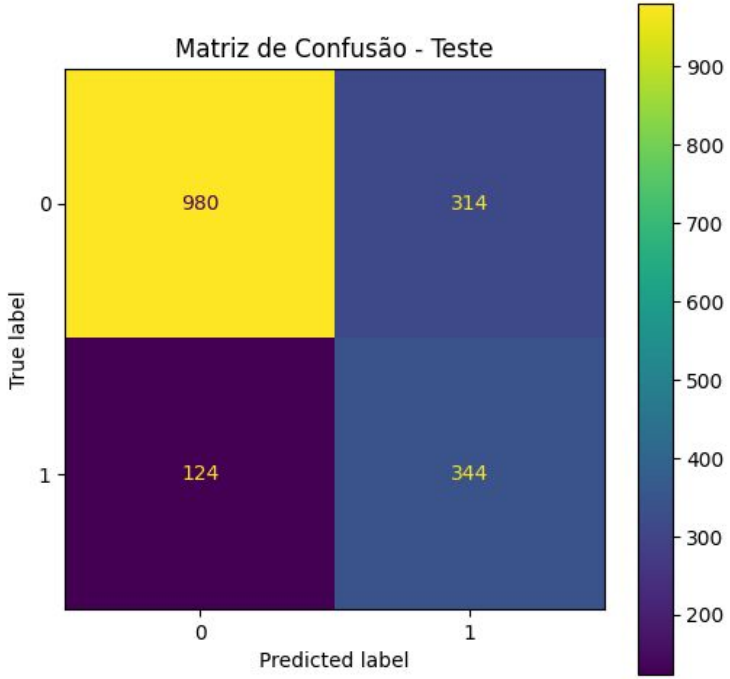
- Log Loss Treino: 0.45599638324345515
- Log Loss Validação: 0.5036649946949482
- Log Loss Teste: 0.48356003109993373

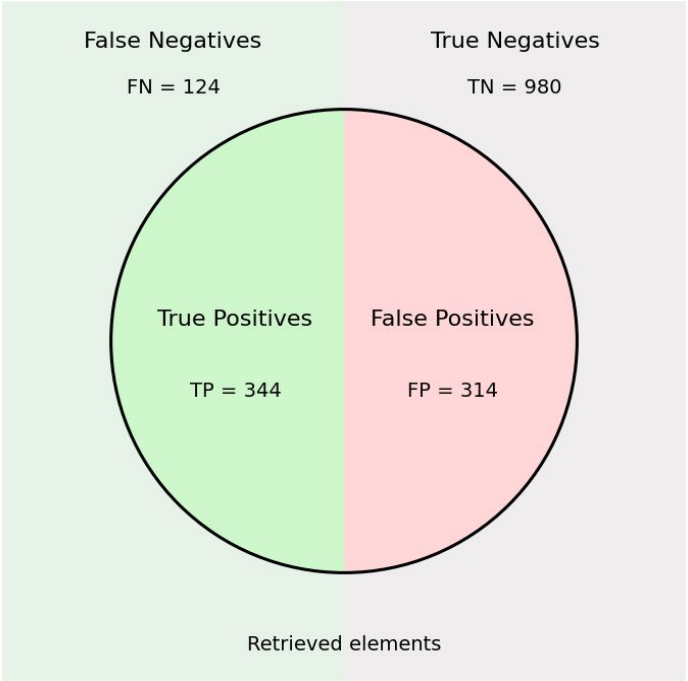
Precision, recall e F1 do teste:

- Precision: 0.5227963525835866
- Recall: 0.7350427350427351
- F1-Score: 0.61101243339254

MLP

Treino 1 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

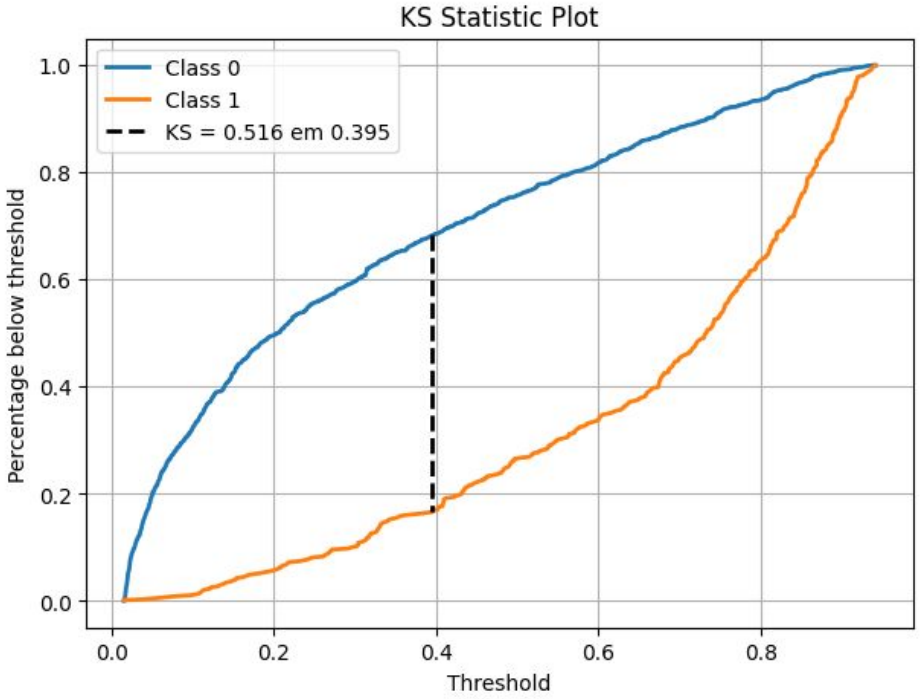




MLP

Treino 1 (Resultados): Teste Kolmogorov-Smirnov (KS)

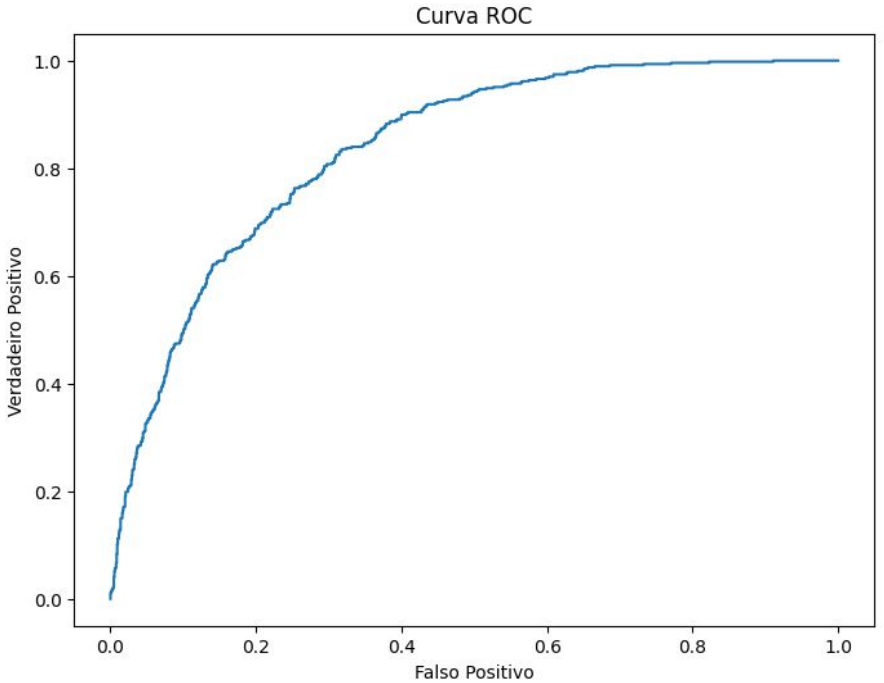
KS Statistic: 0.5158467353597147
Best threshold: 0.3946614613927744



MLP

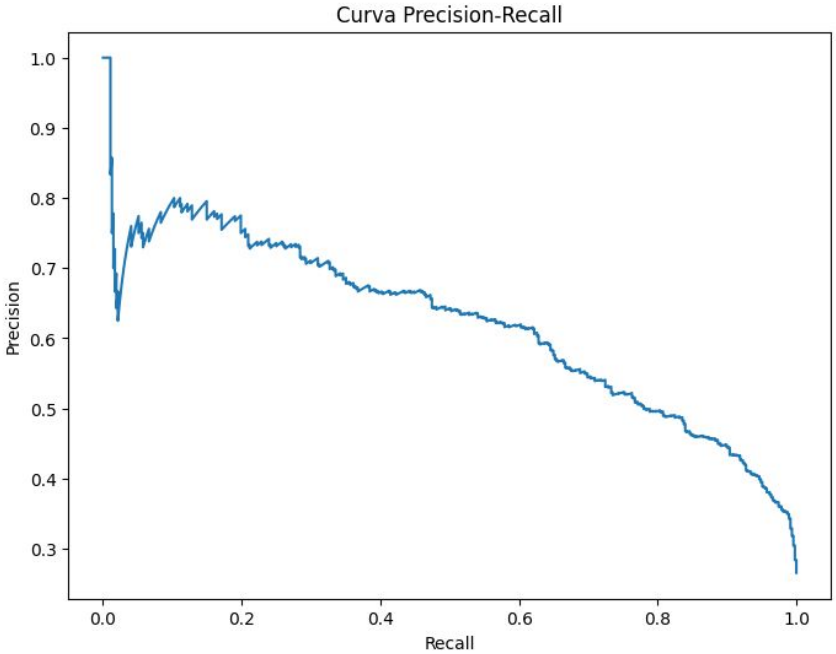
Treino 1 (Resultados): Curva ROC e AUROC

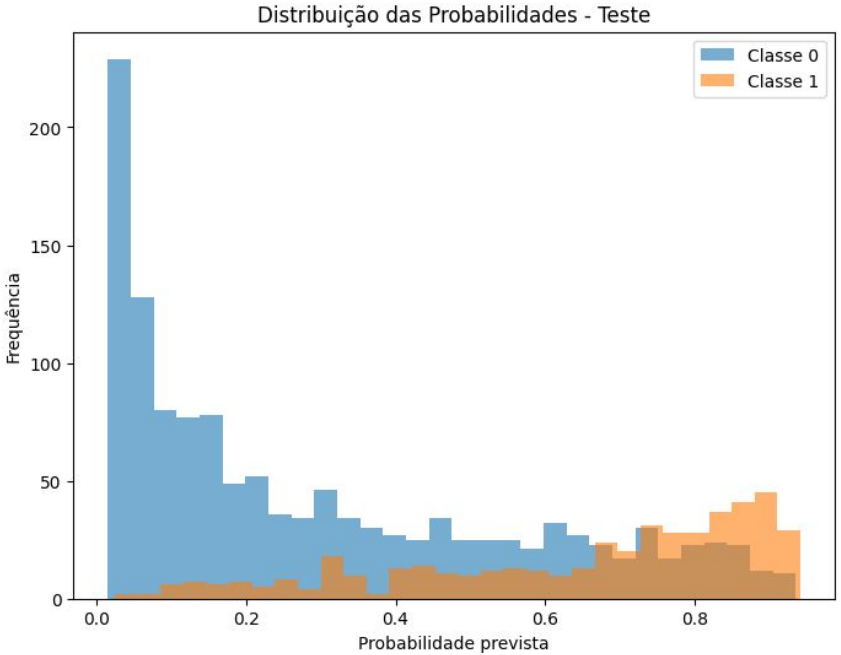
AUC (Área sob a ROC): 0.8361826113951307



MLP

Treino 1 (Resultados): Curva precision - Recall e Distribuição das probabilidades





MLP

Treino 2: MLP Sequential (tensorflow.keras)

- Similar ao treino 1, mas com um modelo diferente
- Treino de teste do modelo
- Esse treino usou um tratamento de dados antigo que era pior.
- Treino realizado com optuna para buscar melhores parâmetros e depois treino é refeito em um novo modelo com os melhores parâmetros encontrados
- Foram feitos 50 trials do optuna

MLP

Treino 2: MLP Sequential (tensorflow.keras)

Parâmetros passados para o optuna:

- hidden layers = 1 a 4
- layer sizes = 16 a 256
- learning rate = 1e-5 a 1e-2
- activation functions = "relu", "tanh", "elu" e "LeakyReLU"
- optimizators = “adam", "nadam", "rmsprop" e "sgd"
- L2 regularization = 1e-5 a 1e-2
- batch size = 30 a 300
- dropout = 0.20, 0.25, 0.30, 0.35 ou 0.40
- epochs = 10000
- patience = 10

Melhores parâmetros encontrados:

- hidden layers: 1
- unidades na layer 0: 154
- dropout layer 0: 0.20
- learning rate inicial: 0.0029854636682851987
- activation function : 'tanh'
- optimizator: 'nadam'
- L2 regularization: 8.499553337026635e-05
- batch size: 152

MLP

Treino 2 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.76      0.82      0.78      2587
           1       0.80      0.74      0.77      2587

    accuracy                           0.78      5174
   macro avg       0.78      0.78      0.78      5174
weighted avg       0.78      0.78      0.78      5174

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.74      0.79      0.76      1293
           1       0.77      0.72      0.75      1293

    accuracy                           0.76      2586
   macro avg       0.76      0.76      0.76      2586
weighted avg       0.76      0.76      0.76      2586

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.88      0.79      0.84      1294
           1       0.55      0.71      0.62       468
...
    accuracy                           0.77      1762
   macro avg       0.72      0.75      0.73      1762
weighted avg       0.80      0.77      0.78      1762
```

Erro Médio Quadrado:

- MSE Treino: 0.2238113645148821
- MSE Validação: 0.24439288476411447
- MSE Teste: 0.22871736662883088

Entropia Cruzada:

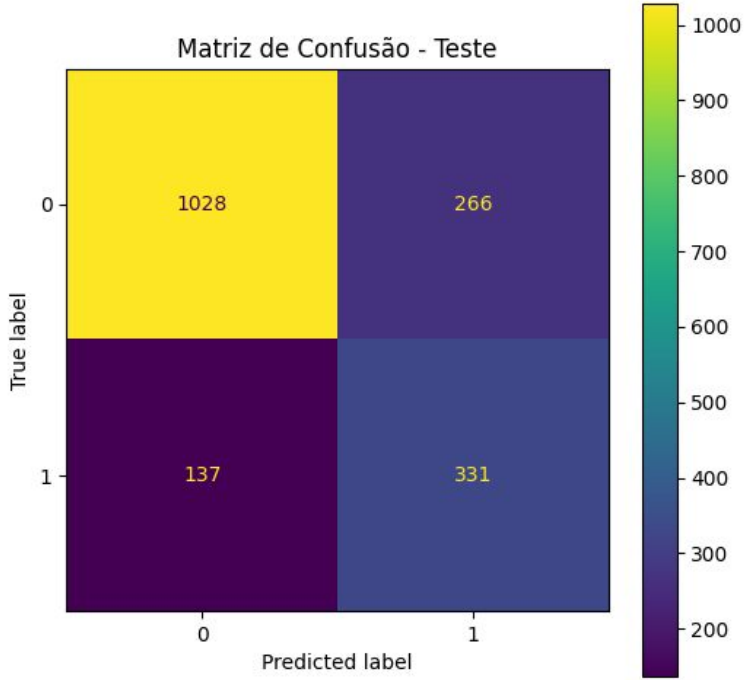
- Log Loss Treino: 0.46135084550078553
- Log Loss Validação: 0.5188290480595444
- Log Loss Teste: 0.4522830618763039

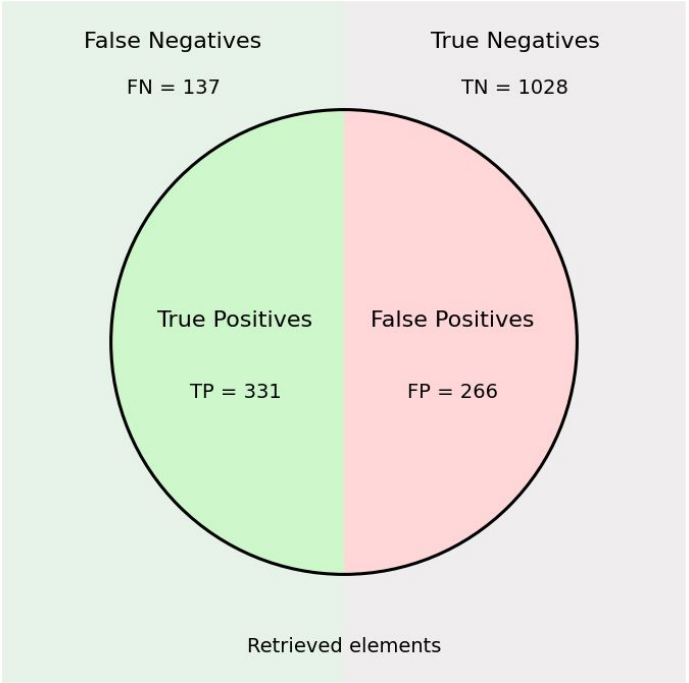
Precision, recall e F1 do teste:

- Precision: 0.5544388609715243
- Recall: 0.7072649572649573
- F1-Score: 0.6215962441314554

MLP

Treino 2 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

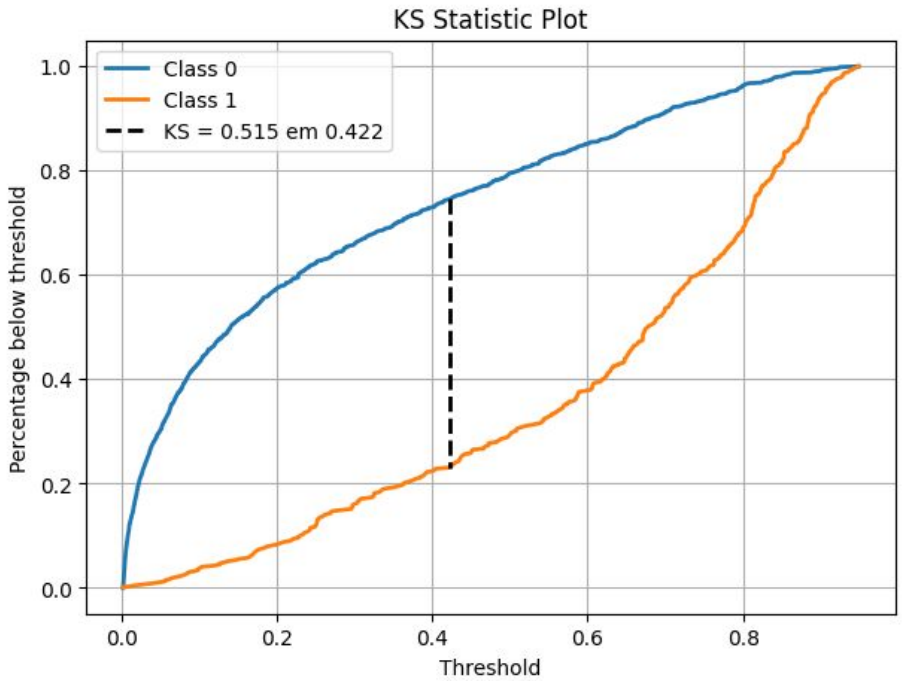




MLP

Treino 2 (Resultados): Teste Kolmogorov-Smirnov (KS)

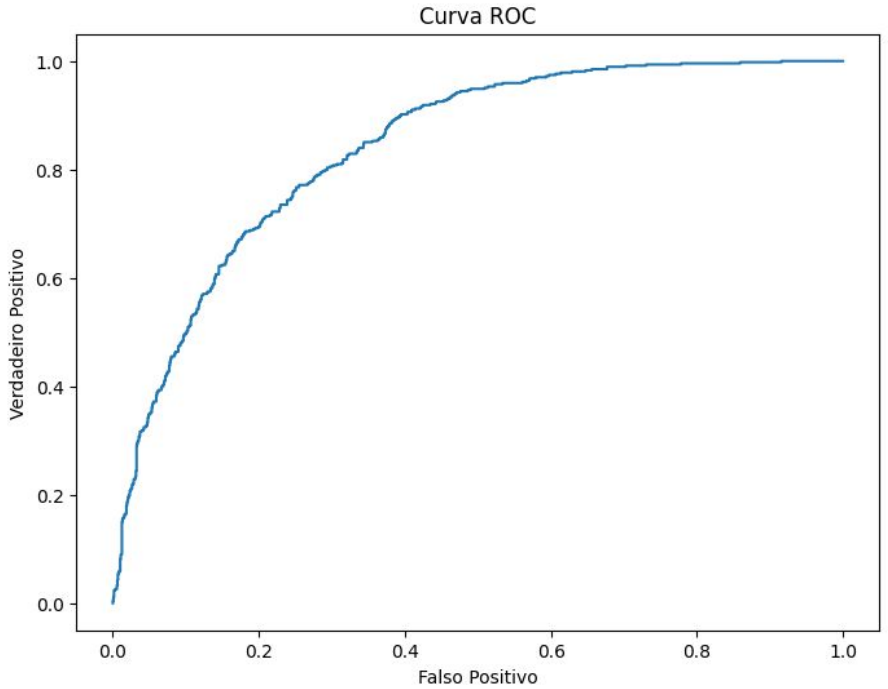
KS Statistic: 0.5146112405815821
Best threshold: 0.42201215



MLP

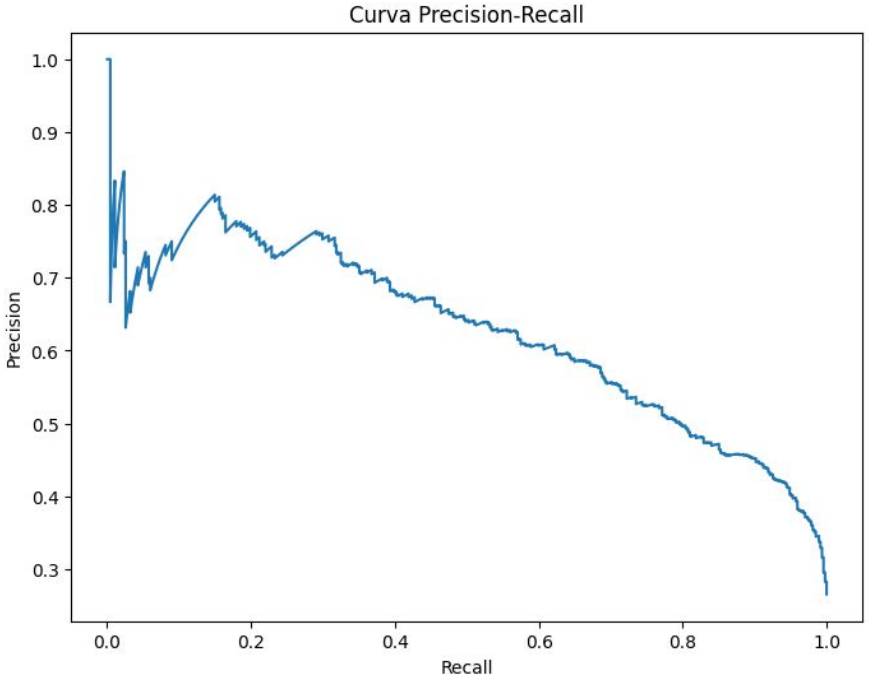
Treino 2 (Resultados): Curva ROC e AUROC

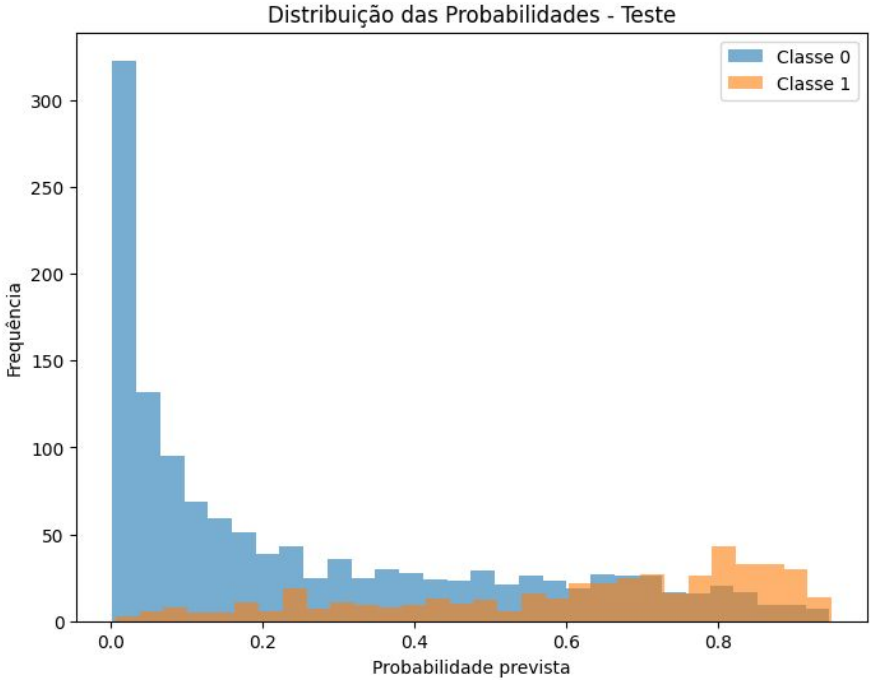
AUC (Área sob a ROC): 0.8394620470547828



MLP

Treino 2 (Resultados): Curva precision - Recall e Distribuição das probabilidades





MLP

Treino 2: Comparando resultados de teste

Parâmetros	Melhor treino (1)	Treino atual (2)
Precision	0.5227963525835866	0.5544388609715243
Recall	0.7350427350427351	0.7072649572649573
F1-Score	0.61101243339254	0.6215962441314554
Accuracy	0.75	0.77
MSE	0.24858115777525538	0.22871736662883088
Log Loss	0.48356003109993373	0.4522830618763039
KS	0.5158467353597147	0.5146112405815821
AUC	0.8361826113951307	0.8394620470547828

MLP

Treino 3: melhorar ks e tratamento ajustado

- Treino do optuna focado em melhorar o ks (40 trials), repete treino em um novo modelo com os melhores parâmetros encontrados
- Tratamento de dados modificado: enumerando dados categóricos

MLP

Treino 3: melhorar ks e tratamento ajustado

Parâmetros passados para o optuna:

- hidden layers = 2 e 3
- layer sizes = 16 a 256
- learning rate = 1e-4 a 1e-3
- activation functions = "relu", "tanh", "elu" e "LeakyReLU"
- optimizators = "adam", "nadam", "rmsprop" e "sgd"
- L2 regularization = 2e-3 a 8e-3
- batch size = 64 a 256
- dropout = 0.00, 0.05, 0.10, 0.15, 0.20, 0.25 ou 0.30
- epochs = 10000
- patience = 20

Melhores parâmetros encontrados:

- hidden layers: 3
- unidades na layer 0: 157
- dropout layer 0: 0.10
- unidades na layer 1: 132
- dropout layer 1: 0.05
- unidades na layer 2: 18
- dropout layer 2: 0.00
- learning rate inicial: 0.00011931111288467095
- activation function : 'elu'
- optimizator: 'adam'
- L2 regularization: 0.005375307912213187
- batch size: 94

MLP

Treino 3 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.80      0.74      0.77      2581
           1       0.76      0.81      0.78      2587

    accuracy                           0.78      5168
   macro avg       0.78      0.78      0.78      5168
weighted avg       0.78      0.78      0.78      5168

Accuracy no treino: 0.7767

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.77      0.72      0.74      1291
           1       0.74      0.79      0.76      1293

    accuracy                           0.75      2584
   macro avg       0.76      0.75      0.75      2584
weighted avg       0.76      0.75      0.75      2584

Accuracy na validação: 0.7539

==== CLASSIFICATION REPORT - TESTE ====
...
   macro avg       0.72      0.77      0.72      1759
weighted avg       0.81      0.75      0.76      1759

Accuracy no teste: 0.7499
```

Erro Médio Quadrado:

- MSE Treino: 0.22329721362229102
- MSE Validação: 0.24613003095975233
- MSE Teste: 0.25014212620807275

Entropia Cruzada:

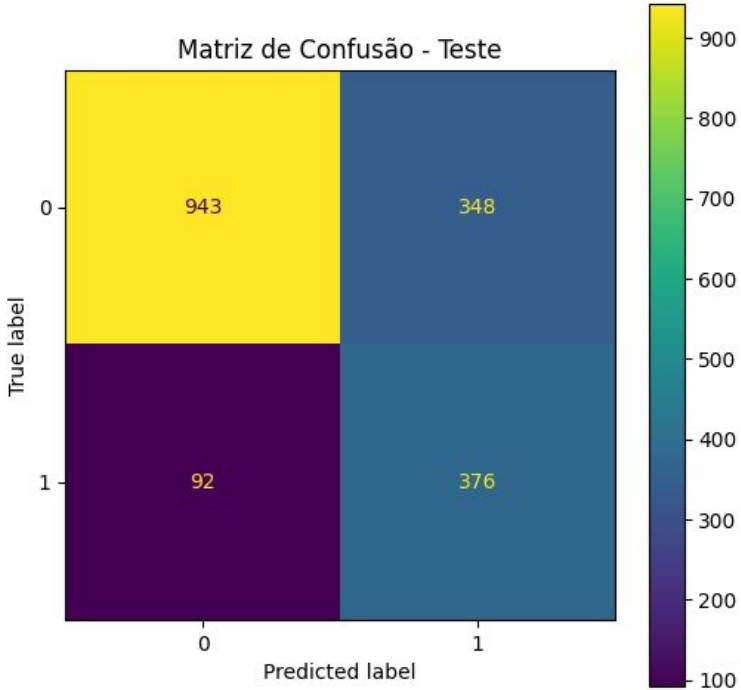
- Log Loss Treino: 0.46473279717431626
- Log Loss Validação: 0.5058577133212865
- Log Loss Teste: 0.4885025420150897

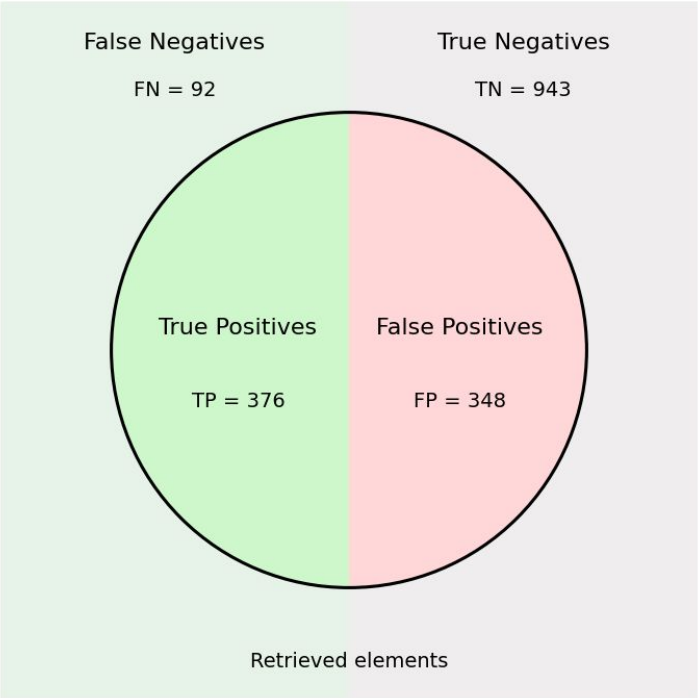
Precision, recall e F1 do teste:

- Precision: 0.5193370165745856
- Recall: 0.8034188034188035
- F1-Score: 0.6308724832214765

MLP

Treino 3 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

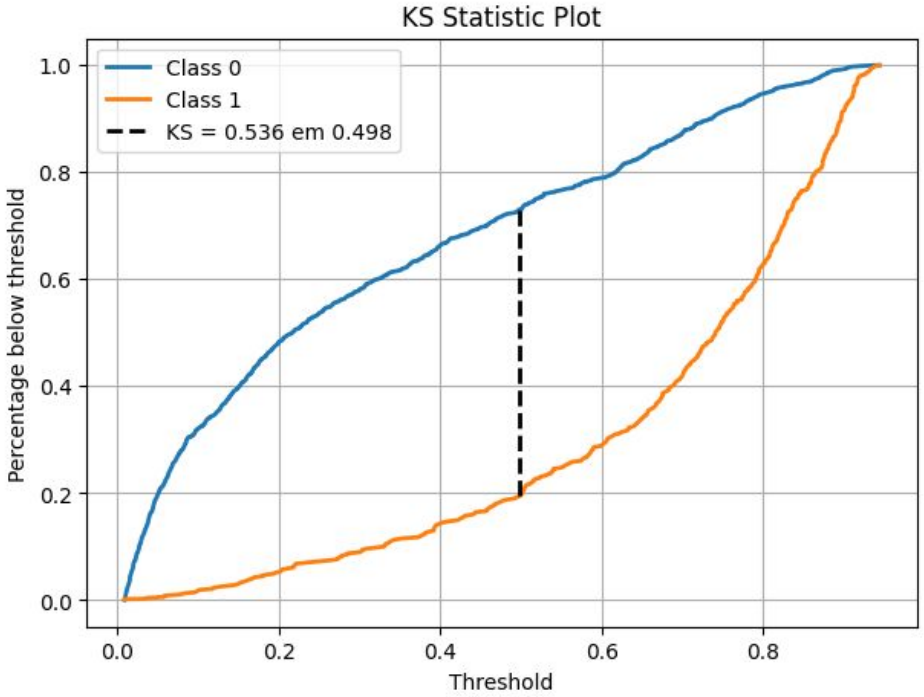




MLP

Treino 3 (Resultados): Teste Kolmogorov-Smirnov (KS)

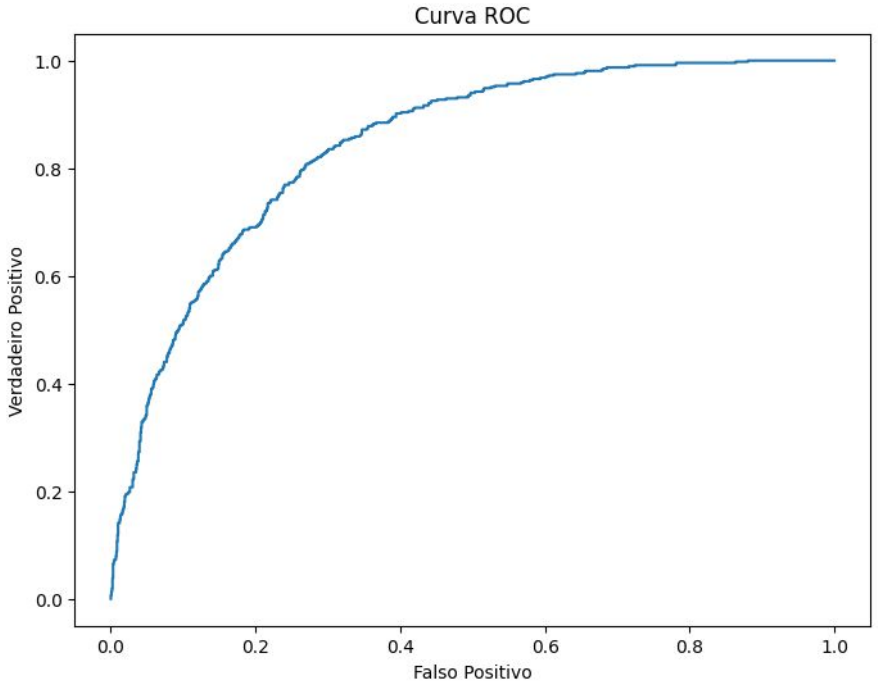
KS Statistic: 0.5360791343228445
Best threshold: 0.49812344



MLP

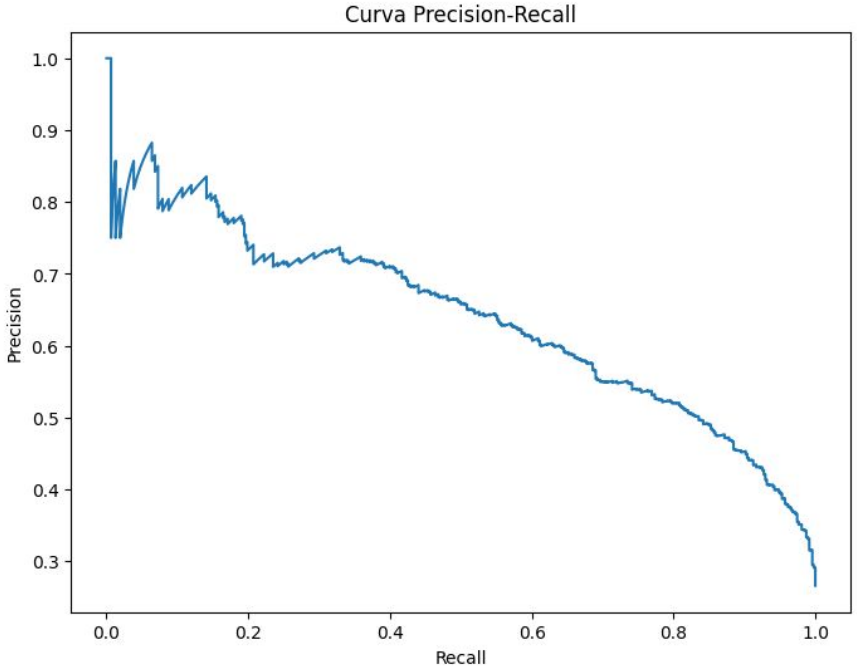
Treino 3 (Resultados): Curva ROC e AUROC

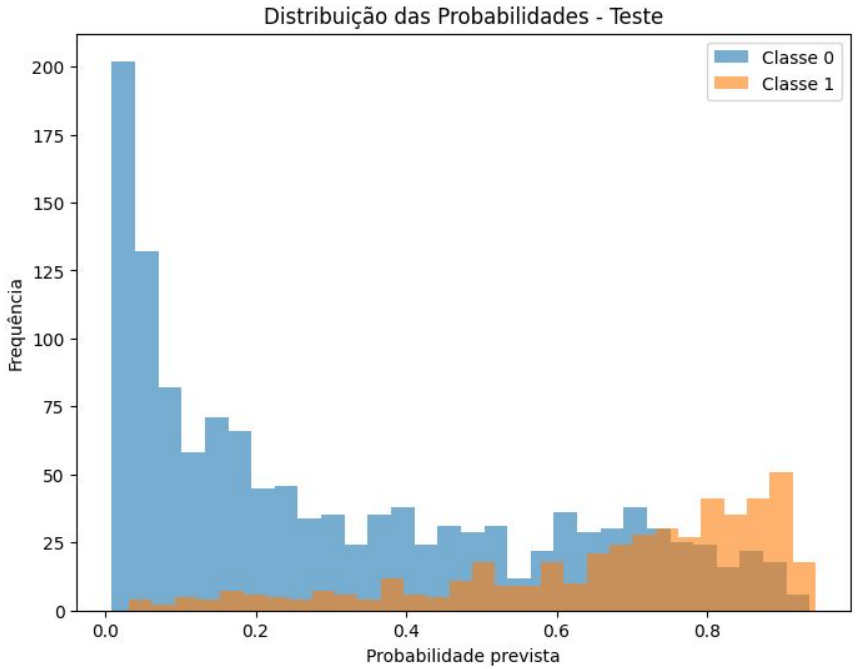
AUC (Área sob a ROC): 0.8423098439558548



MLP

Treino 3 (Resultados): Curva precision - Recall e Distribuição das probabilidades





MLP

Treino 3: Comparando resultados de teste

Parâmetros	Melhor treino (2)	Treino atual (3)
Precision	0.5544388609715243	0.5193370165745856
Recall	0.7072649572649573	0.8034188034188035
F1-Score	0.6215962441314554	0.6308724832214765
Accuracy	0.77	0.7499
MSE	0.22871736662883088	0.25014212620807275
Log Loss	0.4522830618763039	0.4885025420150897
KS	0.5146112405815821	0.5360791343228445
AUC	0.8394620470547828	0.8423098439558548

MLP

Treino 4: categóricos com fazendo one-hot encoding e min_delta=1e-6

- Voltando a tratando dados categóricos com fazendo one-hot encoding
- Early stop mais tolerante, antes o valor mínimo para aceitar que o modelo melhorou era 1e-4, agora aceita até 1e-6.
- Treino com optuna para buscar os melhores parâmetros para esse tratamento de dados (40 trial), repete treino em um novo modelo com os melhores parâmetros encontrados

MLP

Treino 4: categóricos com fazendo one-hot encoding e min_delta=1e-6

Parâmetros passados para o optuna:

- hidden layers = 2 e 3
- layer sizes = 16 a 256
- learning rate = 1e-6 a 1e-3
- activation functions = "relu", "tanh", "elu" e "LeakyReLU"
- optimizators = "adam", "nadam", "rmsprop", "sgd"
- L2 regularization = 1e-6 a 1e-3
- batch size = 64 a 256
- dropout = 0.00, 0.05, 0.10, 0.15, 0.20, 0.25 e 0.30
- epochs = 10000
- patience = 20

Melhores parâmetros encontrados:

- hidden layers: 3
- unidades na layer 0: 96
- dropout layer 0: 0.15
- unidades na layer 1: 143
- dropout layer 1: 0.2
- unidades na layer 2: 25
- dropout layer 2: 0.25
- learning rate inicial: 0.0003310897628313633
- activation function : 'LeakyReLU'
- optimizator: 'adam'
- L2 regularization: 2.2769275477330717e-05
- batch size: 66

MLP

Treino 4 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.81      0.77      0.79      2581
           1       0.78      0.81      0.80      2587

    accuracy                           0.79      5168
   macro avg       0.79      0.79      0.79      5168
weighted avg       0.79      0.79      0.79      5168

Accuracy no treino: 0.7945

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.78      0.75      0.76      1291
           1       0.76      0.79      0.77      1293

    accuracy                           0.77      2584
   macro avg       0.77      0.77      0.77      2584
weighted avg       0.77      0.77      0.77      2584

Accuracy na validação: 0.7666

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.90      0.74      0.81      1291
           1       0.52      0.76      0.62       468

    accuracy                           0.75      1759
   macro avg       0.71      0.75      0.72      1759
weighted avg       0.80      0.75      0.76      1759

Accuracy no teste: 0.7493
```

Erro Médio Quadrado:

- MSE Treino: 0.20549535603715172
- MSE Validação: 0.233359133126935
- MSE Teste: 0.25071063104036384

Entropia Cruzada:

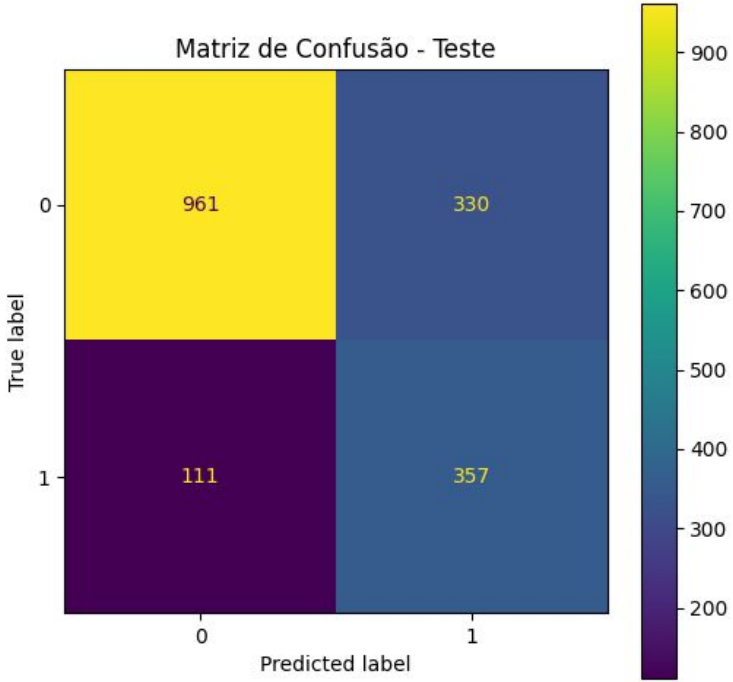
- Log Loss Treino: 0.43282974566318155
- Log Loss Validação: 0.5131991660865742
- Log Loss Teste: 0.4767886784547145

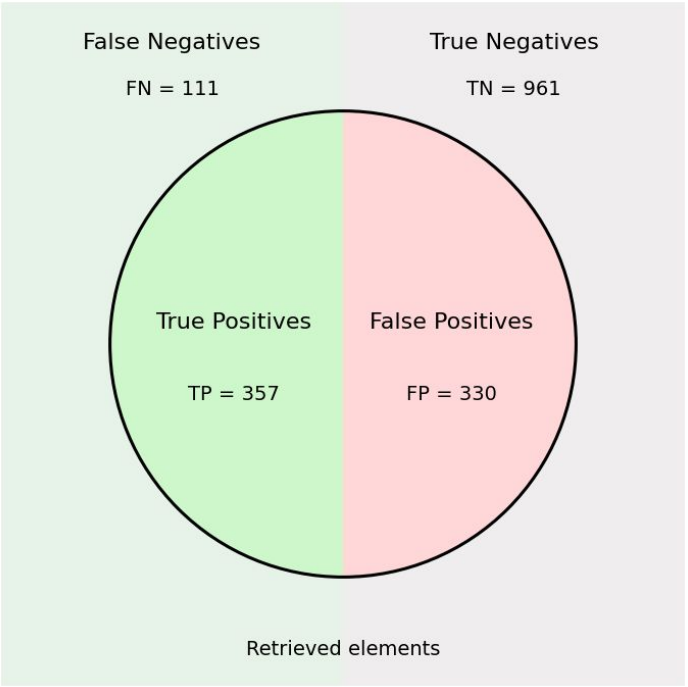
Precision, recall e F1 do teste:

- Precision: 0.519650655021834
- Recall: 0.7628205128205128
- F1-Score: 0.6181818181818182

MLP

Treino 4 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

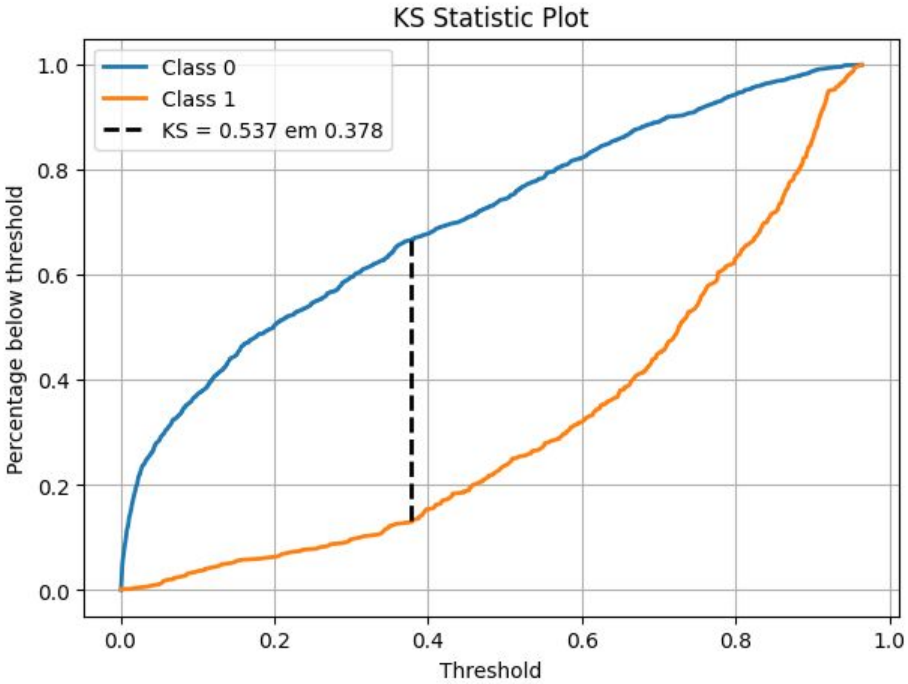




MLP

Treino 4 (Resultados): Teste Kolmogorov-Smirnov (KS)

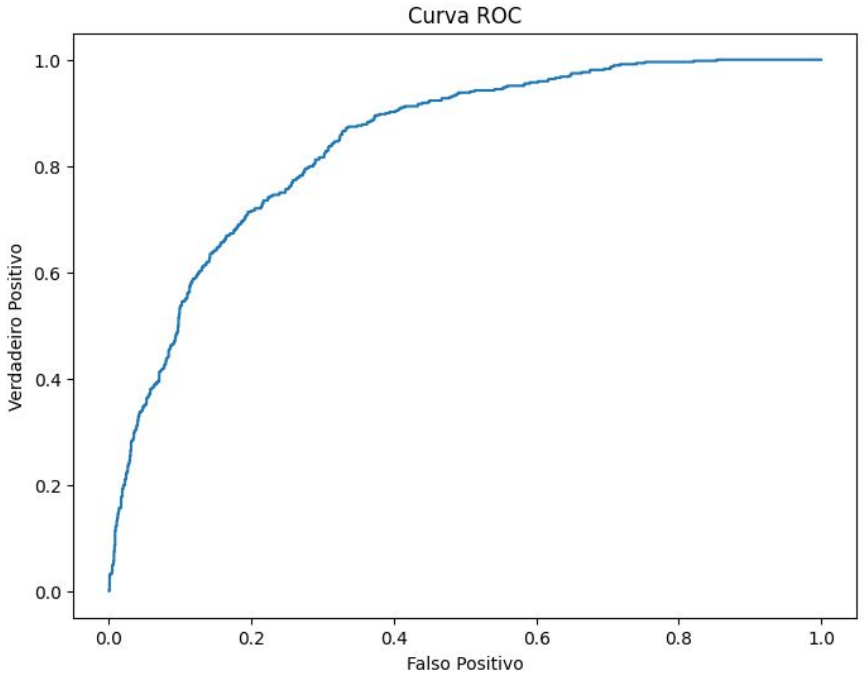
KS Statistic: 0.5368808461330588
Best threshold: 0.37799597



MLP

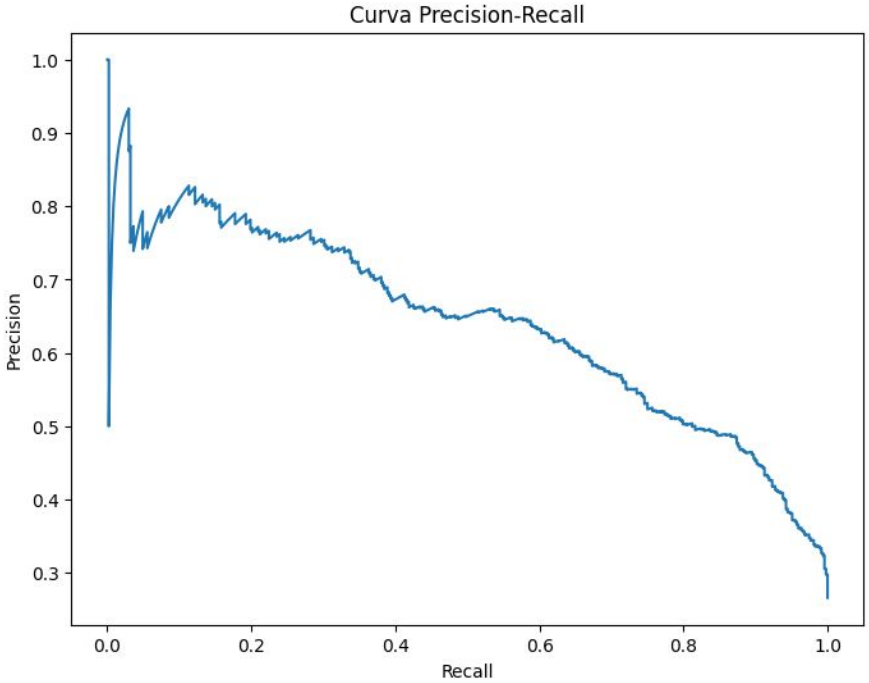
Treino 4 (Resultados): Curva ROC e AUROC

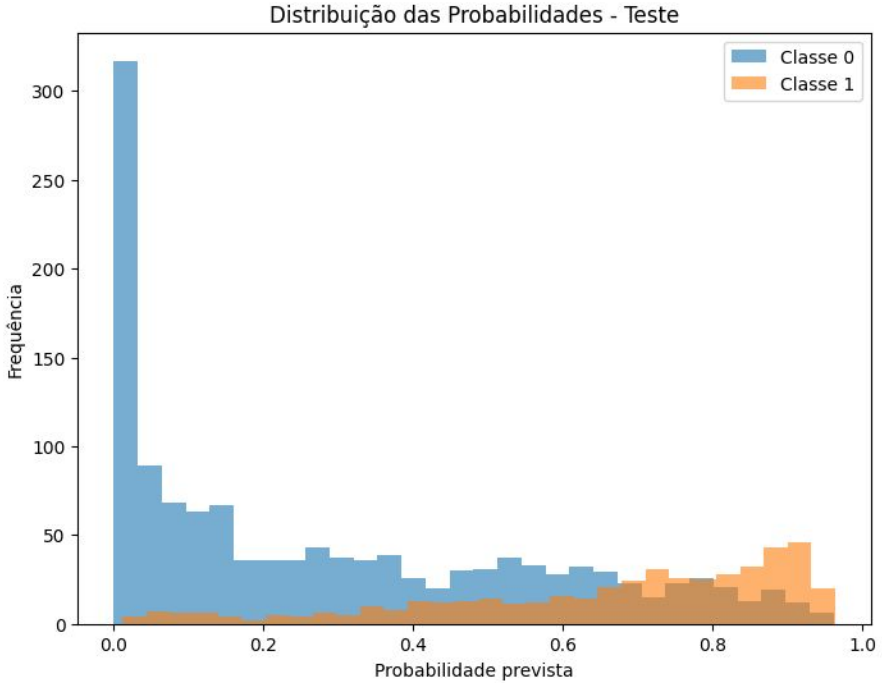
AUC (Área sob a ROC): 0.8418497222718757



MLP

Treino 4 (Resultados): Curva precision - Recall e Distribuição das probabilidades





MLP

Treino 4: Comparando resultados de teste

Parâmetros	Melhor treino (3)	Treino atual (4)
Precision	0.5193370165745856	0.519650655021834
Recall	0.8034188034188035	0.7628205128205128
F1-Score	0.6308724832214765	0.6181818181818182
Accuracy	0.7499	0.7493
MSE	0.25014212620807275	0.25071063104036384
Log Loss	0.4885025420150897	0.4767886784547145
KS	0.5360791343228445	0.5368808461330588
AUC	0.8423098439558548	0.8418497222718757

MLP

Treino 5: Escalonando apenas features não binárias

- Ajustando tratamento para escalonar apenas as features que não são binárias
- Treino com optuna para obter melhores parâmetros (40 trial), repete treino em um novo modelo com os melhores parâmetros encontrados
- Modelo conseguiu um KS = 0.5635939898460297, mas apenas no treino, com os dados de teste o valor foi menor (entre 0.52 e 0.53)

MLP

Treino 5: Escalonando apenas features não binárias

Parâmetros passados para o optuna:

- hidden layers = 2 e 3
- layer sizes = 16 a 256
- learning rate = 1e-6 a 1e-3
- activation functions = "relu", "tanh", "elu" e "LeakyReLU"
- optimizators = "adam", "nadam", "rmsprop", "sgd"
- L2 regularization = 1e-6 a 1e-3
- batch size = 64 a 256
- dropout = 0.00, 0.05, 0.10, 0.15, 0.20
- epochs = 10000
- patience = 20

Melhores parâmetros encontrados:

- hidden layers: 2
- unidades na layer 0: 77
- dropout layer 0: 0.05
- unidades na layer 1: 181
- dropout layer 1: 0.15
- learning rate inicial: 2.1532650853433163e-05
- activation function : 'LeakyReLU'
- optimizator: 'adam'
- L2 regularization: 0.0002866449752438247
- batch size: 106

MLP

Treino 5 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.82      0.76      0.79      2581
           1       0.78      0.83      0.80      2587

    accuracy                           0.80      5168
   macro avg       0.80      0.80      0.80      5168
weighted avg       0.80      0.80      0.80      5168

Accuracy no treino: 0.7959

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.78      0.72      0.75      1291
           1       0.74      0.80      0.77      1293

    accuracy                           0.76      2584
   macro avg       0.76      0.76      0.76      2584
weighted avg       0.76      0.76      0.76      2584

Accuracy na validação: 0.7593

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.90      0.73      0.81      1291
           1       0.51      0.78      0.62       468

    accuracy                           0.74      1759
   macro avg       0.71      0.76      0.71      1759
weighted avg       0.80      0.74      0.76      1759

Accuracy no teste: 0.7442
```

Erro Médio Quadrado:

- MSE Treino: 0.204140866873065
- MSE Validação: 0.24071207430340558
- MSE Teste: 0.2558271745309835

Entropia Cruzada:

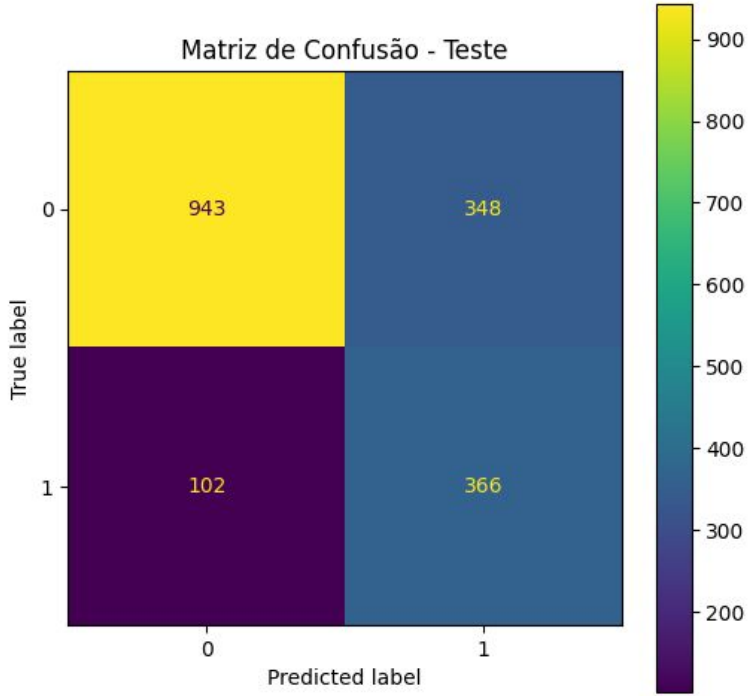
- Log Loss Treino: 0.43694645283023337
- Log Loss Validação: 0.5077351015156404
- Log Loss Teste: 0.48302838091547157

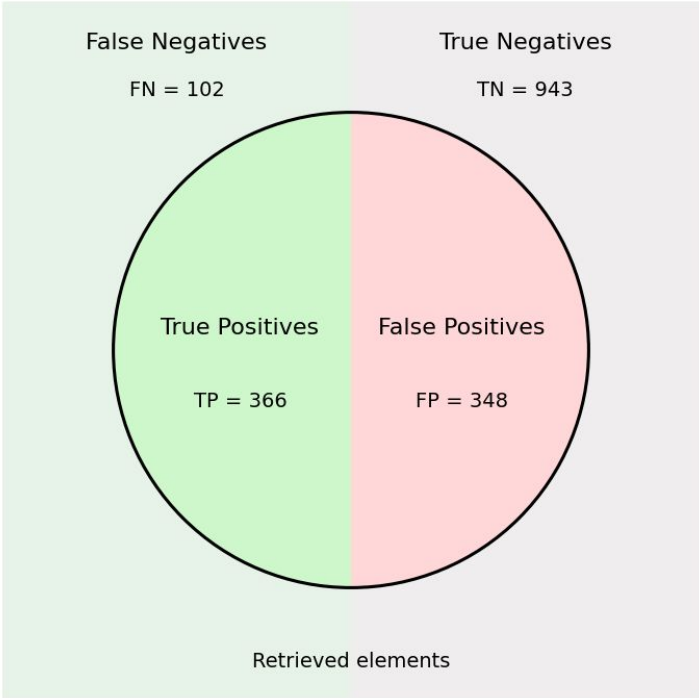
Precision, recall e F1 do teste:

- Precision: 0.5126050420168067
- Recall: 0.782051282051282
- F1-Score: 0.6192893401015228

MLP

Treino 5 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

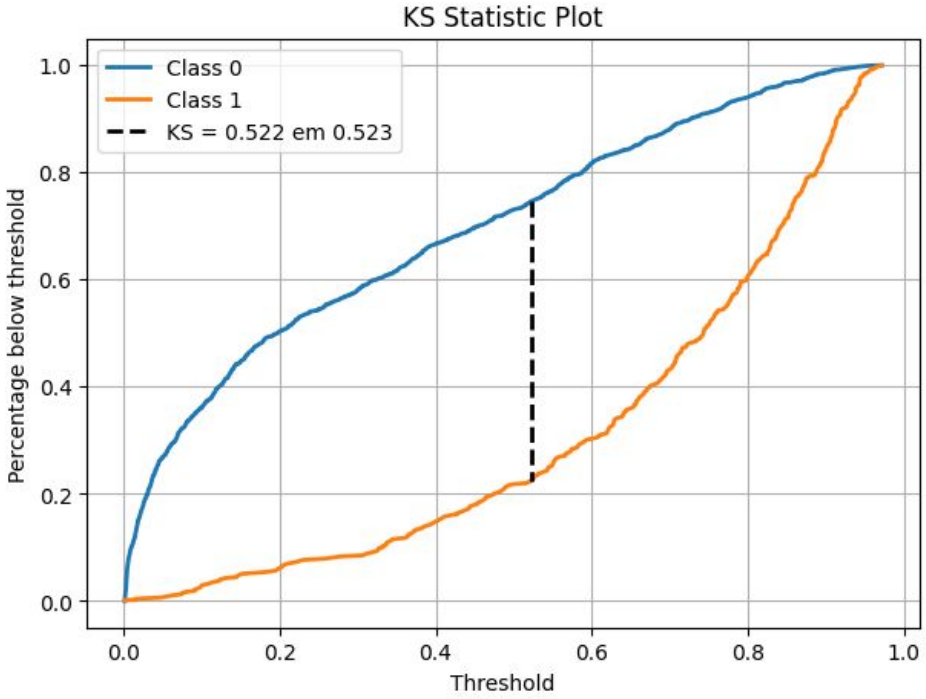




MLP

Treino 5 (Resultados): Teste Kolmogorov-Smirnov (KS)

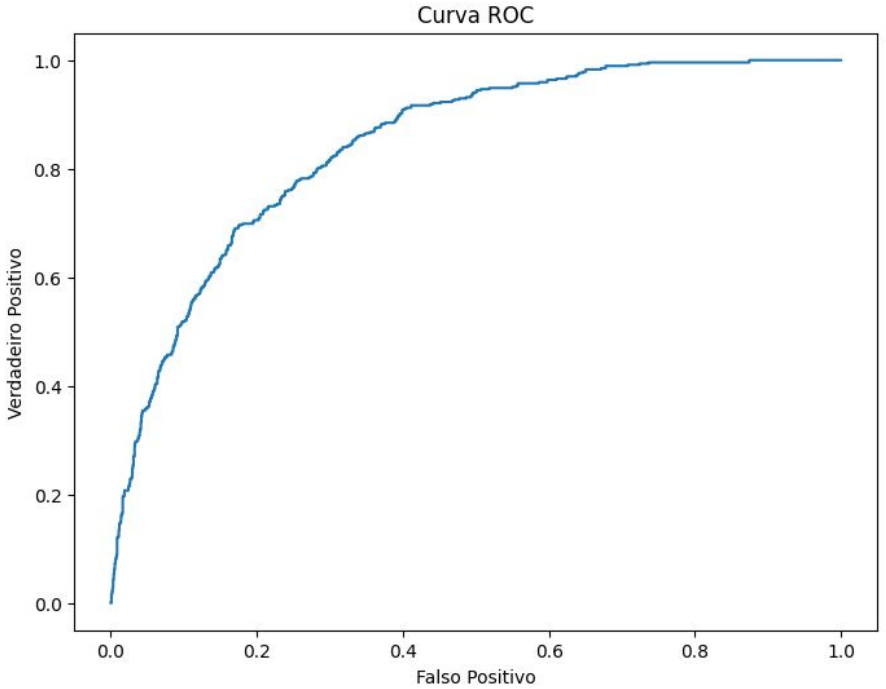
KS Statistic: 0.522114040640255
Best threshold: 0.52250147



MLP

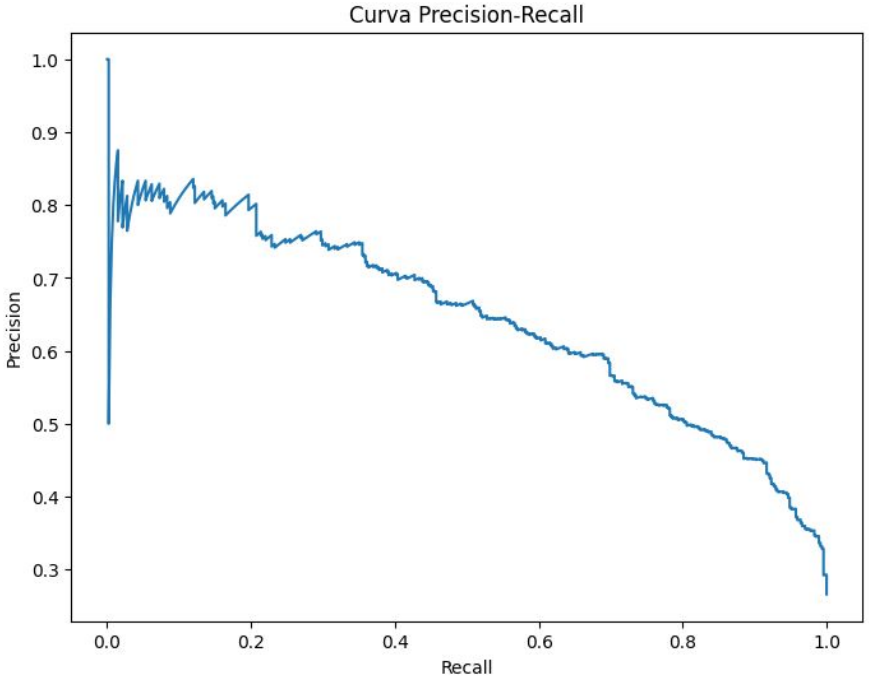
Treino 5 (Resultados): Curva ROC e AUROC

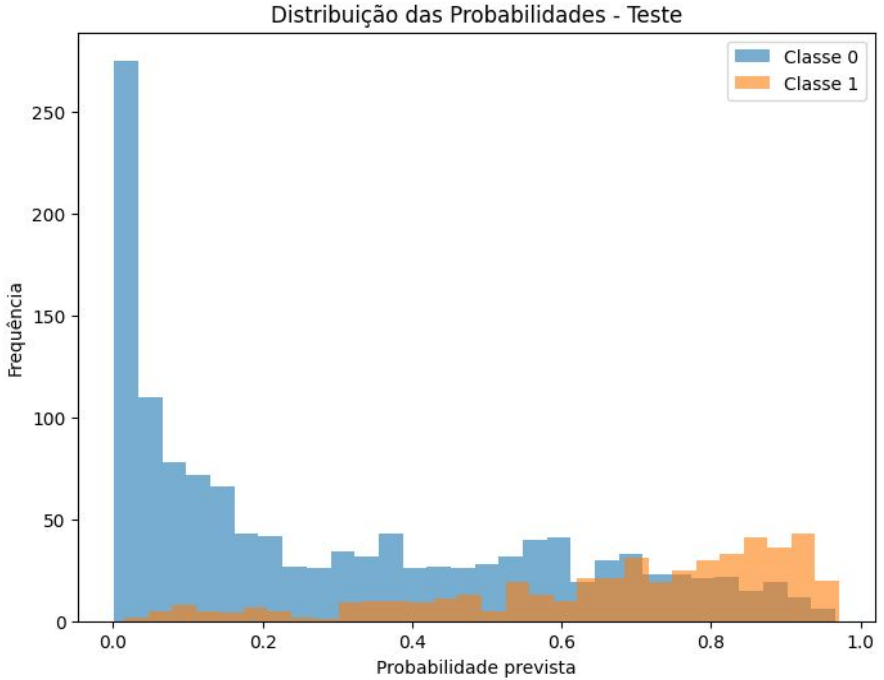
AUC (Área sob a ROC): 0.8429520281766603



MLP

Treino 5 (Resultados): Curva precision - Recall e Distribuição das probabilidades





MLP

Treino 5: Comparando resultados de teste

Parâmetros	Melhor treino (4)	Treino atual (5)
Precision	0.519650655021834	0.5126050420168067
Recall	0.7628205128205128	0.782051282051282
F1-Score	0.6181818181818182	0.6192893401015228
Accuracy	0.7493	0.7442
MSE	0.25071063104036384	0.2558271745309835
Log Loss	0.4767886784547145	0.48302838091547157
KS	0.5368808461330588	0.522114040640255
AUC	0.8418497222718757	0.8429520281766603

XGBoost

Treino 1:

Parâmetros passados para o optuna:

n_estimators = 100 a 1000
learning_rate = 0.001 a 0.3 (log)
max_depth = 3 a 10
min_child_weight = 1 a 10
subsample = 0.5 a 1.0
colsample_bytree = 0.5 a 1.0
alpha (L1) = 1e-8 a 10.0 (log)
lambda (L2) = 1e-8 a 10.0 (log)
early_stopping_rounds = 20

Melhores parâmetros encontrados:

n_estimators: 979
learning_rate: 0.061414724107698944
max_depth: 3 (Navalha de Occam - profundidade mínima escolhida)
min_child_weight: 1
subsample: 0.7179522880653418
colsample_bytree: 0.8883916926672029
alpha (L1): 0.0011190199032929346
lambda (L2): 9.755484238080027e-06
Melhor Loss: 0.49645037094050215

XGBoost

=== TABELA GERAL DE RESULTADOS (Incluindo KS) ===

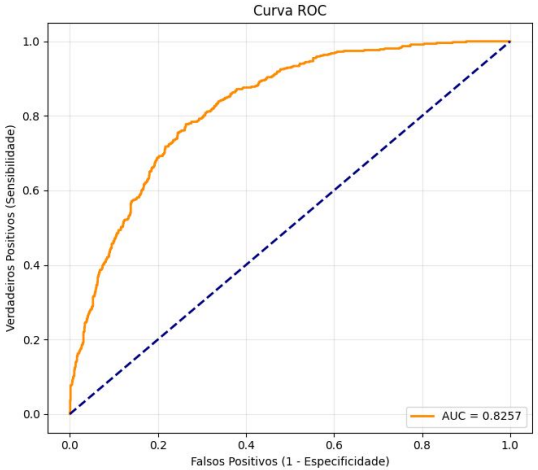
Conjunto	MSE	KS Statistic	Precision	Recall	F1-Score	Support
Treinamento	0.0872	0.7911	0.8977	0.8951	0.8948	5089
Validação	0.0923	0.7765	0.8852	0.8821	0.8818	2586
Teste	0.1622	0.5143	0.7890	0.7639	0.7722	1762

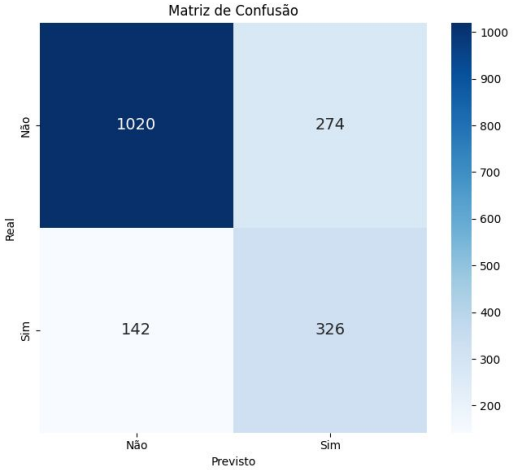
XGBoost

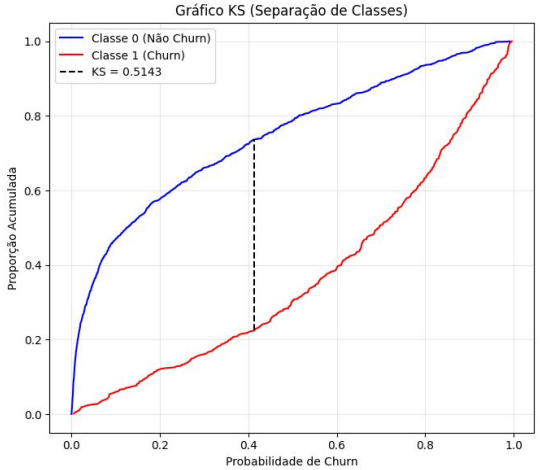
=== Detalhes por Classe (Precision, Recall, F1) ===

	precision	recall	f1-score	support
0	0.88	0.79	0.83	1294
1	0.54	0.70	0.61	468
accuracy			0.76	1762
macro avg	0.71	0.74	0.72	1762
weighted avg	0.79	0.76	0.77	1762

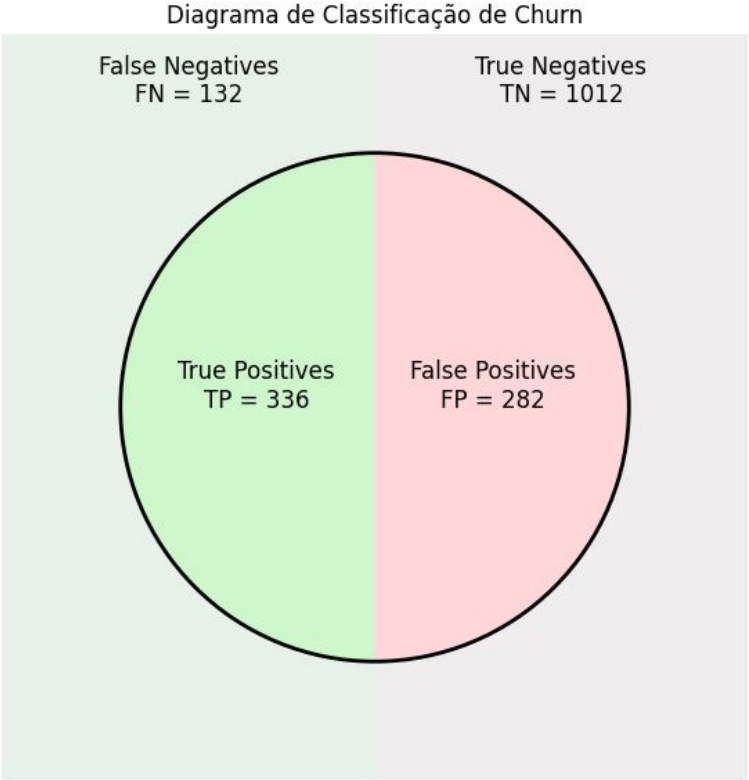
XGBoost


Curva ROC
Verdadeiros Positivos (Sensibilidade)
Falsos Positivos (1 - Especificidade)
AUC = 0.8257
0.0
0.2
0.4
0.6
0.8
1.0

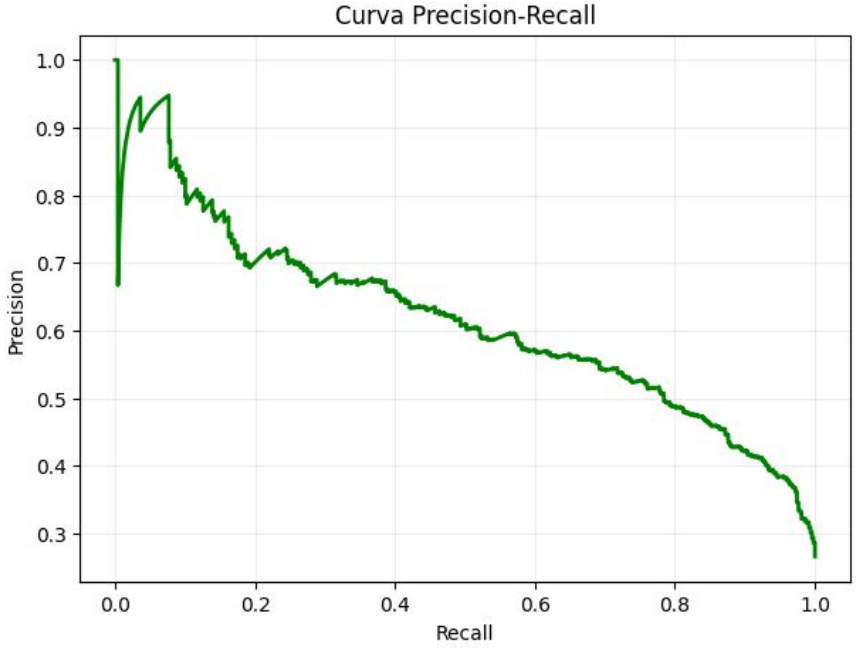

Matriz de Confusão
Real
Previsto
Não
Sim
1020
274
142
326
1000
900
800
700
600
500
400
300
200

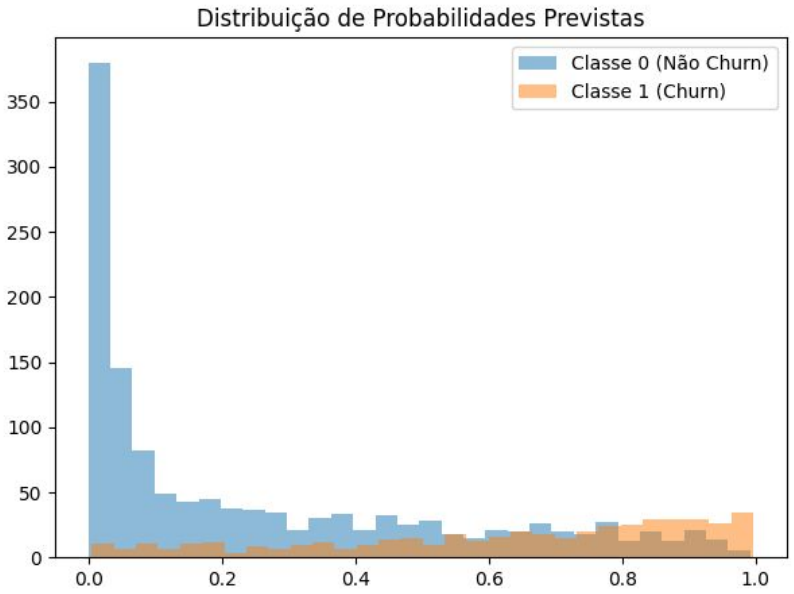

Gráfico KS (Separação de Classes)
Classe 0 (Não Churn)
Classe 1 (Churn)
KS = 0.5143
Proporção Acumulada
Probabilidade de Churn
0.0
0.2
0.4
0.6
0.8
1.0

XGBoost


Diagrama de Classificação de Churn
False Negatives
FN = 132
True Negatives
TN = 1012
True Positives
TP = 336
False Positives
FP = 282

XGBoost


Curva Precision-Recall
Precision
Recall
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.0
0.2
0.4
0.6
0.8
1.0


Distribuição de Probabilidades Previstas
Classe 0 (Não Churn)
Classe 1 (Churn)
350
300
250
200
150
100
50
0
0.0
0.2
0.4
0.6
0.8
1.0

XGBoost

Treino 2:

Parâmetros passados para o optuna:

n_estimators = 100 a 1000
learning_rate = 0.001 a 0.3
max_depth = 3 a 10
gamma (Min. loss reduction) = 0 a 5
alpha (L1) = 1e-8 a 10.0
lambda (L2) = 1e-8 a 10.0
scale_pos_weight = 1 a 3 (Ajuste para Churn)
Métrica Alvo: Maximizar F1-Score na Validação

Melhores parâmetros encontrados:

n_estimators: 221
learning_rate: 0.0620
max_depth: 6
gamma: 4.4195 (Regularização conservadora)
alpha (L1): 1.7408
lambda (L2): 0.1100
scale_pos_weight: 1.3349
Melhor F1-Score (Val): 0.7852

XGBoost

=== TABELA GERAL DE RESULTADOS (Incluindo KS) ===

Conjunto	MSE	KS Statistic	Precision	Recall	F1-Score	Support
Treinamento	0.1221	0.6815	0.8489	0.8404	0.8393	5089
Validação	0.1315	0.6489	0.8195	0.8101	0.8087	2586
Teste	0.1717	0.5421	0.8020	0.7384	0.7526	1762

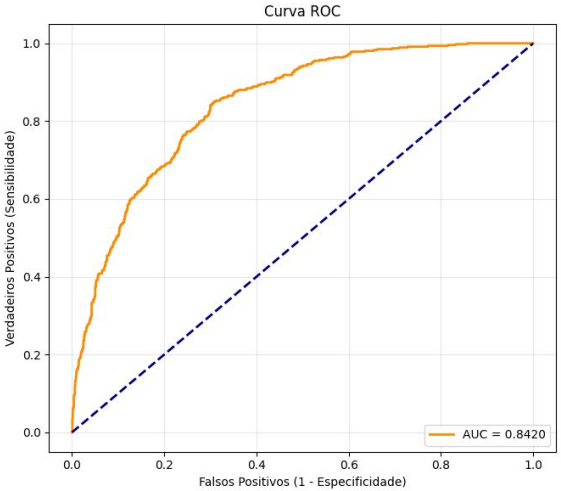
XGBoost

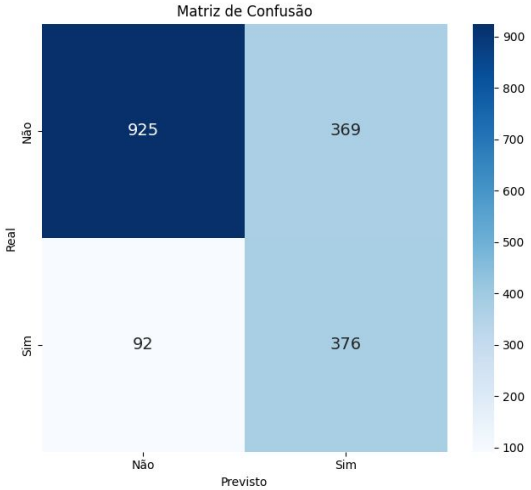
```
=== Detalhes por Classe (Precision, Recall, F1) ===
              precision    recall  f1-score   support

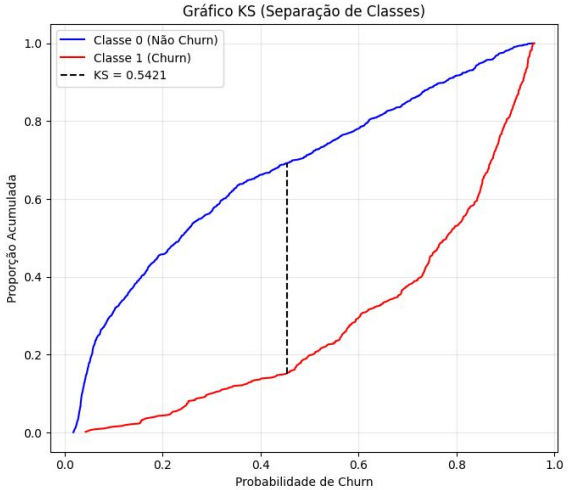
           0       0.91      0.71      0.80      1294
           1       0.50      0.80      0.62       468

    accuracy                           0.74      1762
   macro avg       0.71      0.76      0.71      1762
weighted avg       0.80      0.74      0.75      1762
```

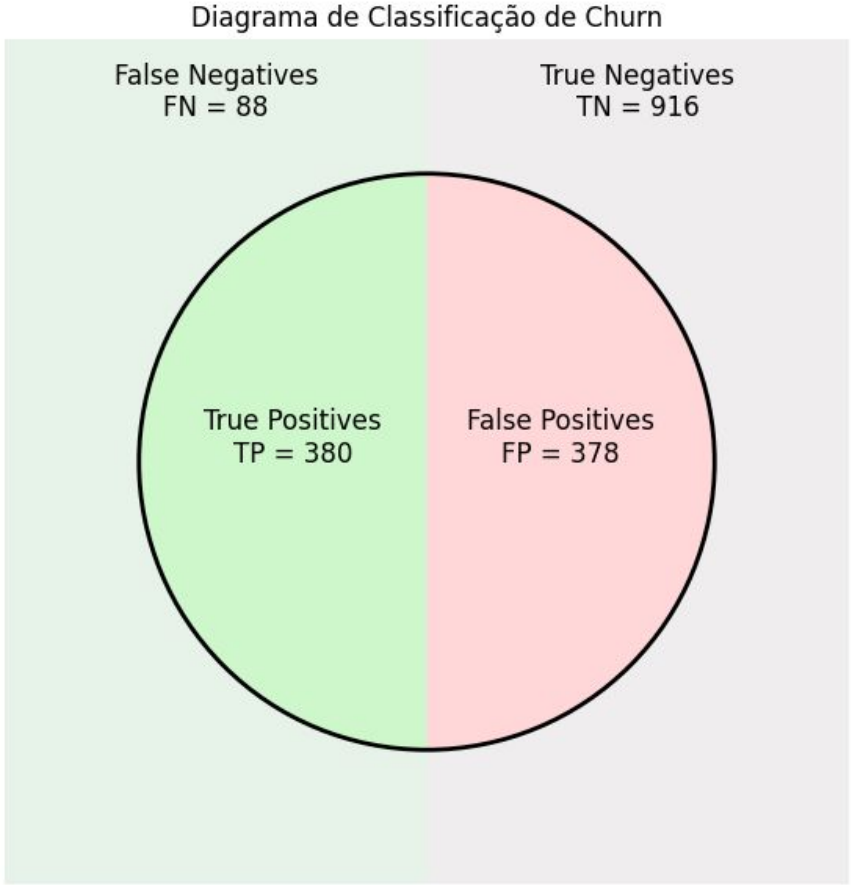
XGBoost


Curva ROC
Verdadeiros Positivos (Sensibilidade)
Falsos Positivos (1 - Especificidade)
AUC = 0.8420

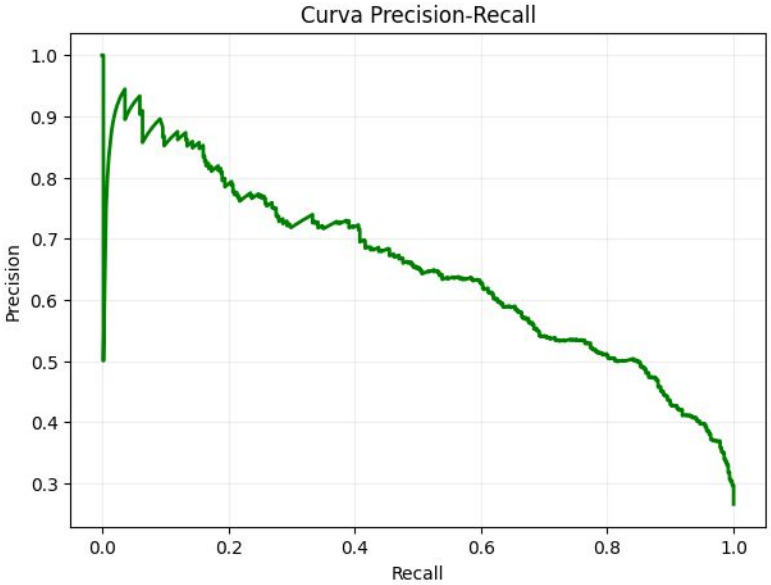

Matriz de Confusão
Não
Sim
925
369
92
376
Real
Previsto

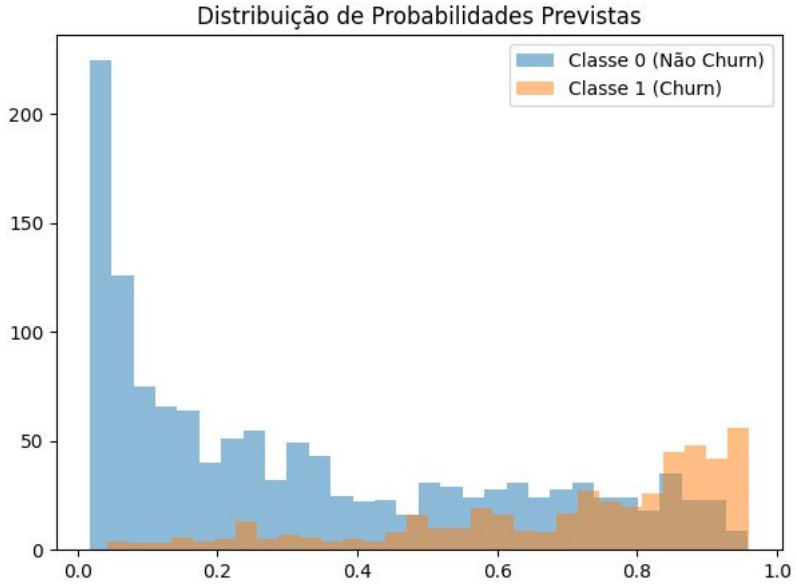

Gráfico KS (Separação de Classes)
Classe 0 (Não Churn)
Classe 1 (Churn)
KS = 0.5421
Proporção Acumulada
Probabilidade de Churn

XGBoost


Diagrama de Classificação de Churn
False Negatives
FN = 88
True Negatives
TN = 916
True Positives
TP = 380
False Positives
FP = 378

XGBoost


Curva Precision-Recall
Precision
Recall
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.0
0.2
0.4
0.6
0.8
1.0


Distribuição de Probabilidades Previstas
Classe 0 (Não Churn)
Classe 1 (Churn)
200
150
100
50
0
0.0
0.2
0.4
0.6
0.8
1.0

STAB

Treino 1: Treino teste do modelo STAB (de Kailane)

- Treino de teste do modelo
- Esse treino usou um tratamento de dados antigo que era pior.
- Treino realizado com optuna para buscar melhores parâmetros e depois treino é refeito em um novo modelo com os melhores parâmetros encontrados
- Foram feitos 20 trials do optuna
- Todos os treino deste modelo são focados em melhorar o KS

STAB

Treino 1: Treino teste do modelo STAB (de Kailane)

Parâmetros passados para o optuna:

- embedding dimensions = 2, 4 ou 8
- transformers number = 1 a 4
- attention heads = 2, 4 ou 8
- attention dropout = 0.10, 0.15 ou 0.20
- feed foward dropout = 0.10, 0.15 ou 0.20
- U values = 2 e 4
- cases values = 8 e 16
- sample size dimensions = 16, 32, 64 ou 128
- learning rate = 1e-4 a 1e-2
- weight decay = 1e-4 a 1e-2
- batch size = 32, 64, 128 ou 256
- epochs = 10000
- patience = 10

Melhores parâmetros encontrados:

- embedding dimensions: 8
- transformers number: 1
- attention heads: 4
- attention dropout: 0.15
- feed foward dropout: 0.15
- U values: 2
- cases values: 8
- sample size dimensions: 32
- learning rate: 0.0006079537506062664
- weight decay: 0.00010027807758221969
- batch size: 128

STAB

Treino 1 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.80      0.74      0.77      2581
           1       0.76      0.82      0.79      2587

    accuracy                           0.78      5168
   macro avg       0.78      0.78      0.78      5168
weighted avg       0.78      0.78      0.78      5168

Accuracy no treino: 0.7779

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.77      0.71      0.74      1291
           1       0.73      0.79      0.76      1293

    accuracy                           0.75      2584
   macro avg       0.75      0.75      0.75      2584
weighted avg       0.75      0.75      0.75      2584

Accuracy na validação: 0.7496

==== CLASSIFICATION REPORT - TESTE ====
...
   macro avg       0.71      0.76      0.71      1759
weighted avg       0.80      0.74      0.75      1759

Accuracy no teste: 0.7408
```

Erro Médio Quadrado:

- MSE Treino: 0.22213622291021673
- MSE Validação: 0.2503869969040248
- MSE Teste: 0.25923820352473

Entropia Cruzada:

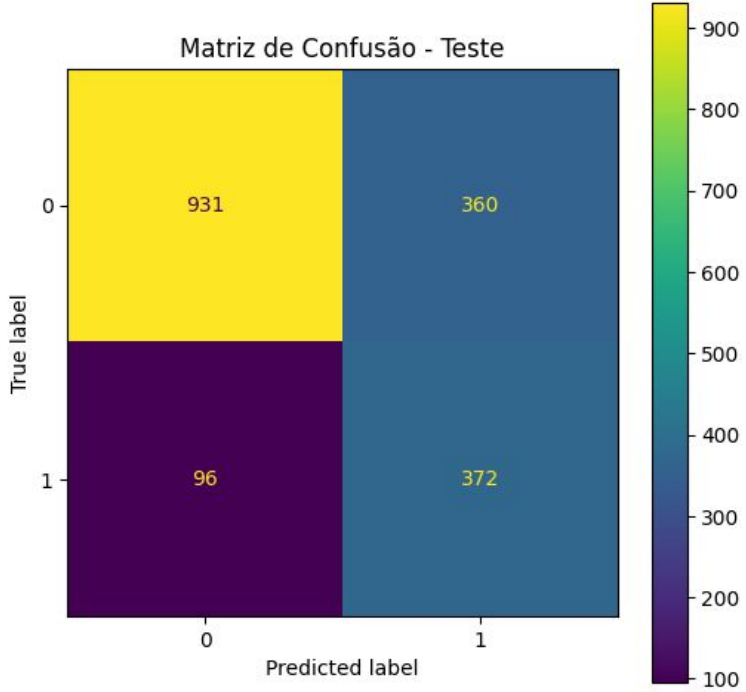
- Log Loss Treino: 0.4586124672039528
- Log Loss Validação: 0.5069905399268915
- Log Loss Teste: 0.500784413565308

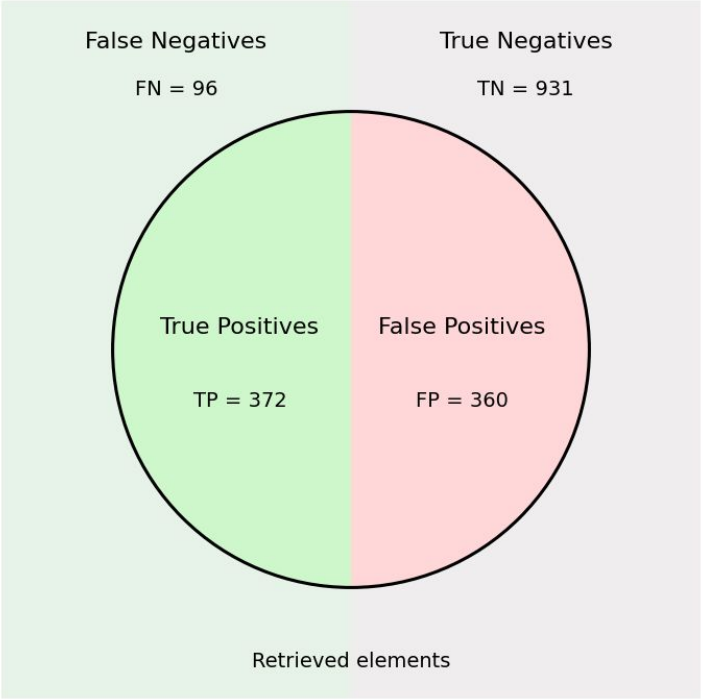
Precision, recall e F1 do teste:

- Precision: 0.5081967213114754
- Recall: 0.7948717948717948
- F1-Score: 0.62

STAB

Treino 1 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

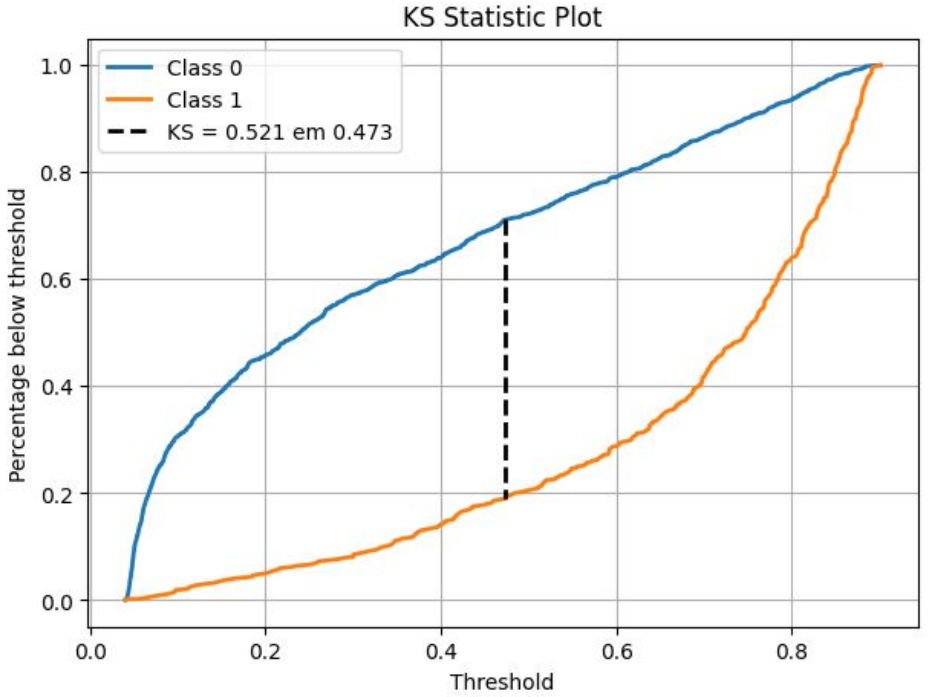




STAB

Treino 1 (Resultados): Teste Kolmogorov-Smirnov (KS)

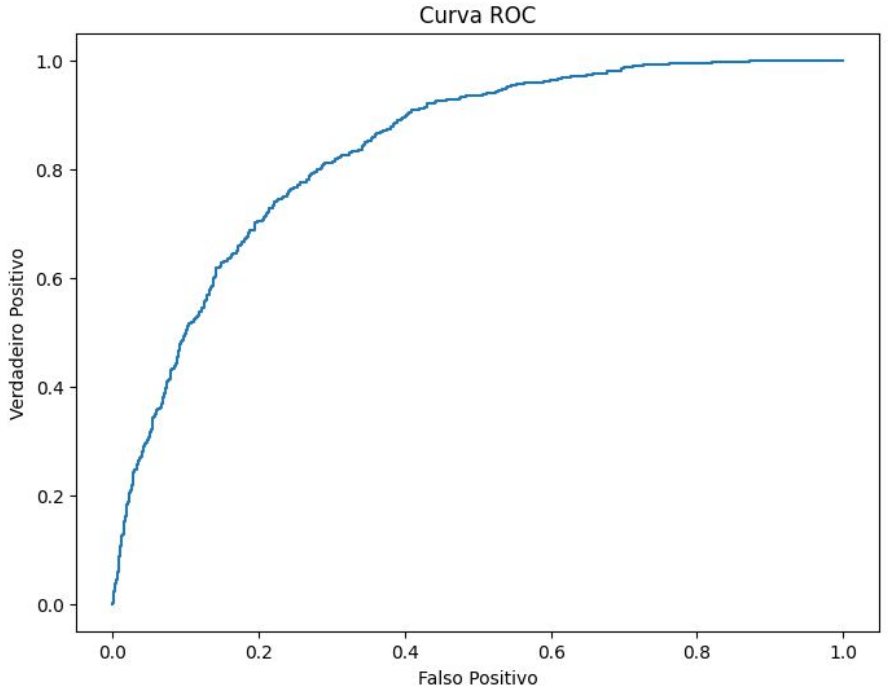
KS Statistic: 0.5207322495514675
Best threshold: 0.47306046



STAB

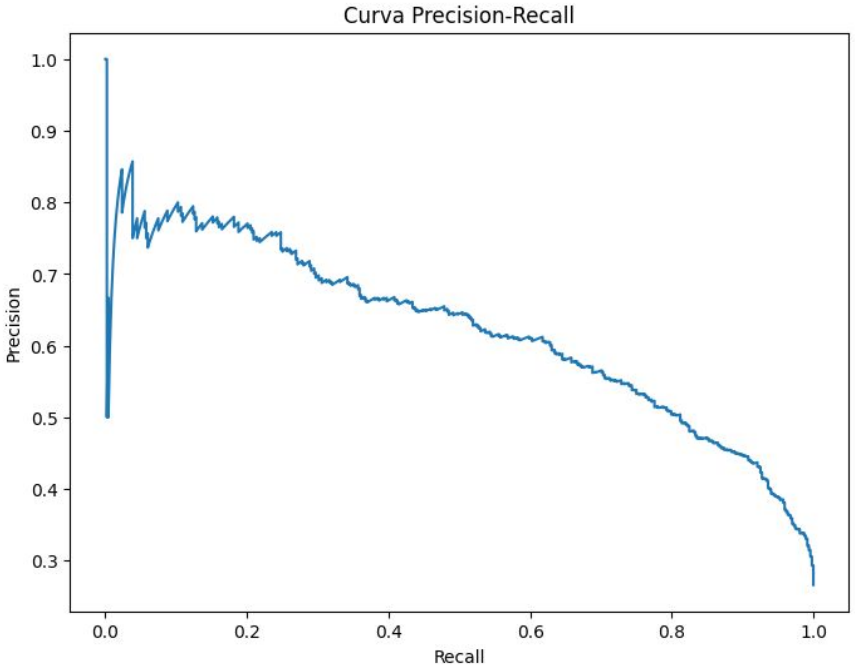
Treino 1 (Resultados): Curva ROC e AUROC

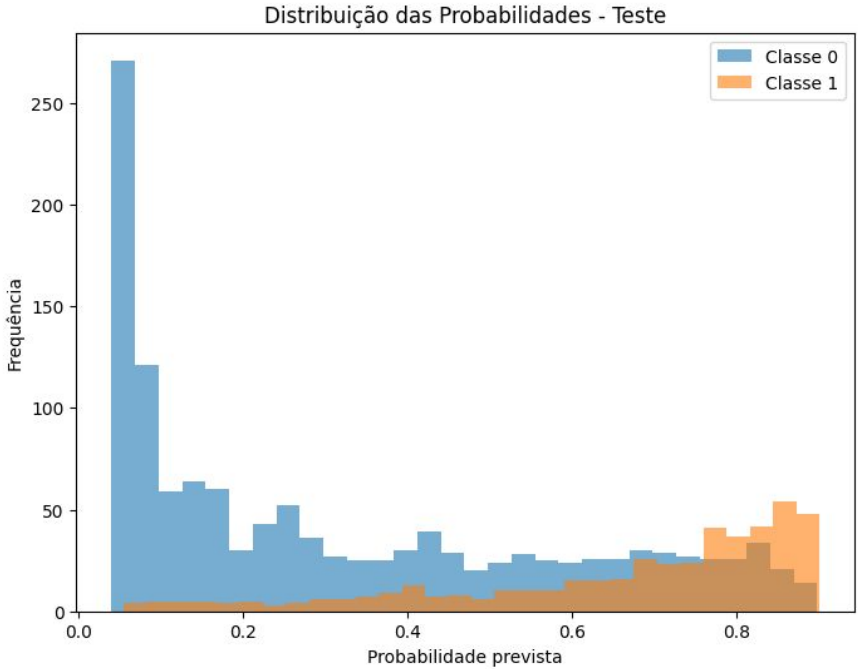
AUC (Área sob a ROC): 0.8360907532092661



STAB

Treino 1 (Resultados): Curva precision - Recall e Distribuição das probabilidades





STAB

Treino 2: Treino com tratamento de dados corrigido

- Treino com o tratamento de dados funcionando como descrito anteriormente
- Treino com optuna para buscar os melhores parâmetros (20 trials), repete treino em um novo modelo com os melhores parâmetros encontrados
- Treino focado em KS
- Melhor KS do treino: 0.5420948462102918

STAB

Treino 2: Treino com tratamento de dados corrigido

Parâmetros passados para o optuna:

- embedding dimensions = 2, 4 ou 8
- transformers number = 1 a 4
- attention heads = 2, 4, ou 8
- attention dropout = 0.10, 0.15 ou 0.20
- feed foward dropout = 0.10, 0.15 ou 0.20
- U values = 2 e 4
- cases values = 8 e 16
- sample size dimensions = 16, 32, 64 ou 128
- learning rate = 1e-4 a 1e-2
- weight decay = 1e-4 a 1e-2
- batch size = 32, 64, 128 ou 256
- epochs = 10000
- patience = 10

Melhores parâmetros encontrados:

- embedding dimensions: 8
- transformers number: 4
- attention heads: 2
- attention dropout: 0.15
- feed foward dropout: 0.15
- U values: 4
- cases values: 16
- sample size dimensions: 32
- learning rate: 0.00031803232307224766
- weight decay: 0.00018207626239658746
- batch size: 32

STAB

Treino 2 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.79      0.75      0.77      2581
           1       0.76      0.80      0.78      2587

    accuracy                           0.77      5168
   macro avg       0.78      0.77      0.77      5168
weighted avg       0.78      0.77      0.77      5168

Accuracy no treino: 0.7750

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.77      0.71      0.74      1291
           1       0.73      0.79      0.76      1293

    accuracy                           0.75      2584
   macro avg       0.75      0.75      0.75      2584
weighted avg       0.75      0.75      0.75      2584

Accuracy na validação: 0.7523

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.91      0.73      0.81      1291
           1       0.52      0.80      0.63       468

    accuracy                           0.75      1759
   macro avg       0.72      0.77      0.72      1759
weighted avg       0.81      0.75      0.76      1759

Accuracy no teste: 0.7510
```

Erro Médio Quadrado:

- MSE Treino: 0.22503869969040247
- MSE Validação: 0.2476780185758514
- MSE Teste: 0.2490051165434906

Entropia Cruzada:

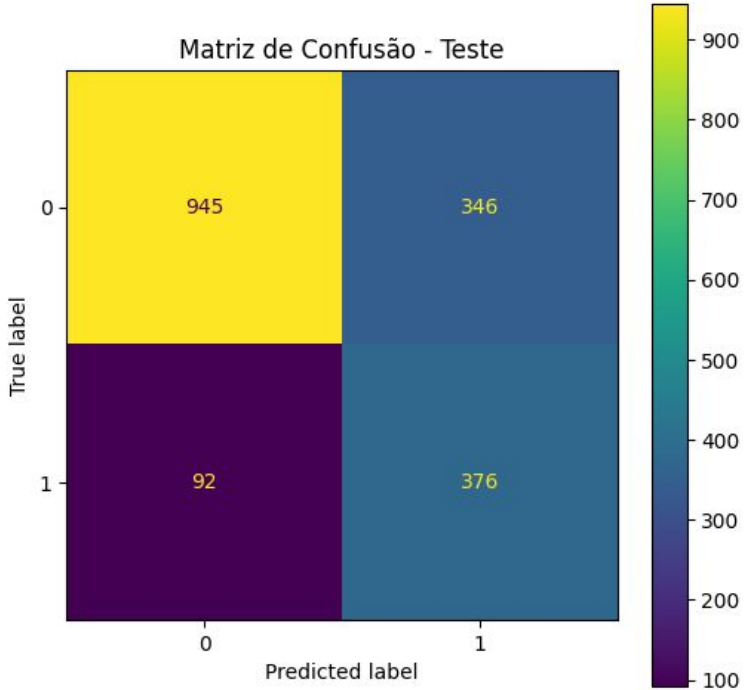
- Log Loss Treino: 0.4679090282188555
- Log Loss Validação: 0.5082222908371096
- Log Loss Teste: 0.48897471975012663

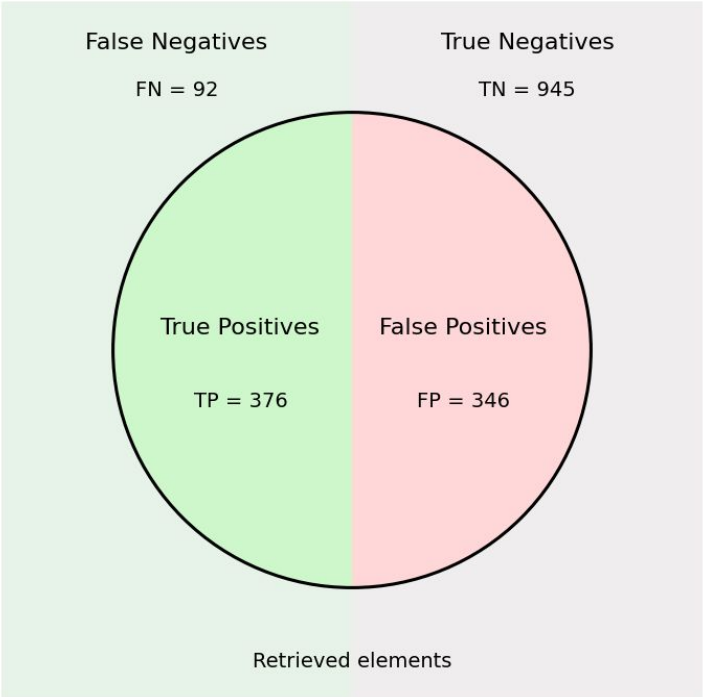
Precision, recall e F1 do teste:

- Precision: 0.5207756232686981
- Recall: 0.8034188034188035
- F1-Score: 0.6319327731092437

STAB

Treino 2 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

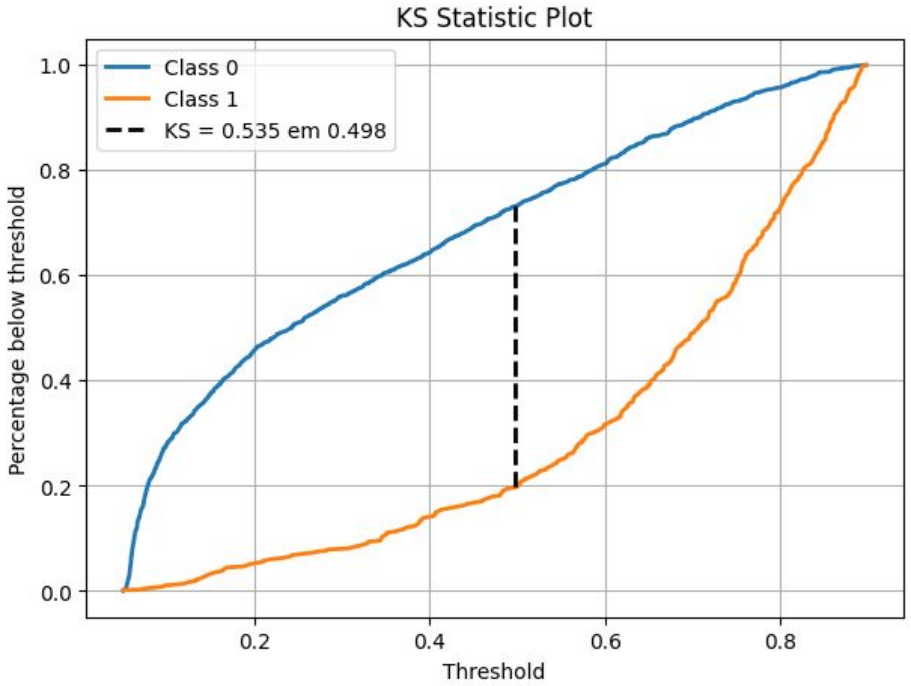




STAB

Treino 2 (Resultados): Teste Kolmogorov-Smirnov (KS)

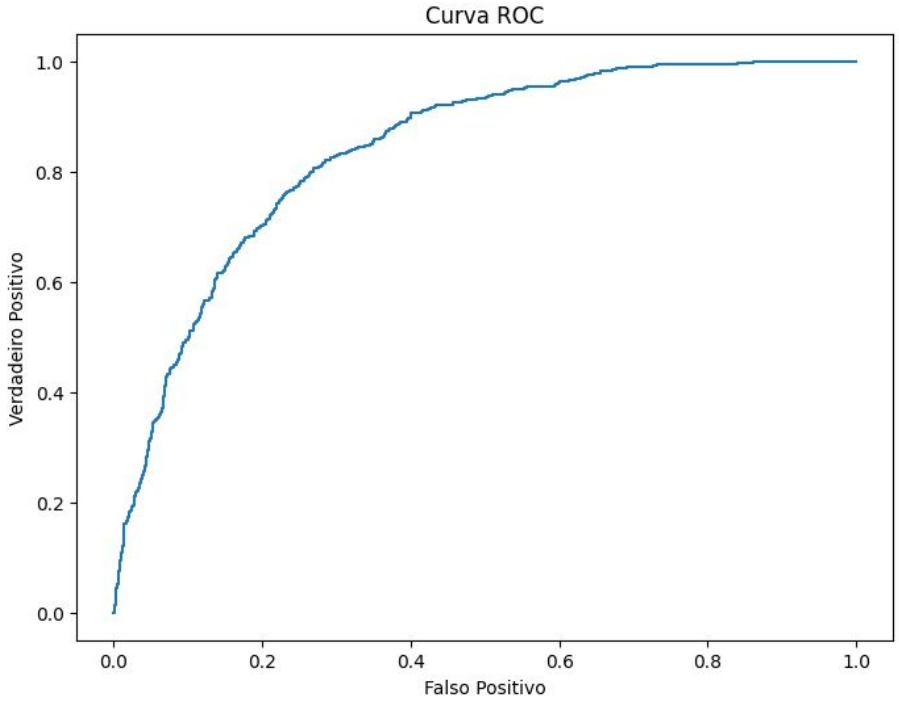
KS Statistic: 0.534644134882011
Best threshold: 0.498103



STAB

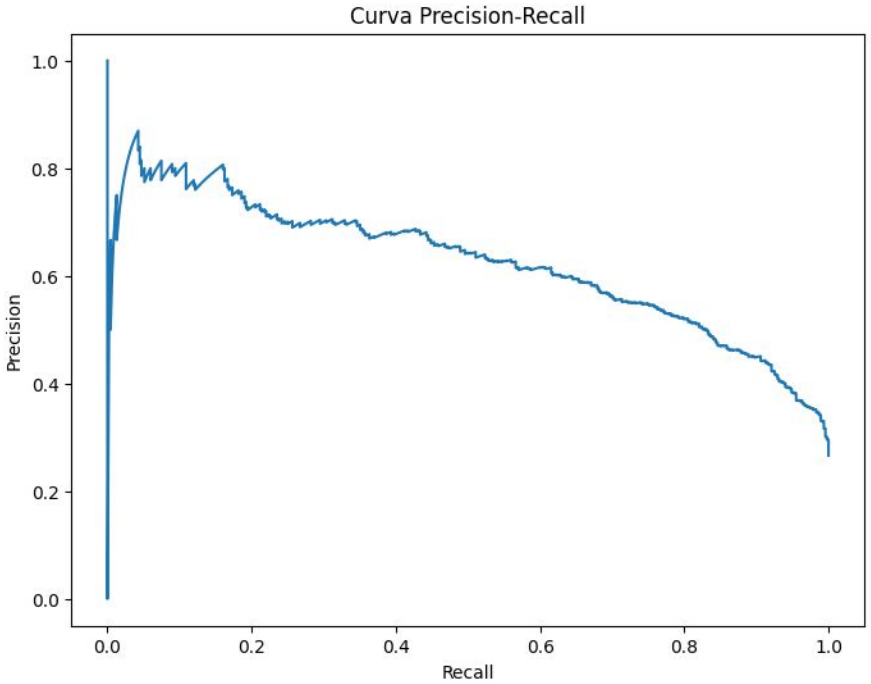
Treino 2 (Resultados): Curva ROC e AUROC

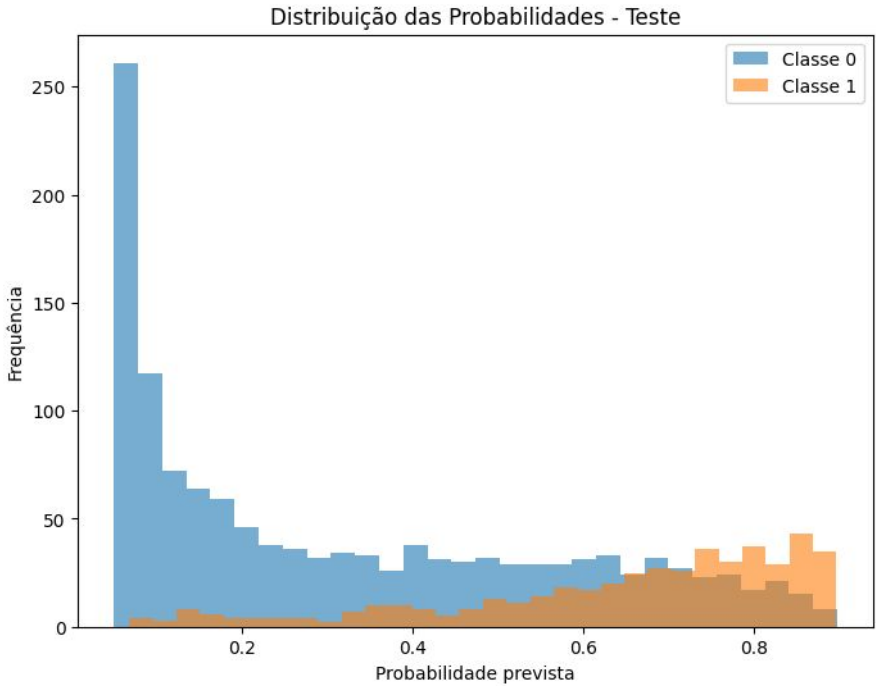
AUC (Área sob a ROC): 0.8388763100227081



STAB

Treino 2 (Resultados): Curva precision - Recall e Distribuição das probabilidades





STAB

Treino 2: Comparando resultados de teste

Parâmetros	Melhor treino (1)	Treino atual (2)
Precision	0.5081967213114754	0.5207756232686981
Recall	0.7948717948717948	0.8034188034188035
F1-Score	0.62	0.6319327731092437
Accuracy	0.7408	0.7510
MSE	0.25923820352473	0.2490051165434906
Log Loss	0.500784413565308	0.48897471975012663
KS	0.5207322495514675	0.534644134882011
AUC	0.8360907532092661	0.8388763100227081

STAB

Treino 3: Novas features, target encoding e focal loss

- Novas features adicionadas:
  - no_protection: cliente não tem OnlineSecurity e TechSupport
  - high_monthly_charge: cliente paga mensalmente mais que a média
  - charges_per_month: gasto média por mês
- TargetEncoder: técnica de codificação de variáveis categóricas que transforma cada categoria em um valor numérico baseado no target (apenas baseado no target do treino).
- focal loss: função de perda usada principalmente em classificação, criada para lidar com desbalanceamento de classes, fazendo o modelo focar mais nos exemplos difíceis e menos nos fáceis.

STAB

Treino 3: Novas features, target encoding e focal loss

- Treino usou os mesmos parâmetros encontrados pelo optuna no treino anterior

Parâmetros:

- embedding dimensions: 8
- transformers number: 4
- attention heads: 2
- attention dropout: 0.15
- feed foward dropout: 0.15
- U values: 4
- cases values: 16
- sample size dimensions: 32
- learning rate: 0.00031803232307224766
- weight decay: 0.00018207626239658746
- batch size: 32

STAB

Treino 3 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.79      0.73      0.76      2587
           1       0.75      0.81      0.78      2587

    accuracy                           0.77      5174
   macro avg       0.77      0.77      0.77      5174
weighted avg       0.77      0.77      0.77      5174

Accuracy no treino: 0.7687

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.78      0.71      0.75      1293
           1       0.74      0.81      0.77      1293

    accuracy                           0.76      2586
   macro avg       0.76      0.76      0.76      2586
weighted avg       0.76      0.76      0.76      2586

Accuracy na validação: 0.7575

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.91      0.72      0.81      1294
           1       0.51      0.79      0.62       468

    accuracy                           0.74      1762
   macro avg       0.71      0.76      0.71      1762
weighted avg       0.80      0.74      0.76      1762

Accuracy no teste: 0.7429
```

Erro Médio Quadrado:

- MSE Treino: 0.23134905295709315
- MSE Validação: 0.24245939675174014
- MSE Teste: 0.25709421112372305

Entropia Cruzada:

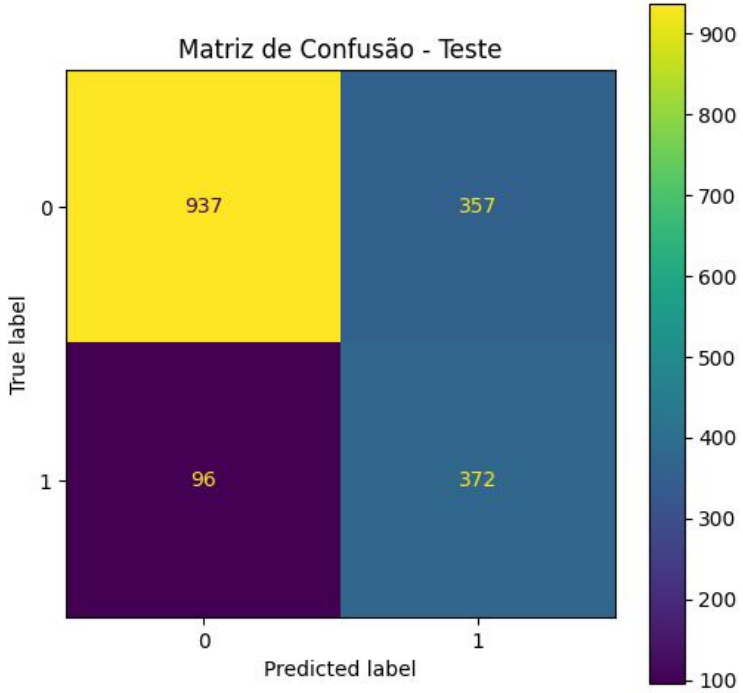
- Log Loss Treino: 0.5484596122049012
- Log Loss Validação: 0.5653481249937805
- Log Loss Teste: 0.5544835080523517

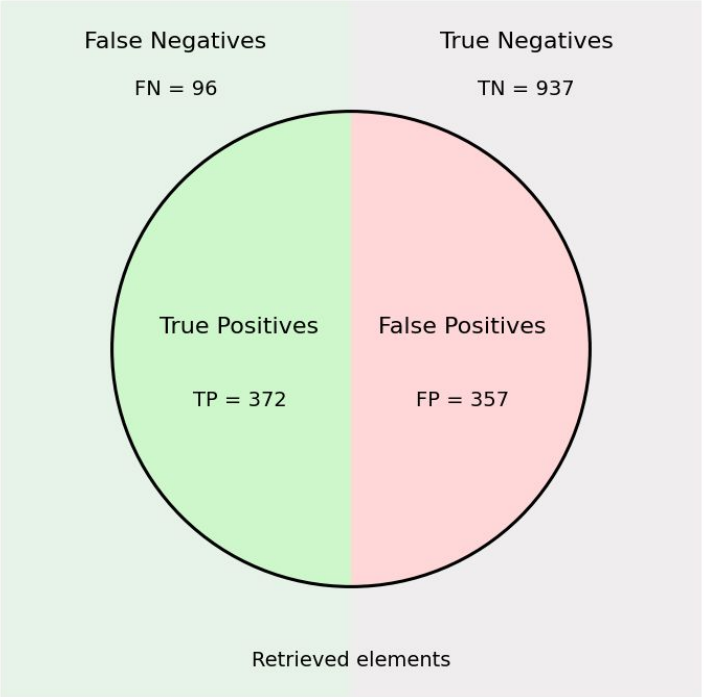
Precision, recall e F1 do teste:

- Precision: 0.5102880658436214
- Recall: 0.7948717948717948
- F1-Score: 0.6215538847117794

STAB

Treino 3 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

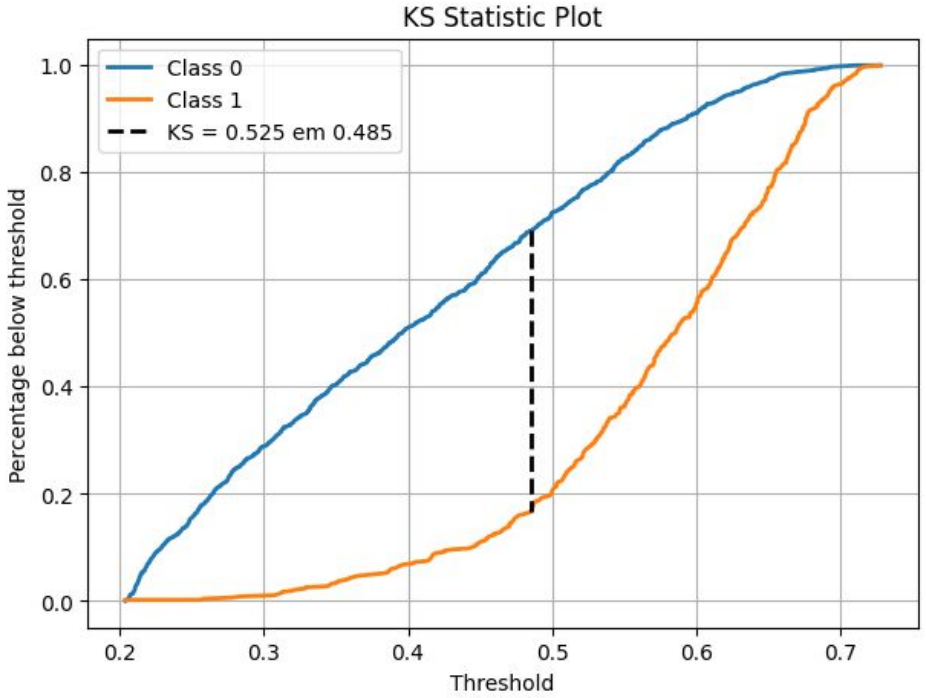




STAB

Treino 3 (Resultados): Teste Kolmogorov-Smirnov (KS)

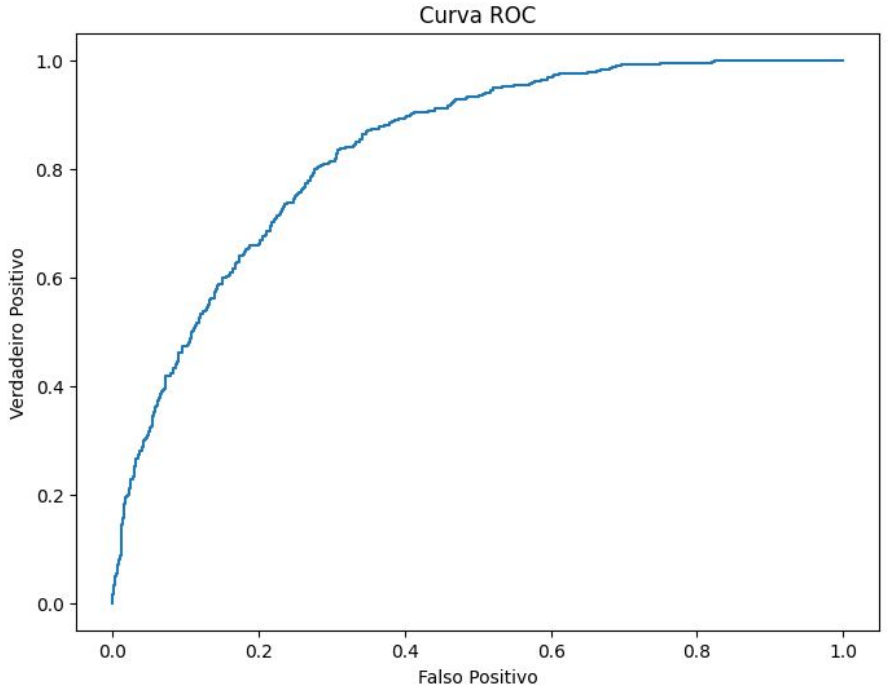
KS Statistic: 0.5250238322973542
Best threshold: 0.48499963



STAB

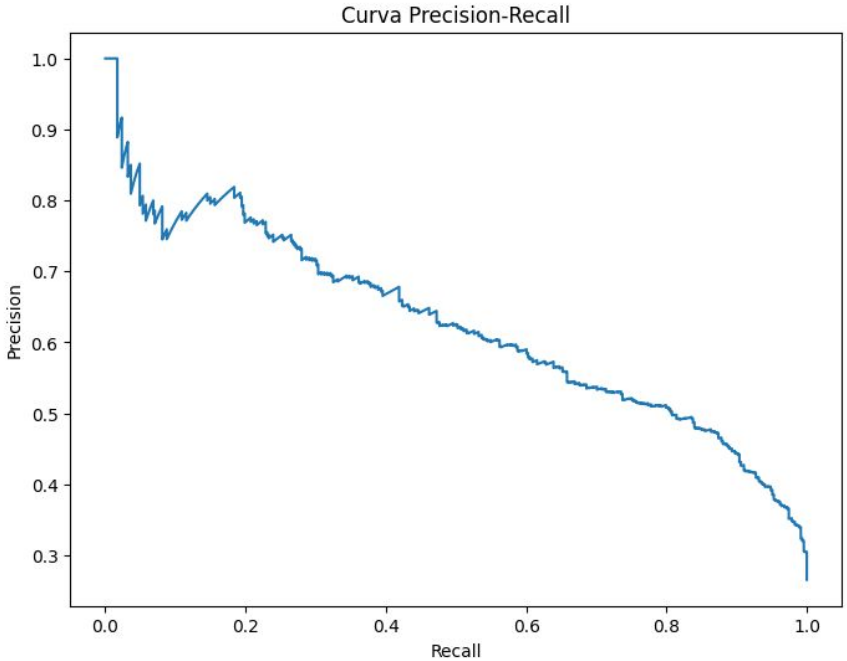
Treino 3 (Resultados): Curva ROC e AUROC

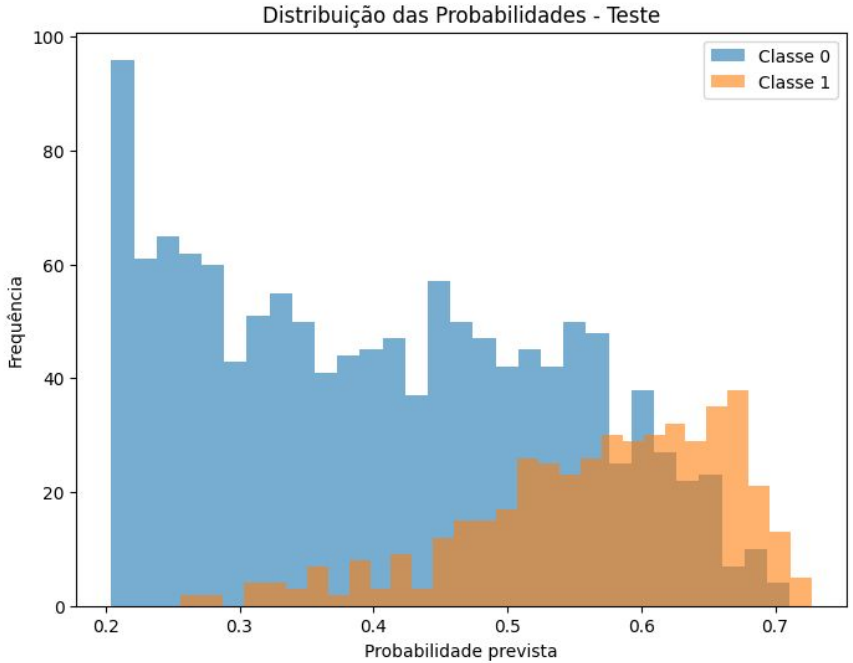
AUC (Área sob a ROC): 0.8335364403756985



STAB

Treino 3 (Resultados): Curva precision - Recall e Distribuição das probabilidades





STAB

Treino 3: Comparando resultados de teste

Parâmetros	Melhor treino (2)	Treino atual (3)
Precision	0.5207756232686981	0.5102880658436214
Recall	0.8034188034188035	0.7948717948717948
F1-Score	0.6319327731092437	0.6215538847117794
Accuracy	0.7510	0.7429
MSE	0.2490051165434906	0.25709421112372305
Log Loss	0.48897471975012663	0.5544835080523517
KS	0.534644134882011	0.5250238322973542
AUC	0.8388763100227081	0.8335364403756985

STAB

Treino 4: Modelo usando ranking loss

- Ranking loss: função de perda que não tenta acertar o rótulo, ela tenta ordenar corretamente os clientes
- Treino do optuna para obter os melhores parâmetros (15 trials), repete treino em um novo modelo com os melhores parâmetros encontrados

STAB

Treino 4: Modelo usando ranking loss

Parâmetros passados para o optuna:

- embedding dimensions = 2, 4 ou 8
- transformers number = 1 a 4
- attention heads = 2, 4, ou 8
- attention dropout = 0.10, 0.15 ou 0.20
- feed foward dropout = 0.10, 0.15 ou 0.20
- U values = 2 e 4
- cases values = 8 e 16
- sample size dimensions = 16, 32, 64 ou 128
- learning rate = 1e-4 a 1e-2
- weight decay = 1e-4 a 1e-2
- batch size = 32, 64, 128 ou 256
- epochs = 10000
- patience = 20

Melhores parâmetros encontrados:

- embedding dimensions: 4
- transformers number: 3
- attention heads: 2
- attention dropout: 0.20
- feed foward dropout: 0.15
- U values: 2
- cases values: 8
- sample size dimensions: 64
- learning rate: 0.00840379330955643
- weight decay: 0.0007537850623514248
- batch size: 64

STAB

Treino 4 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.81      0.72      0.76      2581
           1       0.75      0.83      0.79      2587

    accuracy                           0.78      5168
   macro avg       0.78      0.78      0.78      5168
weighted avg       0.78      0.78      0.78      5168

Accuracy no treino: 0.7769

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.78      0.70      0.74      1291
           1       0.73      0.80      0.76      1293

    accuracy                           0.75      2584
   macro avg       0.75      0.75      0.75      2584
weighted avg       0.75      0.75      0.75      2584

Accuracy na validação: 0.7496

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.92      0.72      0.80      1291
           1       0.51      0.82      0.63       468

    accuracy                           0.74      1759
   macro avg       0.71      0.77      0.72      1759
weighted avg       0.81      0.74      0.76      1759

Accuracy no teste: 0.7442
```

Erro Médio Quadrado:

- MSE Treino: 0.22310371517027863
- MSE Validação: 0.2503869969040248
- MSE Teste: 0.2558271745309835

Entropia Cruzada:

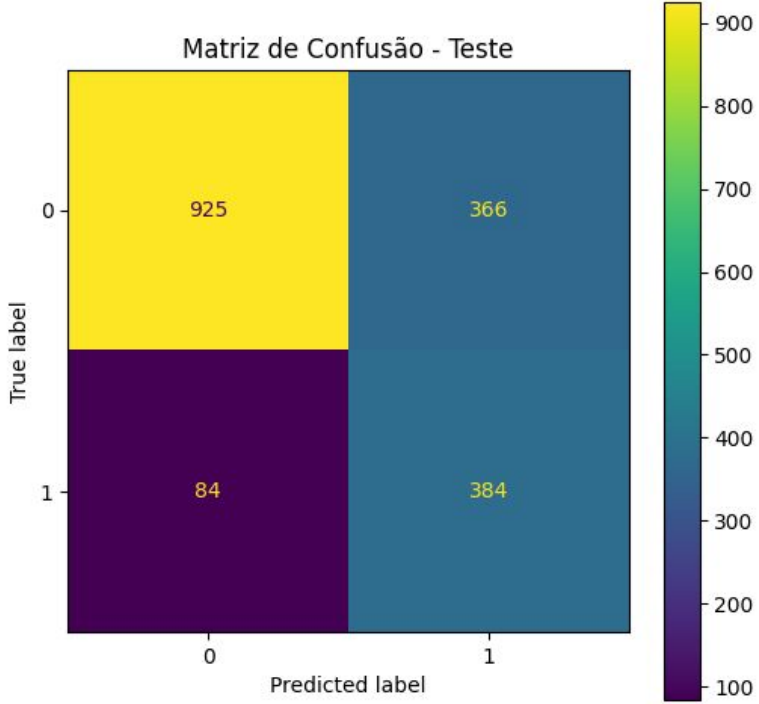
- Log Loss Treino: 0.46353364510687467
- Log Loss Validação: 0.5080782791834084
- Log Loss Teste: 0.5047930714677319

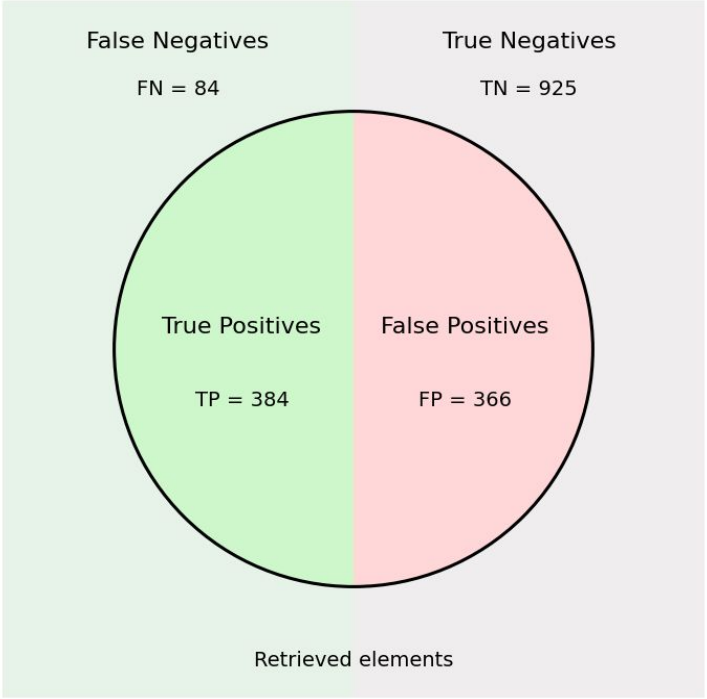
Precision, recall e F1 do teste:

- Precision: 0.512
- Recall: 0.8205128205128205
- F1-Score: 0.6305418719211823

STAB

Treino 4 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

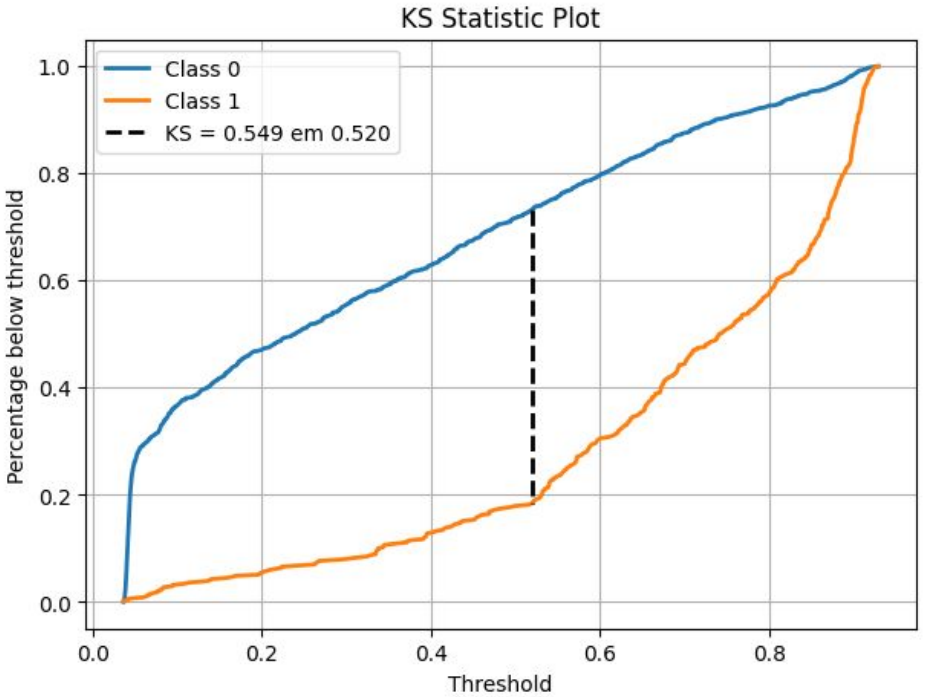




STAB

Treino 4 (Resultados): Teste Kolmogorov-Smirnov (KS)

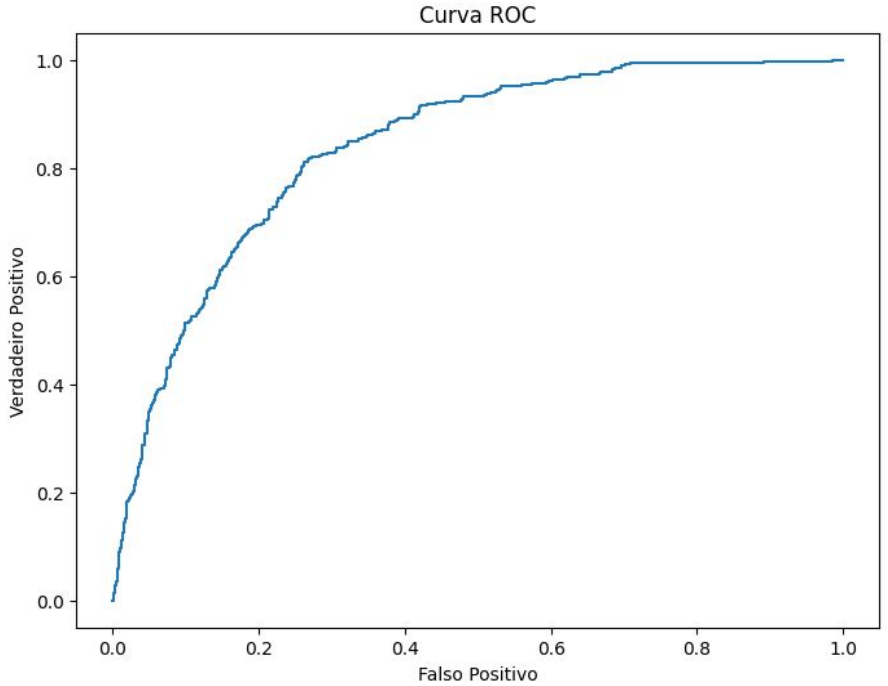
KS Statistic: 0.5486353789303027
Best threshold: 0.5197244



STAB

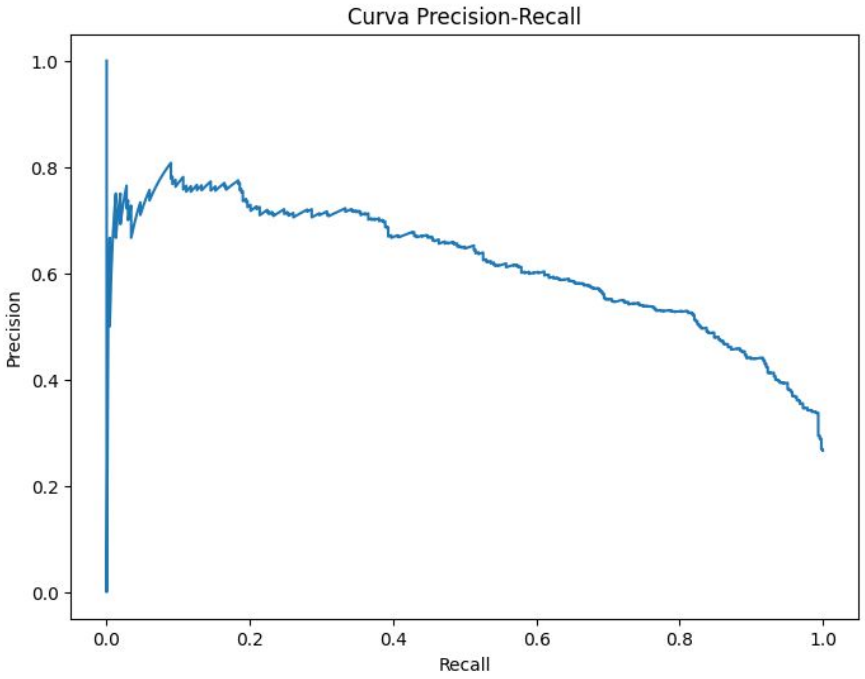
Treino 4 (Resultados): Curva ROC e AUROC

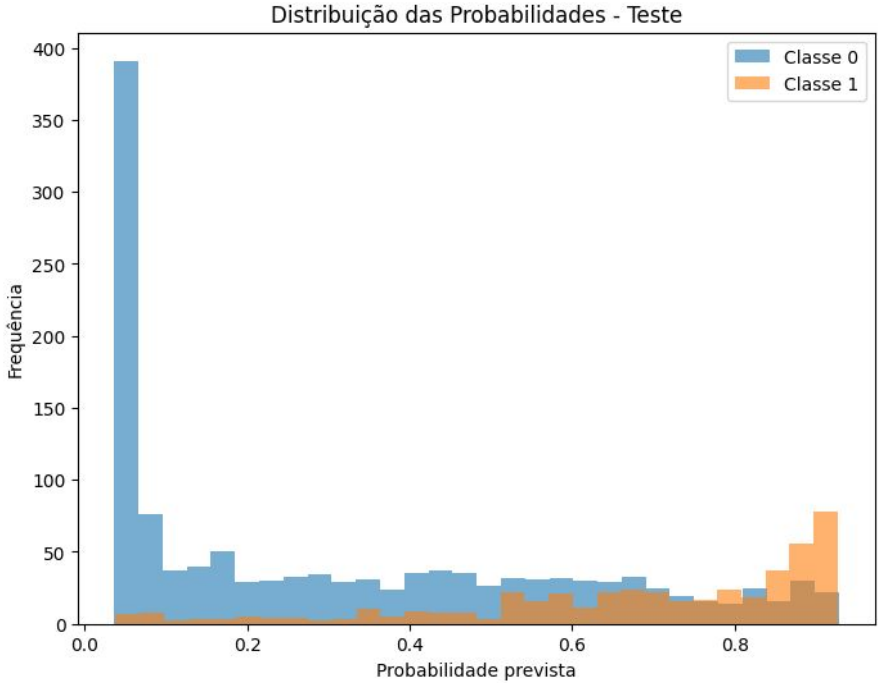
AUC (Área sob a ROC): 0.8375257370222514



STAB

Treino 5 (Resultados): Curva precision - Recall e Distribuição das probabilidades





STAB

Treino 4: Comparando resultados de teste

Parâmetros	Melhor treino (2)	Treino atual (4)
Precision	0.5207756232686981	0.512
Recall	0.8034188034188035	0.8205128205128205
F1-Score	0.6319327731092437	0.6305418719211823
Accuracy	0.7510	0.7442
MSE	0.2490051165434906	0.2558271745309835
Log Loss	0.48897471975012663	0.5047930714677319
KS	0.534644134882011	0.5486353789303027
AUC	0.8388763100227081	0.8375257370222514

TabPFN

Treino 1:

Parâmetros passados para o optuna:

subsample_size = [512, 1024, 1536, 2048] (Tamanho do Contexto)
n_samples = 1 a 32 (Amostras de Inferência/Ensemble)
Métrica: LogLoss (Minimização da Incerteza)
N_Trials: 20

Melhores parâmetros encontrados:

subsample_size: 1024
n_samples: 9
Melhor Loss (Validação): 0.5025
KS Statistic (Teste): 0.5323
AUROC (Teste): 0.8417
Best Threshold (KS): 0.4526

TabPFN

=== TABELA GERAL DE RESULTADOS - TabPFN (Incluindo KS) ===

Conjunto	MSE	KS Statistic	Precision	Recall	F1-Score	Support
Treinamento	0.1270	0.6571	0.8293	0.8264	0.8261	5174
Validação	0.1424	0.6102	0.8029	0.8005	0.8001	2586
Teste	0.1627	0.5347	0.7958	0.7491	0.7613	1762

TabPFN

```
==== MÉTRICAS NO TESTE ====
Precision: 0.4823
Recall:    0.8141
F1-Score:  0.6057

==== RELATÓRIO COMPLETO (TESTE) ====
              precision    recall  f1-score   support

           0       0.91      0.68      0.78      1294
           1       0.48      0.81      0.61       468

    accuracy                           0.72      1762
   macro avg       0.70      0.75      0.69      1762
weighted avg       0.80      0.72      0.73      1762
```

TabPFN

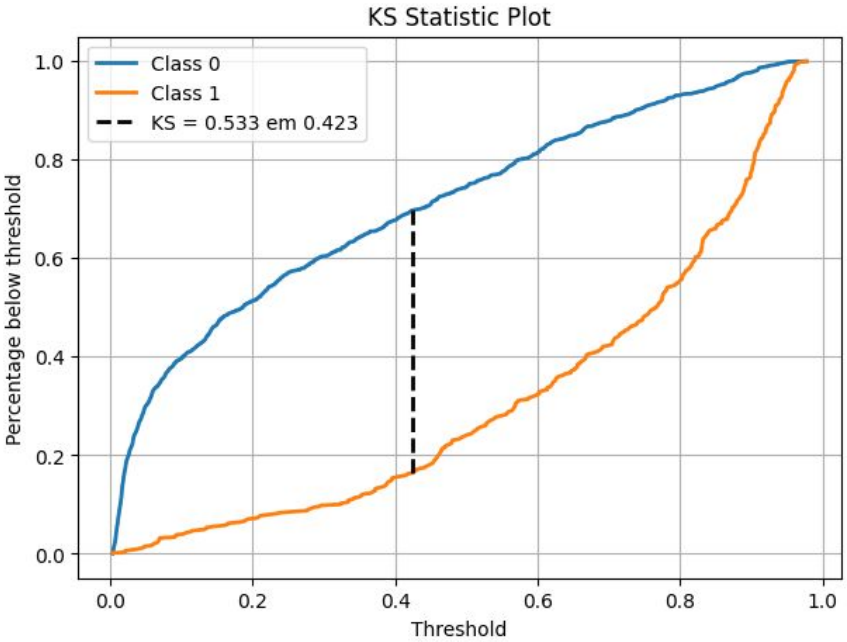
```python
# === 4. MSE (Erro Médio Quadrado) ===
print("MSE Treino:", mean_squared_error(y_train, y_train_pred))
print("MSE Validação:", mean_squared_error(y_val, y_val_pred))
print("MSE Teste:", mean_squared_error(y_test, y_test_pred))
```

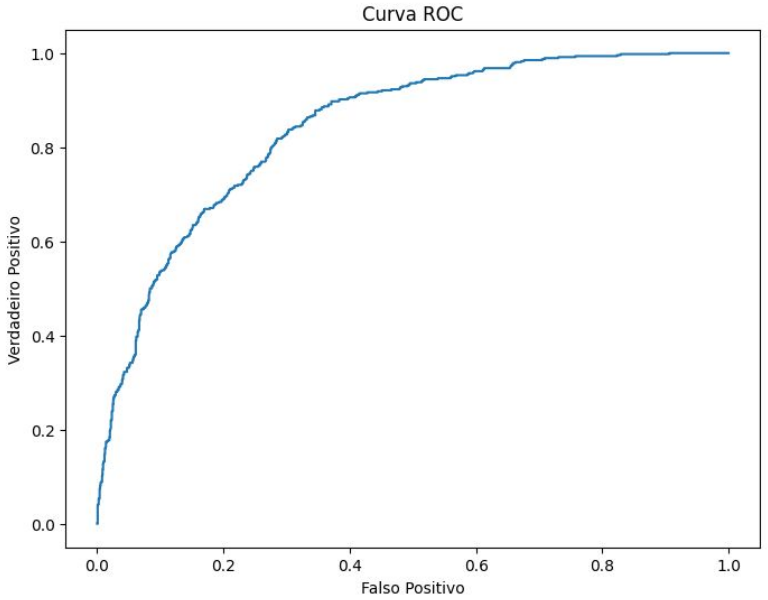
```
MSE Treino: 0.17356010823347506
MSE Validação: 0.19953596287703015
MSE Teste: 0.2508513053348468
```

```python
# === 5. Entropia Cruzada (Log Loss) ===
print("Log Loss Treino:", log_loss(y_train, final_model.predict_proba(x_train)))
print("Log Loss Validação:", log_loss(y_val, final_model.predict_proba(x_val)))
print("Log Loss Teste:", log_loss(y_test, final_model.predict_proba(x_test)))
```

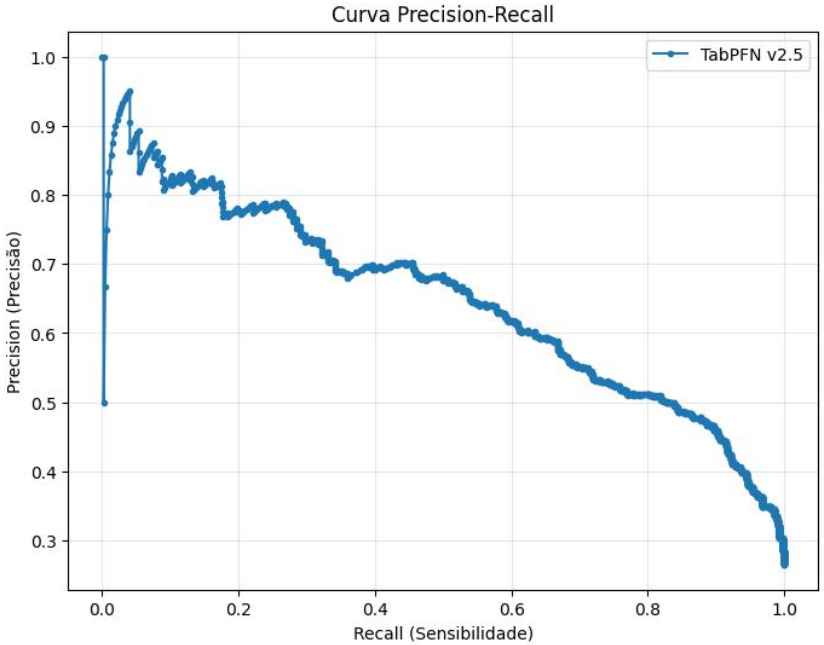
```
Log Loss Treino: 0.40165544655354674
Log Loss Validação: 0.43944541666203135
Log Loss Teste: 0.48696742967120854
```

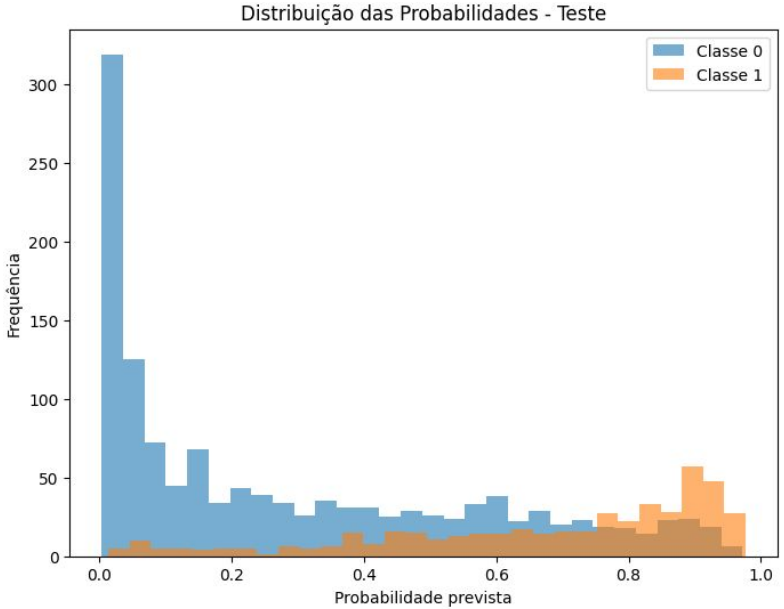
TabPFN


KS Statistic Plot
Class 0
Class 1
KS = 0.533 em 0.423
Percentage below threshold
Threshold
0.0
0.2
0.4
0.6
0.8
1.0

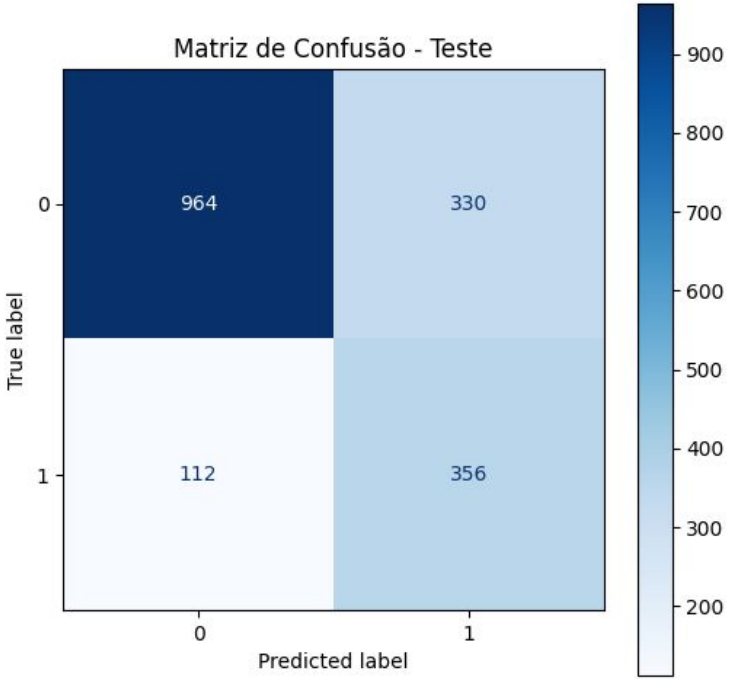

Curva ROC
Verdadeiro Positivo
Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0

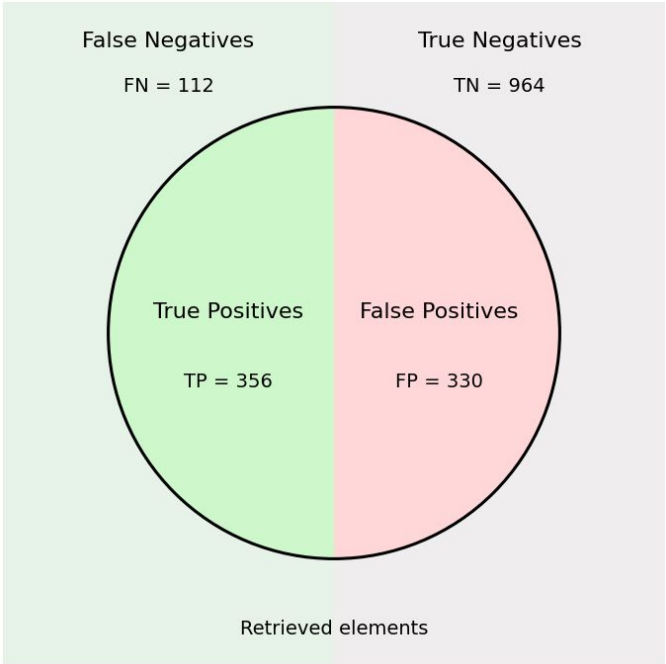
TabPFN


Curva Precision-Recall
TabPFN v2.5
Precision (Precisão)
Recall (Sensibilidade)
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.0
0.2
0.4
0.6
0.8
1.0


Distribuição das Probabilidades - Teste
Classe 0
Classe 1
Frequência
Probabilidade prevista
300
250
200
150
100
50
0
0.0
0.2
0.4
0.6
0.8
1.0

TabPFN


Matriz de Confusão - Teste
964
330
112
356
0
1
True label
0
1
Predicted label
900
800
700
600
500
400
300
200


False Negatives
FN = 112
True Negatives
TN = 964
True Positives
TP = 356
False Positives
FP = 330
Retrieved elements

Mitra

Treino 1:

Parâmetros passados para o optuna:

learning_rate = 0.0001 a 0.1 (escala log)
num_leaves = 20 a 100 (complexidade das árvores)
Métrica Alvo: Minimizar LogLoss na Validação
Framework: AutoGluon Tabular
N_Trials: 15 tentativas

Melhores parâmetros encontrados:

learning_rate: 0.04572
num_leaves: 20
Melhor Loss (Validação): 0.5024

Mitra

```
***  ==== CLASSIFICATION REPORT - TREINO ====
                precision    recall  f1-score   support

             0       0.97      0.89      0.93      2587
             1       0.90      0.98      0.93      2587

      accuracy                           0.93      5174
     macro avg       0.93      0.93      0.93      5174
  weighted avg       0.93      0.93      0.93      5174

  ==== CLASSIFICATION REPORT - VALIDAÇÃO ====
                precision    recall  f1-score   support

             0       0.72      0.79      0.76      1293
             1       0.77      0.70      0.73      1293

      accuracy                           0.75      2586
     macro avg       0.75      0.75      0.74      2586
  weighted avg       0.75      0.75      0.74      2586

  ==== CLASSIFICATION REPORT - TESTE ====
                precision    recall  f1-score   support

             0       0.87      0.79      0.83      1294
             1       0.54      0.68      0.60       468

      accuracy                           0.76      1762
     macro avg       0.70      0.73      0.71      1762
  weighted avg       0.78      0.76      0.77      1762
```

Mitra

```python
# === 3. Precision, Recall e F1 ===
print("Precision:", precision_score(y_test, y_test_pred))
print("Recall:", recall_score(y_test, y_test_pred))
print("F1-Score:", f1_score(y_test, y_test_pred))
```

```
Precision: 0.535593220338983
Recall: 0.6752136752136753
F1-Score: 0.5973534971644613
```

```python
# === 4. MSE (Erro Médio Quadrado) ===
print("MSE Treino:", mean_squared_error(y_train, y_train_pred))
print("MSE Validação:", mean_squared_error(y_val, y_val_pred))
print("MSE Teste:", mean_squared_error(y_test, y_test_pred))
```

```
MSE Treino: 0.06880556629300348
MSE Validação: 0.25444702242846096
MSE Teste: 0.24177071509648126
```

```python
# === 5. Log Loss ===
print("Log Loss Treino:", log_loss(y_train, y_train_proba))
print("Log Loss Validação:", log_loss(y_val, y_val_proba))
print("Log Loss Teste:", log_loss(y_test, y_test_proba))
```

```
Log Loss Treino: 0.2279605199187692
Log Loss Validação: 0.5768680048770438
Log Loss Teste: 0.4925023127361656
```

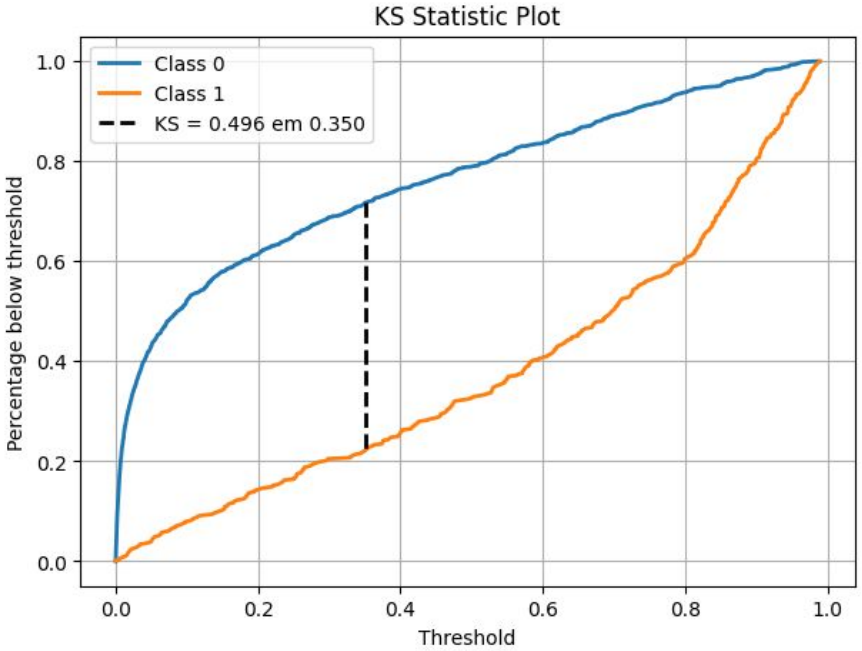
Mitra

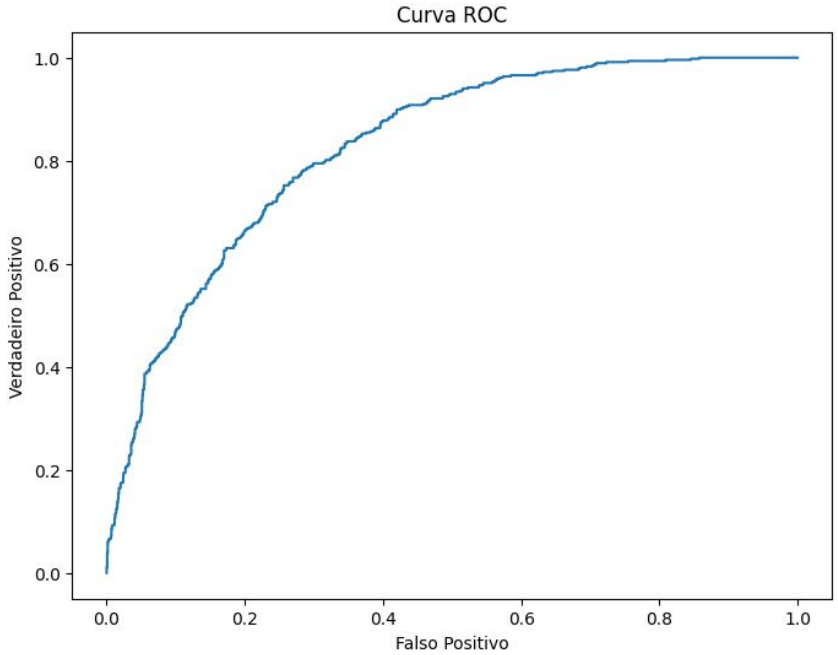
```
KS Statistic: 0.4957465536163729
Best threshold: 0.35042256116867065
```

```python
# === 9. AUROC ===
auc = roc_auc_score(y_test, y_test_proba)
print("AUC (Área sob a ROC):", auc)
```

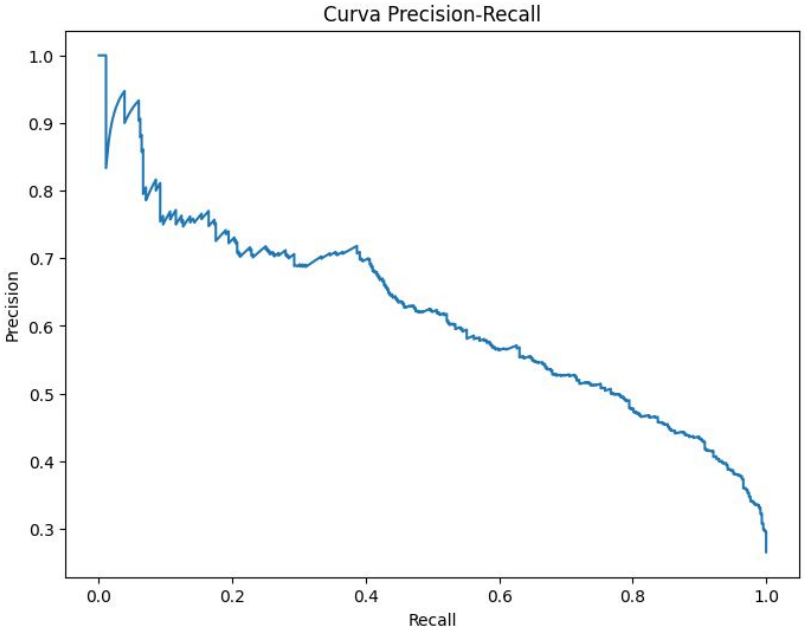
```
AUC (Área sob a ROC): 0.8254451842164361
```

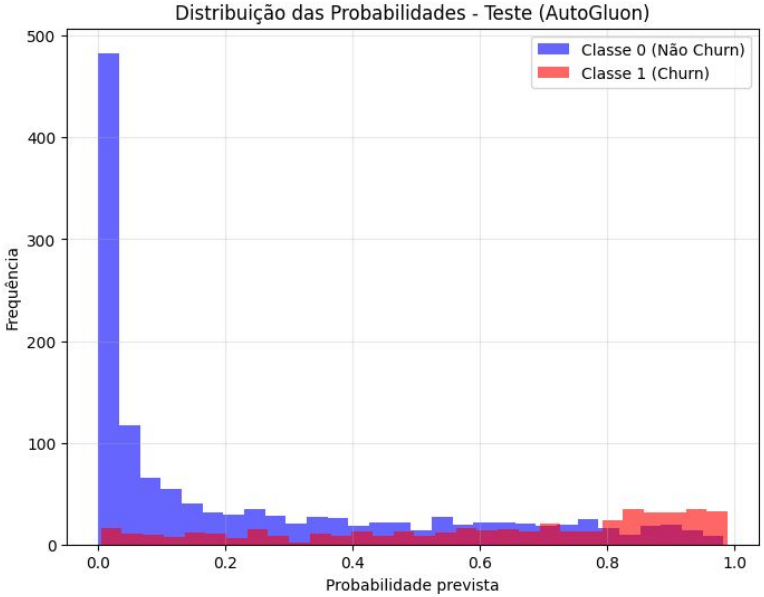
Mitra


KS Statistic Plot
Class 0
Class 1
KS = 0.496 em 0.350
Percentage below threshold
Threshold
0.0
0.2
0.4
0.6
0.8
1.0

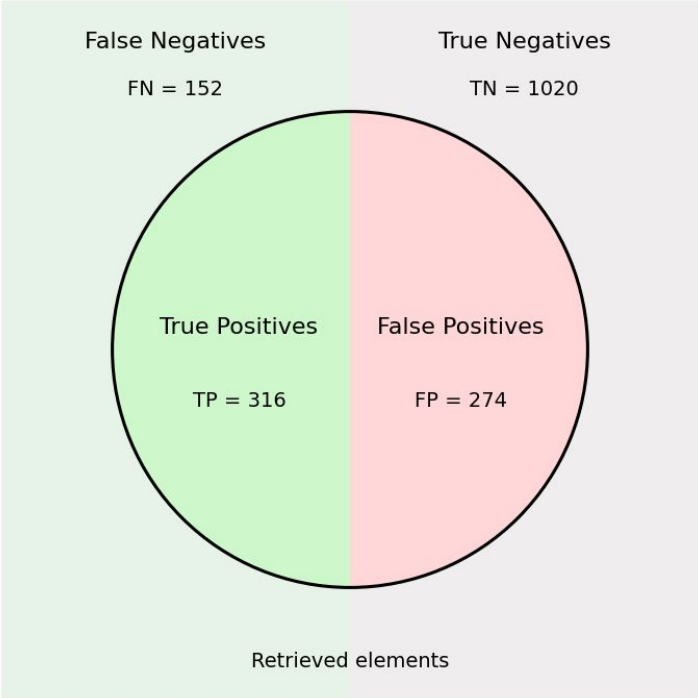

Curva ROC
Verdadeiro Positivo
Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0

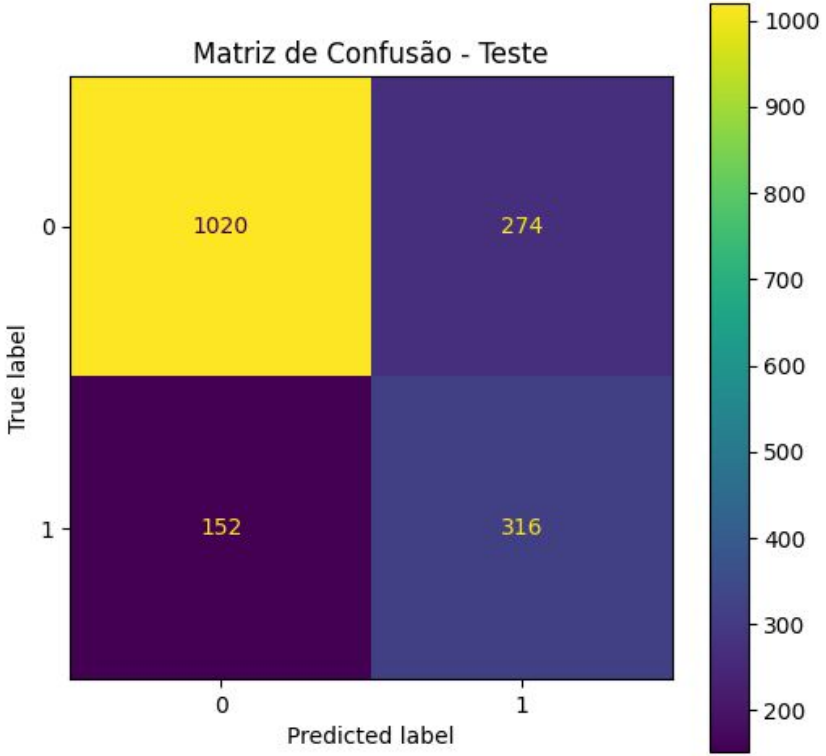
Mitra


Curva Precision-Recall
Precision
Recall
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.0
0.2
0.4
0.6
0.8
1.0


Distribuição das Probabilidades - Teste (AutoGluon)
Classe 0 (Não Churn)
Classe 1 (Churn)
Frequência
Probabilidade prevista
500
400
300
200
100
0
0.0
0.2
0.4
0.6
0.8
1.0

Mitra


False Negatives
FN = 152
True Negatives
TN = 1020
True Positives
TP = 316
False Positives
FP = 274
Retrieved elements


Matriz de Confusão - Teste
1020
274
152
316
0
1
True label
Predicted label
1000
900
800
700
600
500
400
300
200

Mitra

Treino 2:

Parâmetros passados para o optuna:

learning_rate = 0.0001 a 0.1
num_leaves = 16 a 150 (Capacidade das árvores)
min_data_in_leaf = 40 a 200 (Controle de ruído)
feature_fraction = 0.6 a 1.0 (Seleção de variáveis)
lambda_l2 = Regularização para evitar overfitting
Métrica Alvo: Minimizar LogLoss na Validação

Melhores parâmetros encontrados:

learning_rate: 0.0577
num_leaves: 61
min_data_in_leaf: 176
feature_fraction: 0.8059
lambda_l2: 0.4850
Melhor LogLoss (Validação): 0.4965

Mitra

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.83      0.79      0.81      2587
           1       0.80      0.84      0.82      2587

    accuracy                           0.81      5174
   macro avg       0.81      0.81      0.81      5174
weighted avg       0.81      0.81      0.81      5174

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.79      0.74      0.77      1293
           1       0.76      0.81      0.78      1293

    accuracy                           0.77      2586
   macro avg       0.78      0.77      0.77      2586
weighted avg       0.78      0.77      0.77      2586

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.90      0.75      0.82      1294
           1       0.53      0.76      0.62       468

    accuracy                           0.75      1762
   macro avg       0.71      0.76      0.72      1762
weighted avg       0.80      0.75      0.77      1762
```

Mitra

```
== Métricas com threshold padrão do AutoGluon (pred) ==
Precision: 0.526706231454006
Recall: 0.7585470085470085
F1-Score: 0.6217162872154116
```

```
KS Statistic: 0.5407971324430701
Best threshold: 0.4479372203350067
```

Mitra

```
[28]
✓ 0s
# === 4. MSE (Erro Médio Quadrado) ===
print("MSE Treino:", mean_squared_error(y_train, y_train_pred))
print("MSE Validação:", mean_squared_error(y_val, y_val_pred))
print("MSE Teste:", mean_squared_error(y_test, y_test_pred))

MSE Treino: 0.18689601855431
MSE Validação: 0.2254447022428461
MSE Teste: 0.24517593643586832
```

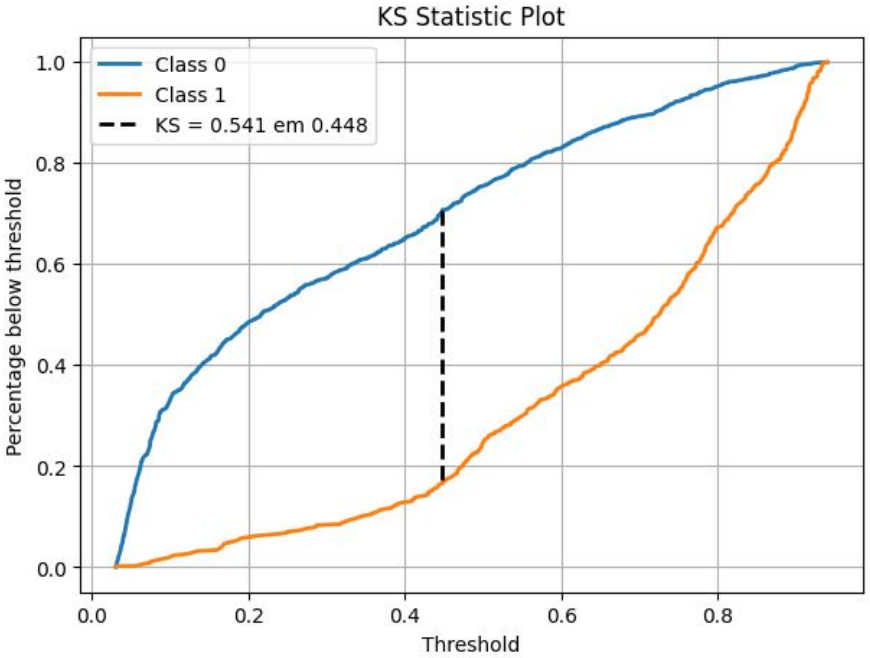
```
[29]
✓ 0s
# === 5. Log Loss ===
print("Log Loss Treino:", log_loss(y_train, y_train_proba))
print("Log Loss Validação:", log_loss(y_val, y_val_proba))
print("Log Loss Teste:", log_loss(y_test, y_test_proba))

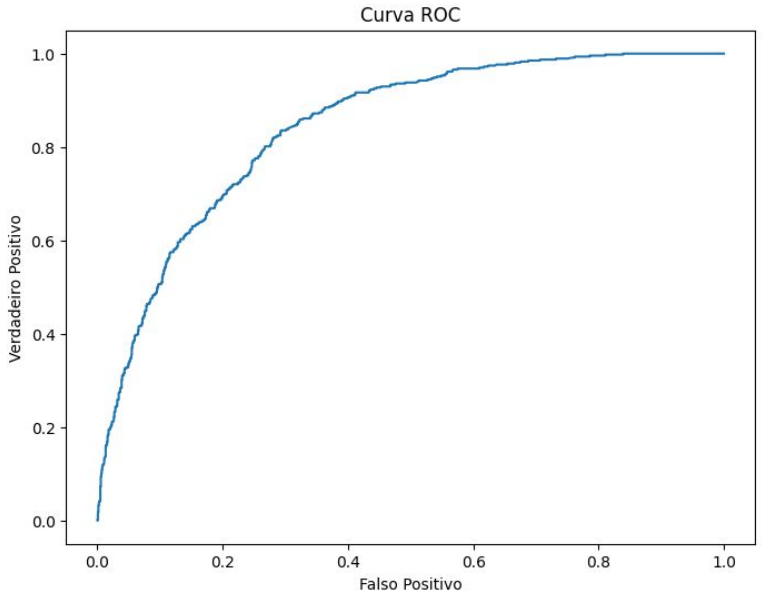
Log Loss Treino: 0.418073386517184
Log Loss Validação: 0.49652558100073385
Log Loss Teste: 0.48070088563712005
```

```
# === 9. AUROC ===
auc = roc_auc_score(y_test, y_test_proba)
print("AUC (Área sob a ROC):", auc)

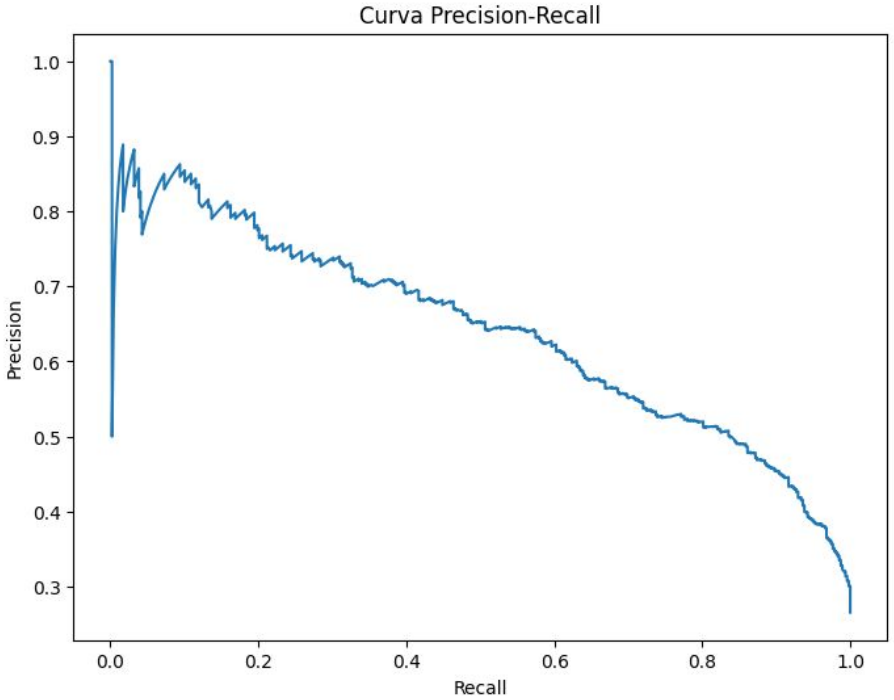
AUC (Área sob a ROC): 0.8424434272579558
```

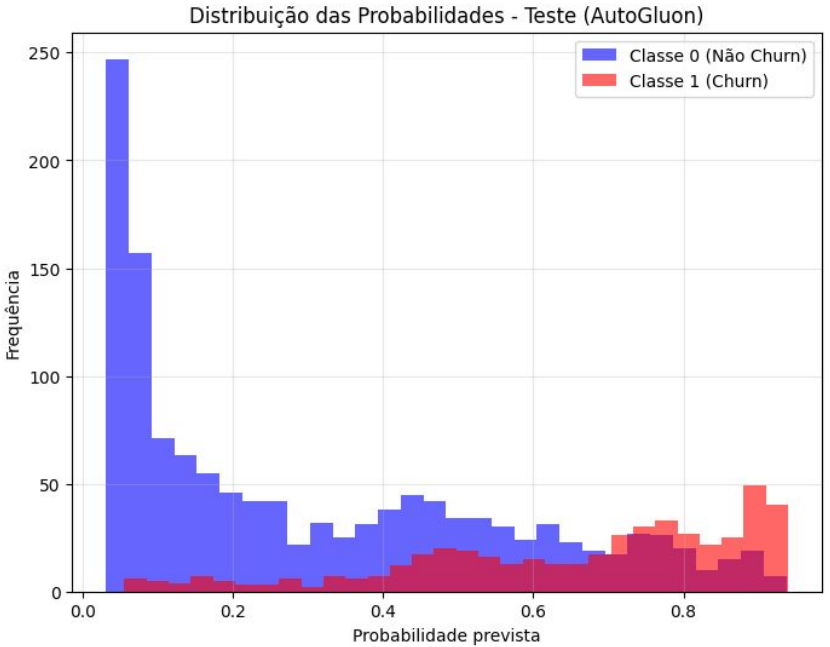
Mitra


KS Statistic Plot
Class 0
Class 1
KS = 0.541 em 0.448
Percentage below threshold
Threshold
0.0
0.2
0.4
0.6
0.8
1.0

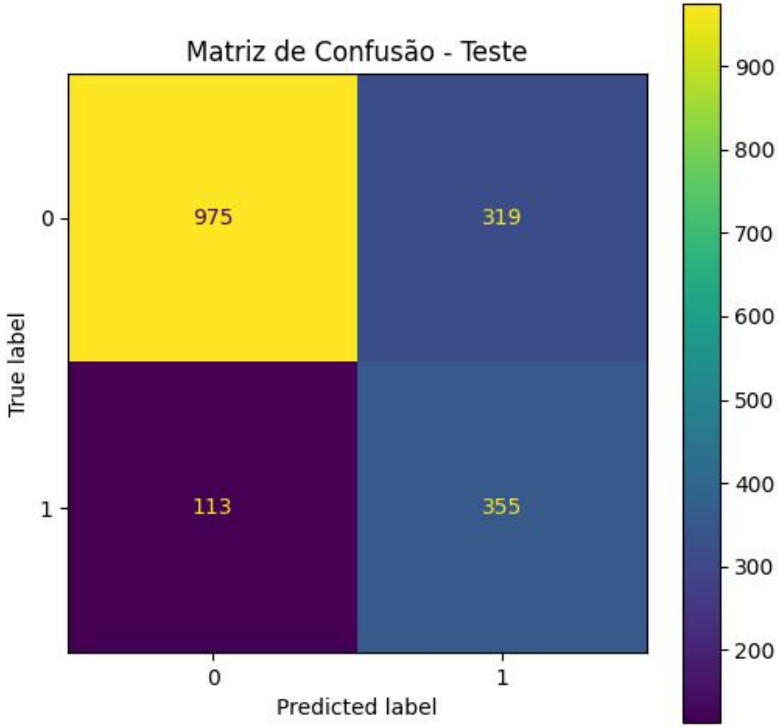

Curva ROC
Verdadeiro Positivo
Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0

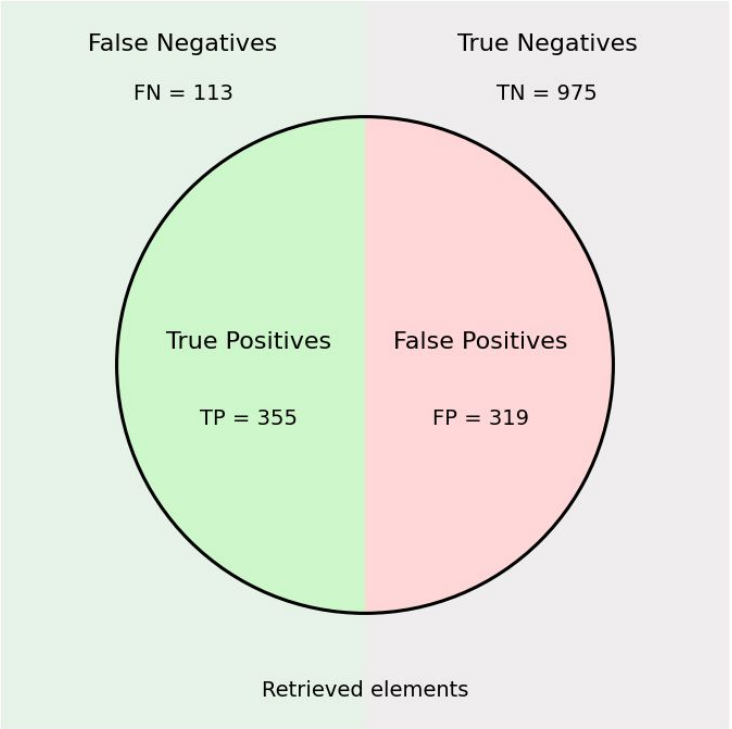
Mitra


Curva Precision-Recall
Precision
Recall
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.0
0.2
0.4
0.6
0.8
1.0


Distribuição das Probabilidades - Teste (AutoGluon)
Classe 0 (Não Churn)
Classe 1 (Churn)
Frequência
Probabilidade prevista
250
200
150
100
50
0
0.0
0.2
0.4
0.6
0.8

Mitra


Matriz de Confusão - Teste
True label
Predicted label
0
1
975
319
113
355
900
800
700
600
500
400
300
200


False Negatives
FN = 113
True Negatives
TN = 975
True Positives
TP = 355
False Positives
FP = 319
Retrieved elements

KAN

Treino 1: Treino teste do modelo KAN

- Treino de teste do modelo
- Esse treino usou um tratamento de dados antigo que era pior.
- Treino realizado com optuna para buscar melhores parâmetros e depois treino é refeito em um novo modelo com os melhores parâmetros encontrados
- Foram feitos 10 trials do optuna
- Todos os treino deste modelo são focados em melhorar o KS

KAN

Treino 1: Treino teste do modelo KAN

Parâmetros passados para o optuna:

- hidden layers = 1 a 8
- layer sizes = 16 a 256
- grid = 2 a 6
- k values = 1, 2 ou 3
- learning rate = 1e-5 a 1e-2
- batch size = 32, 64, 128, 256 ou 512
- função base = "relu", "sigmoid", "tanh", "silu" ou "identity"
- otimizadores = "LBFGS", "SGD", "Adam" ou "RMSProp"
- L2 regularization = 1e-4 a 1e-2
- steps = 10
- epochs = 10000
- patience = 10

Melhores parâmetros encontrados:

- hidden layers = 1
- unidades na layer 0 = 95
- grid = 2
- k values = 2
- learning rate = 0.004694708098653867
- batch size = 512
- função base ='relu'
- otimizadores = 'Adam'
- L2 regularization = 0.00010110422902208374

KAN

Treino 1 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

         0.0       0.85      0.74      0.79      2581
         1.0       0.77      0.87      0.81      2587

    accuracy                           0.80      5168
   macro avg       0.81      0.80      0.80      5168
weighted avg       0.81      0.80      0.80      5168

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

         0.0       0.78      0.69      0.73      1291
         1.0       0.72      0.81      0.76      1293

    accuracy                           0.75      2584
   macro avg       0.75      0.75      0.75      2584
weighted avg       0.75      0.75      0.75      2584

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

         0.0       0.90      0.72      0.80      1291
         1.0       0.51      0.79      0.62       468
...
    accuracy                           0.74      1759
   macro avg       0.71      0.76      0.71      1759
weighted avg       0.80      0.74      0.75      1759
```

Erro Médio Quadrado:

- MSE Treino: 0.19910991191864014
- MSE Validação: 0.25309598445892334
- MSE Teste: 0.2603752017021179

Entropia Cruzada:

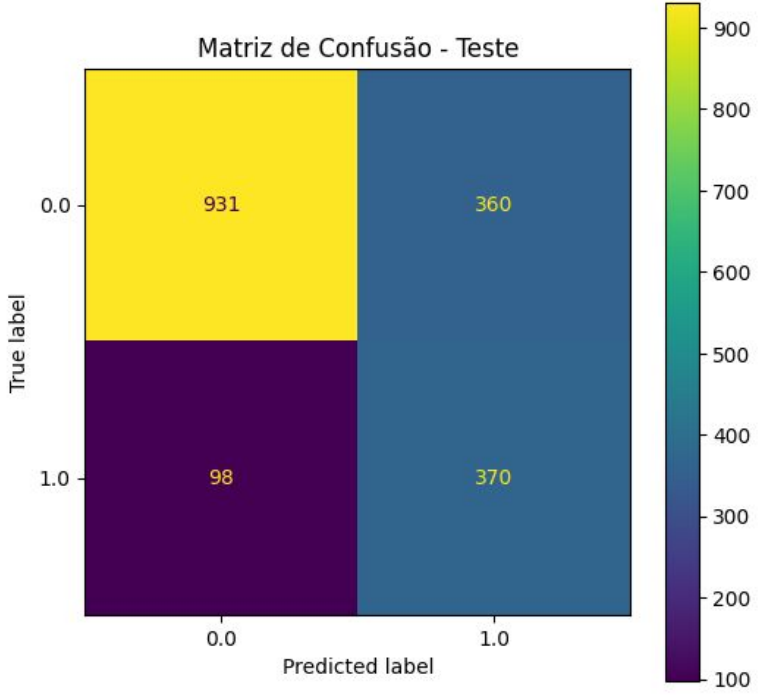
- Log Loss Treino: 0.43023241469395657
- Log Loss Validação: 0.508340462034727
- Log Loss Teste: 0.5019960529013935

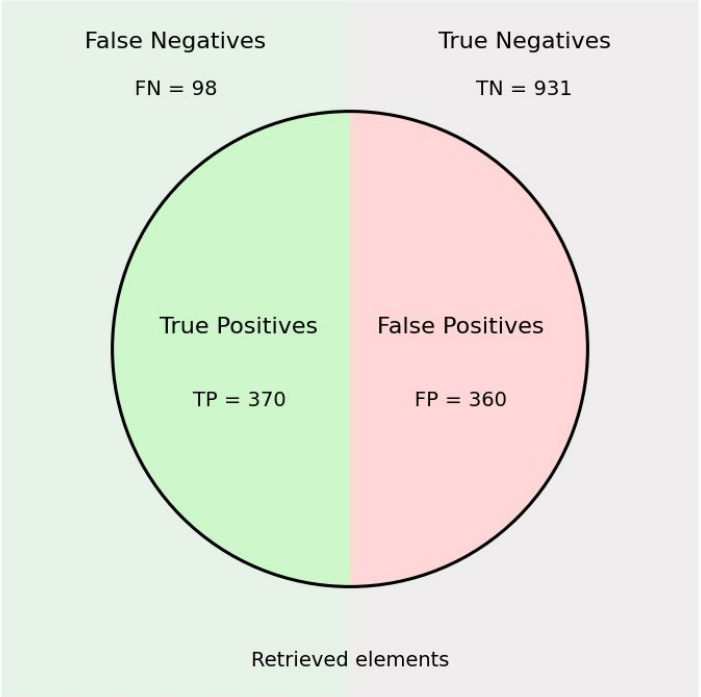
Precision, recall e F1 do teste:

- Precision: 0.5068493150684932
- Recall: 0.7905982905982906
- F1-Score: 0.6176961602671118

KAN

Treino 1 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

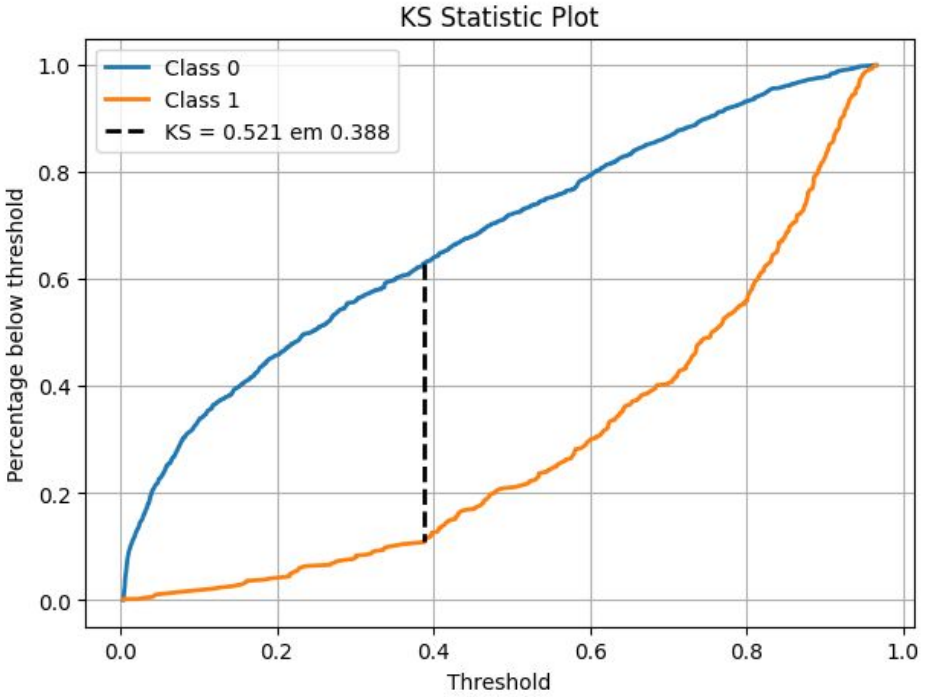




KAN

Treino 1 (Resultados): Teste Kolmogorov-Smirnov (KS)

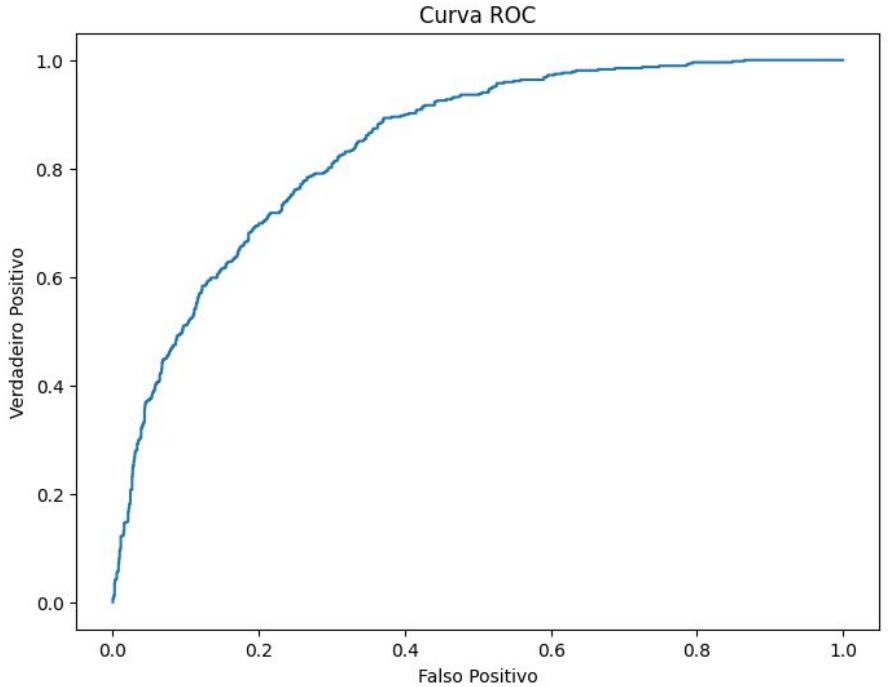
KS Statistic: 0.5206531332719204
Best threshold: 0.38844183



KAN

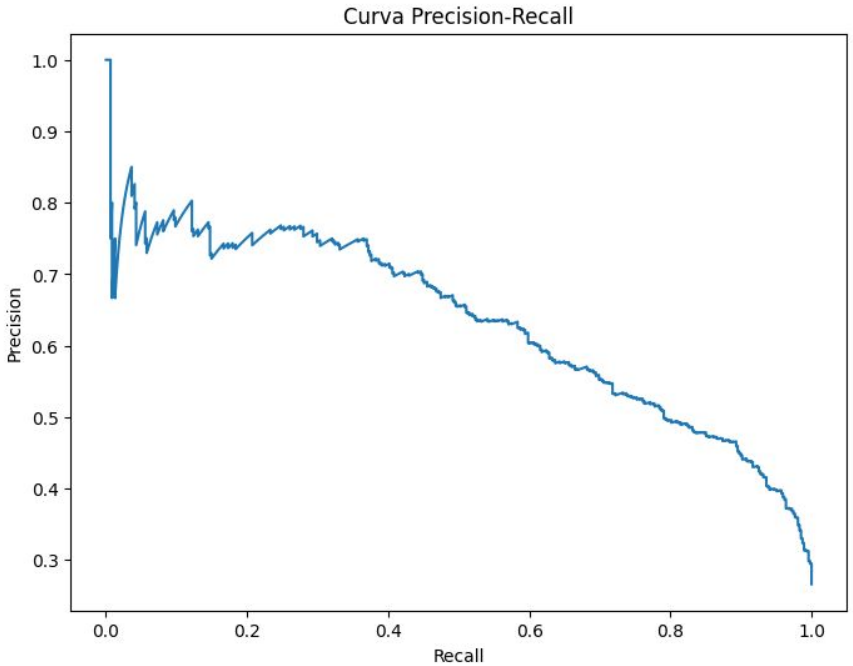
Treino 1 (Resultados): Curva ROC e AUROC

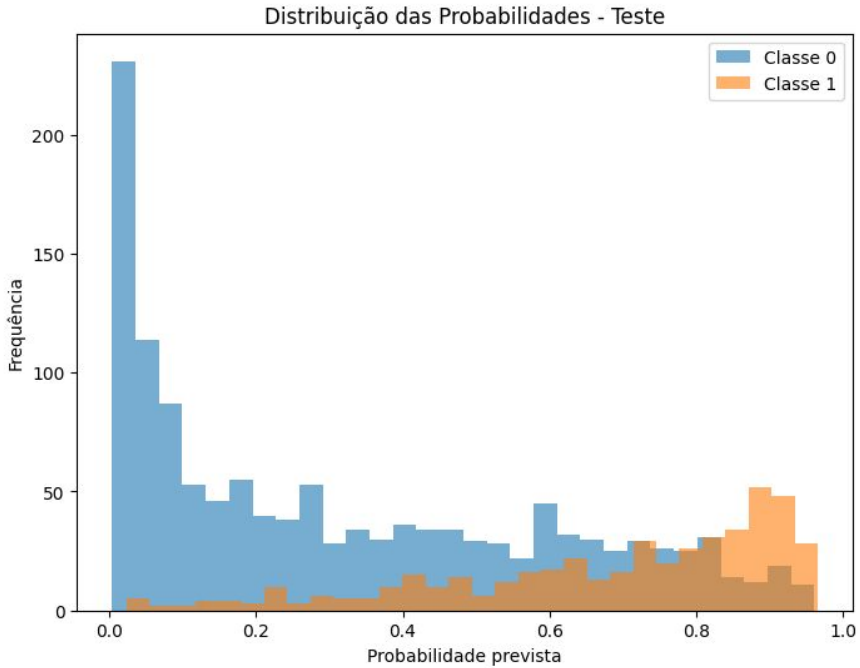
AUC (Área sob a ROC): 0.8401085423742278



KAN

Treino 1 (Resultados): Curva precision - Recall e Distribuição das probabilidades





KAN

Treino 2: Treino com tratamento de dados corrigido

- Treino com o tratamento de dados funcionando como descrito anteriormente
- Treino com optuna para buscar os melhores parâmetros (10 trials), repete treino em um novo modelo com os melhores parâmetros encontrados

KAN

Treino 2: Treino com tratamento de dados corrigido

Parâmetros passados para o optuna:

- hidden layers = 1 a 8
- layer sizes = 16 a 256
- grid = 2 a 6
- k values = 1, 2 ou 3
- learning rate = 1e-5 a 1e-2
- batch size = 32, 64, 128, 256 ou 512
- função base = "relu", "sigmoid", "tanh", "silu" ou "identity"
- otimizadores = "LBFGS", "SGD", "Adam" ou "RMSProp"
- L2 regularization = 1e-4 a 1e-2
- steps = 10
- epochs = 10000
- patience = 10

Melhores parâmetros encontrados:

- hidden layers = 6
- unidades na layer 0 = 83
- unidades na layer 1 = 81
- unidades na layer 2 = 167
- unidades na layer 3 = 104
- unidades na layer 4 = 174
- unidades na layer 5 = 93
- grid = 3
- k values = 2
- learning rate = 0.00041093482280210917
- batch size = 128
- função base = 'identity'
- otimizadores = 'Adam'
- L2 regularization = 0.0003492460466343303

KAN

Treino 2 (Resultados): Relatório de classificação

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

         0.0       0.82      0.75      0.78      2581
         1.0       0.77      0.83      0.80      2587

    accuracy                           0.79      5168
   macro avg       0.79      0.79      0.79      5168
weighted avg       0.79      0.79      0.79      5168

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

         0.0       0.78      0.73      0.76      1291
         1.0       0.75      0.79      0.77      1293

    accuracy                           0.76      2584
   macro avg       0.76      0.76      0.76      2584
weighted avg       0.76      0.76      0.76      2584

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

         0.0       0.91      0.74      0.81      1291
         1.0       0.52      0.80      0.63       468

    accuracy                           0.75      1759
   macro avg       0.72      0.77      0.72      1759
weighted avg       0.81      0.75      0.77      1759
```

Erro Médio Quadrado:

- MSE Treino: 0.20955882966518402
- MSE Validação: 0.2368421107530594
- MSE Teste: 0.24616259336471558

Entropia Cruzada:

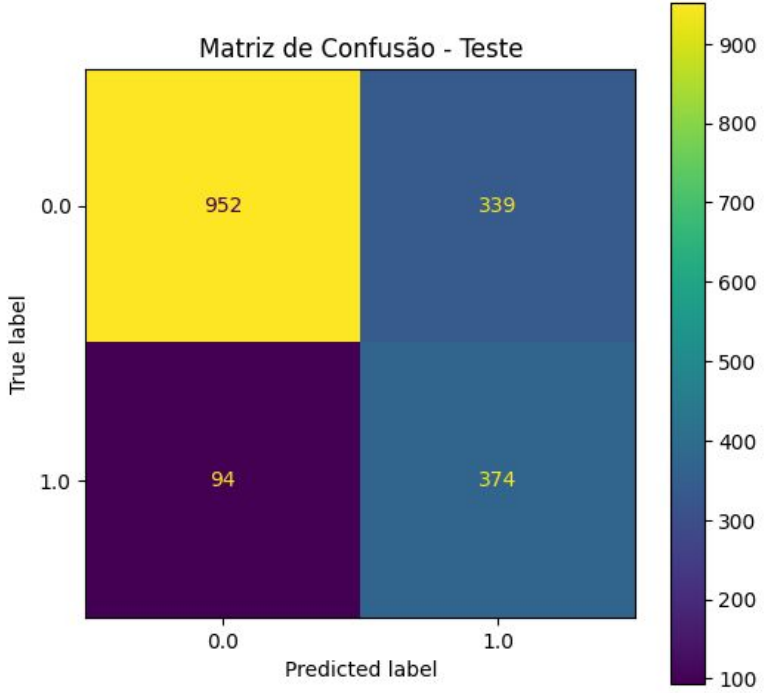
- Log Loss Treino: 0.4604129411200795
- Log Loss Validação: 0.5004647088028096
- Log Loss Teste: 0.49858893585281394

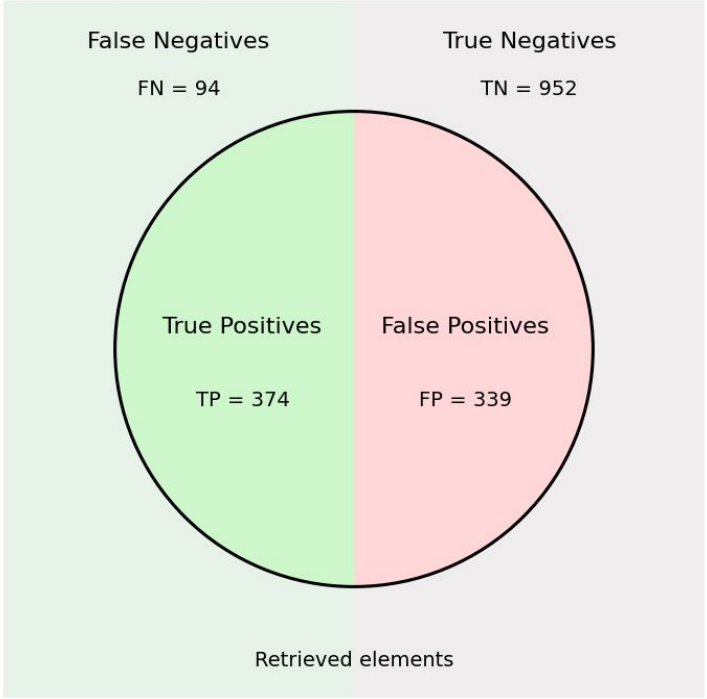
Precision, recall e F1 do teste:

- Precision: 0.5245441795231417
- Recall: 0.7991452991452992
- F1-Score: 0.6333615580016935

KAN

Treino 2 (Resultados): Matriz de confusão e Diagrama TN, FP, FN, TP

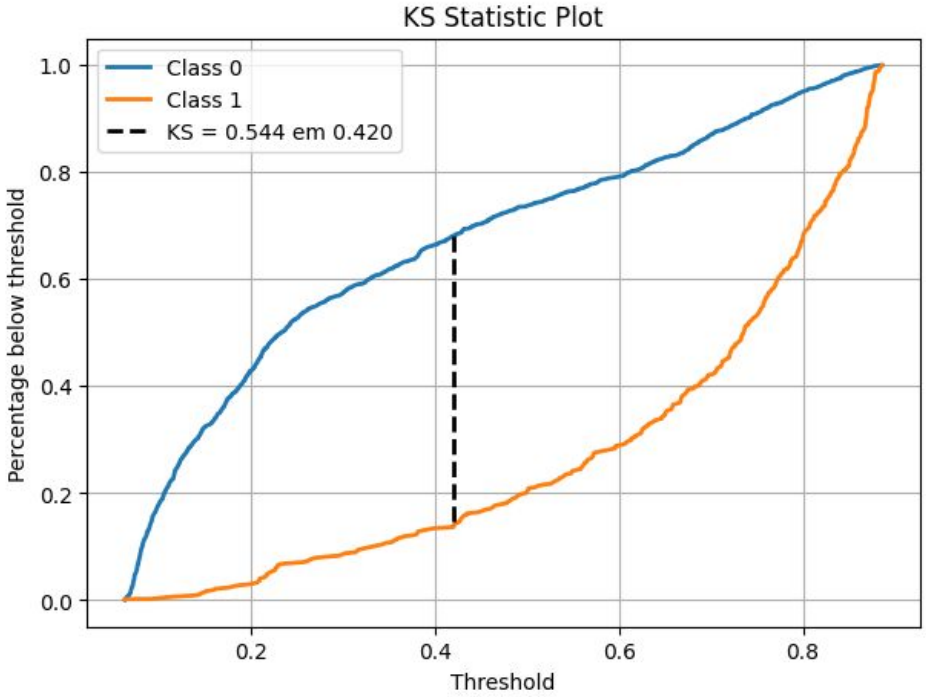




KAN

Treino 2 (Resultados): Teste Kolmogorov-Smirnov (KS)

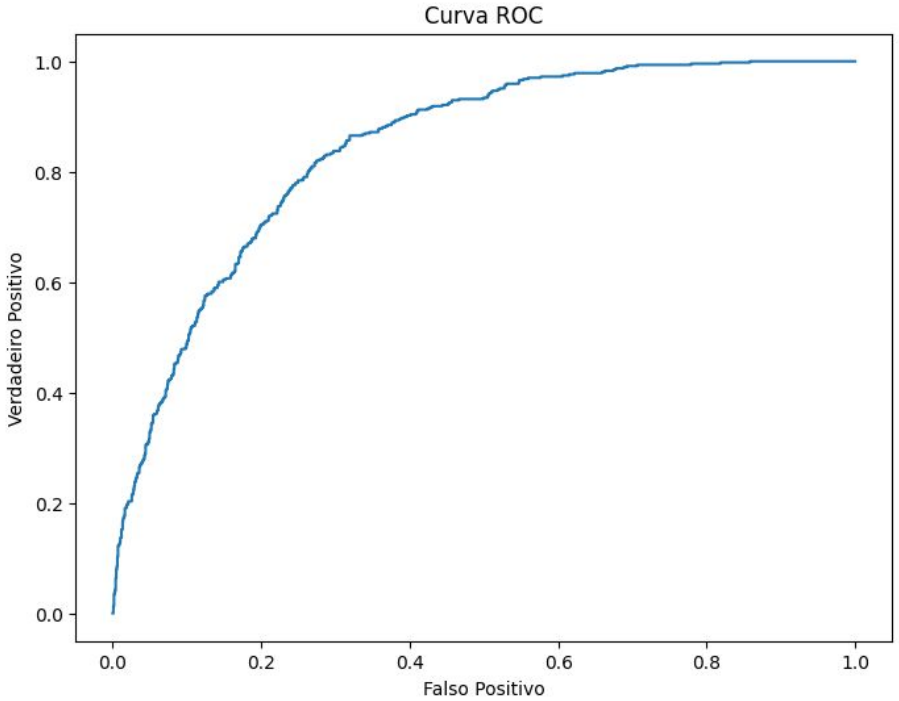
KS Statistic: 0.5443334611332931
Best threshold: 0.4198134



KAN

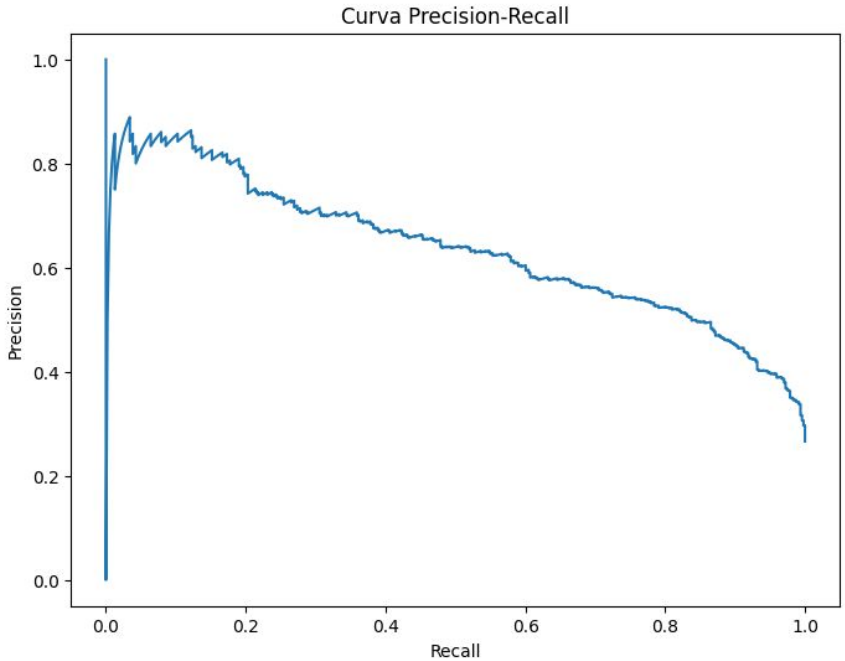
Treino 2 (Resultados): Curva ROC e AUROC

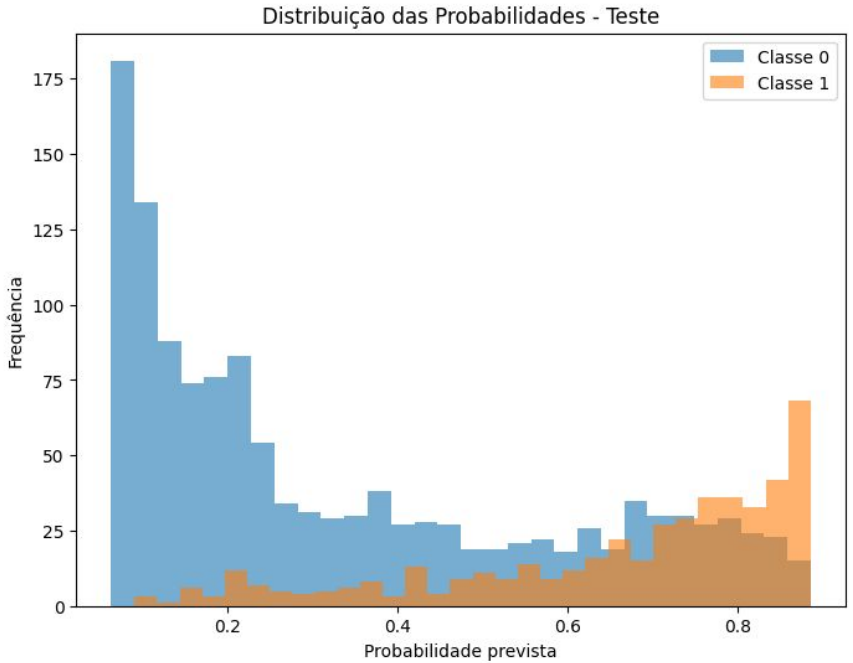
AUC (Área sob a ROC): 0.842054956404298



KAN

Treino 2 (Resultados): Curva precision - Recall e Distribuição das probabilidades





KAN

Treino 2: Comparando resultados de teste

Parâmetros	Melhor treino (1)	Treino atual (2)
Precision	0.5068493150684932	0.5245441795231417
Recall	0.7905982905982906	0.7991452991452992
F1-Score	0.6176961602671118	0.6333615580016935
Accuracy	0.74	0.75
MSE	0.24726357792541	0.24616259336471558
Log Loss	0.5019960529013935	0.49858893585281394
KS	0.5206531332719204	0.5443334611332931
AUC	0.8401085423742278	0.842054956404298

TabKANet

Treino 1:

Parâmetros passados para o optuna:

grid_size = 3 a 10 (Divisões da spline)
spline_order = 3 a 5 (Grau do polinômio)
hidden_dim = 16 a 128 (Dimensão oculta)
lr (Learning Rate) = 1e-4 a 1e-2
batch_size = [64, 128, 256, 512]
Métrica Alvo: Minimizar LogLoss na Validação

Melhores parâmetros encontrados:

grid_size: 10
spline_order: 3
hidden_dim: 41
lr: 0.000636
batch_size: 128

TabKANet

```
==== CLASSIFICATION REPORT - TREINO ====
              precision    recall  f1-score   support

           0       0.81      0.75      0.78      2587
           1       0.77      0.82      0.79      2587

    accuracy                           0.79      5174
   macro avg       0.79      0.79      0.79      5174
weighted avg       0.79      0.79      0.79      5174

==== CLASSIFICATION REPORT - VALIDAÇÃO ====
              precision    recall  f1-score   support

           0       0.78      0.73      0.75      1293
           1       0.75      0.80      0.77      1293

    accuracy                           0.76      2586
   macro avg       0.76      0.76      0.76      2586
weighted avg       0.76      0.76      0.76      2586

==== CLASSIFICATION REPORT - TESTE ====
              precision    recall  f1-score   support

           0       0.91      0.73      0.81      1294
           1       0.52      0.80      0.63       468

    accuracy                           0.75      1762
   macro avg       0.71      0.77      0.72      1762
weighted avg       0.81      0.75      0.76      1762
```

TabKANet

```
# === 3. Precision, Recall e F1 ===
print("Precision:", precision_score(y_test, y_test_pred))
print("Recall:", recall_score(y_test, y_test_pred))
print("F1-Score:", f1_score(y_test, y_test_pred))
```

```
Precision: 0.5194444444444445
Recall: 0.7991452991452992
F1-Score: 0.6296296296296297
```

```
# === 4. MSE (Erro Médio Quadrado) ===
print("MSE Treino:", mean_squared_error(y_train, y_train_pred))
print("MSE Validação:", mean_squared_error(y_val, y_val_pred))
print("MSE Teste:", mean_squared_error(y_test, y_test_pred))
```

```
MSE Treino: 0.21414766138384228
MSE Validação: 0.23665893271461716
MSE Teste: 0.24971623155505107
```

```
# === 5. Log Loss ===
print("Log Loss Treino:", log_loss(y_train, y_train_proba))
print("Log Loss Validação:", log_loss(y_val, y_val_proba))
print("Log Loss Teste:", log_loss(y_test, y_test_proba))
```

```
Log Loss Treino: 0.4442609442829549
Log Loss Validação: 0.5012051132466765
Log Loss Teste: 0.49328667253207337
```

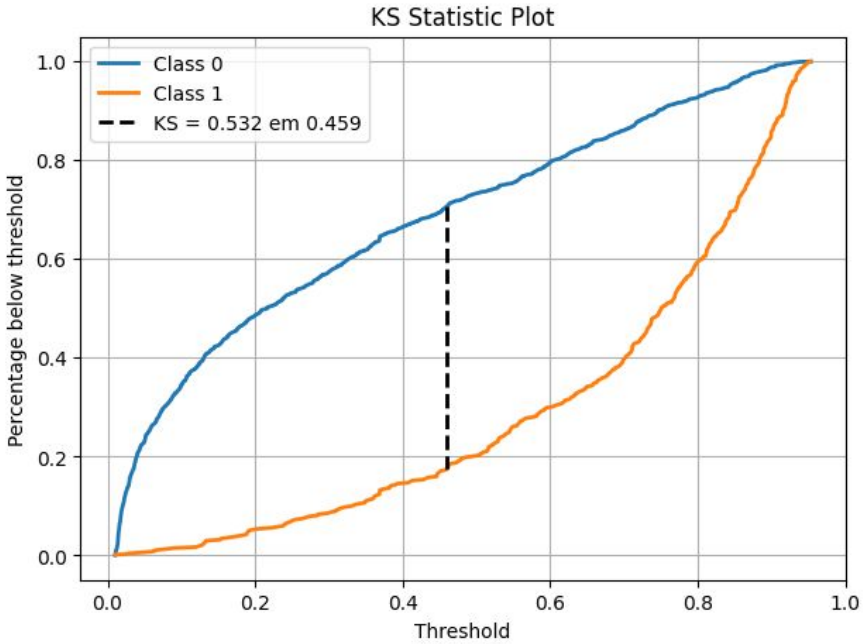
TabKANet

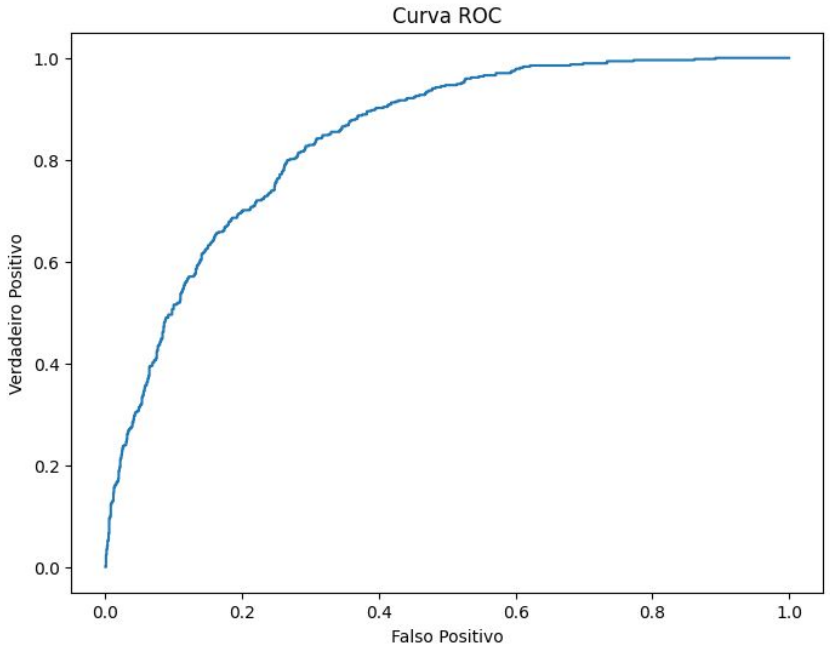
```
KS Statistic: 0.5322050158095044
Best threshold: 0.45910957
```

```python
# === 9. AUROC ===
auc = roc_auc_score(y_test, y_test_proba)
print("AUC (Área sob a ROC):", auc)
```

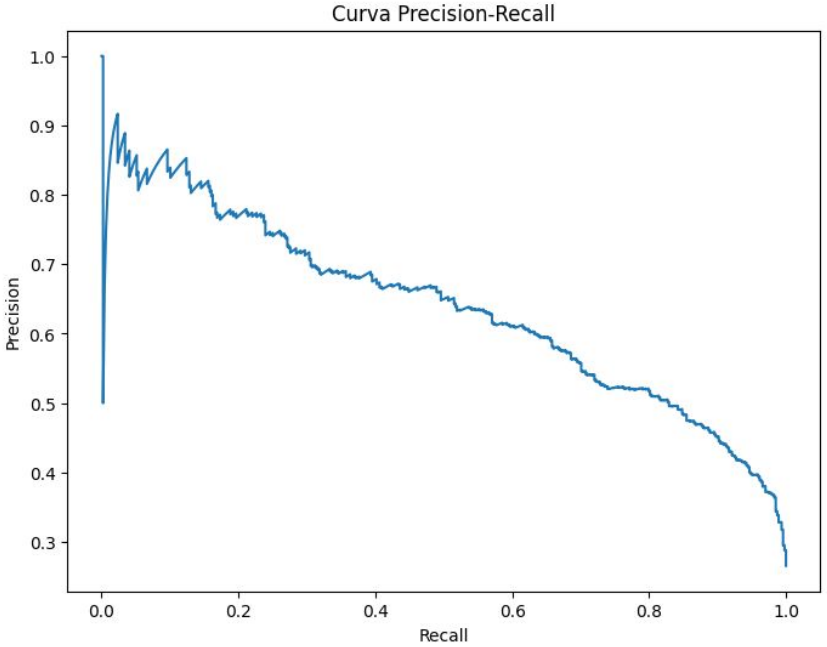
```
AUC (Área sob a ROC): 0.841783742189461
```

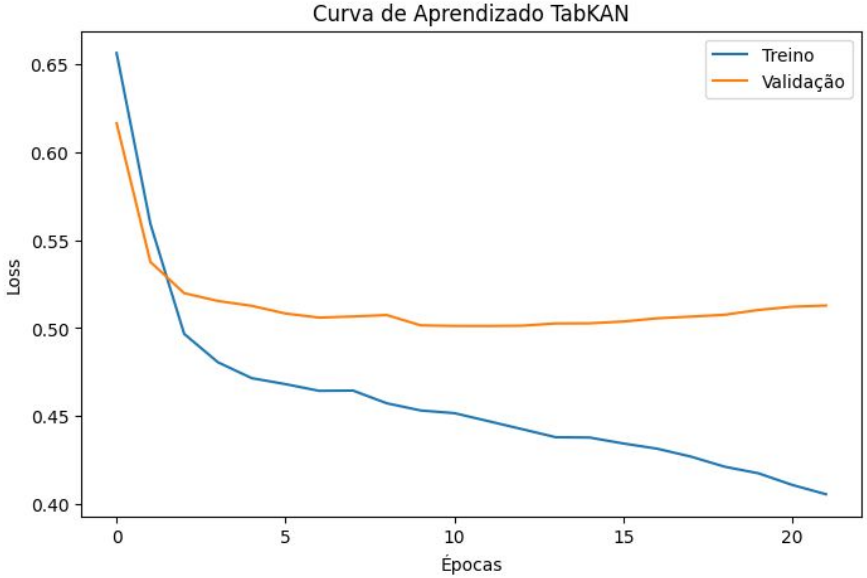
TabKANet


KS Statistic Plot
Class 0
Class 1
KS = 0.532 em 0.459
Percentage below threshold
Threshold
0.0
0.2
0.4
0.6
0.8
1.0

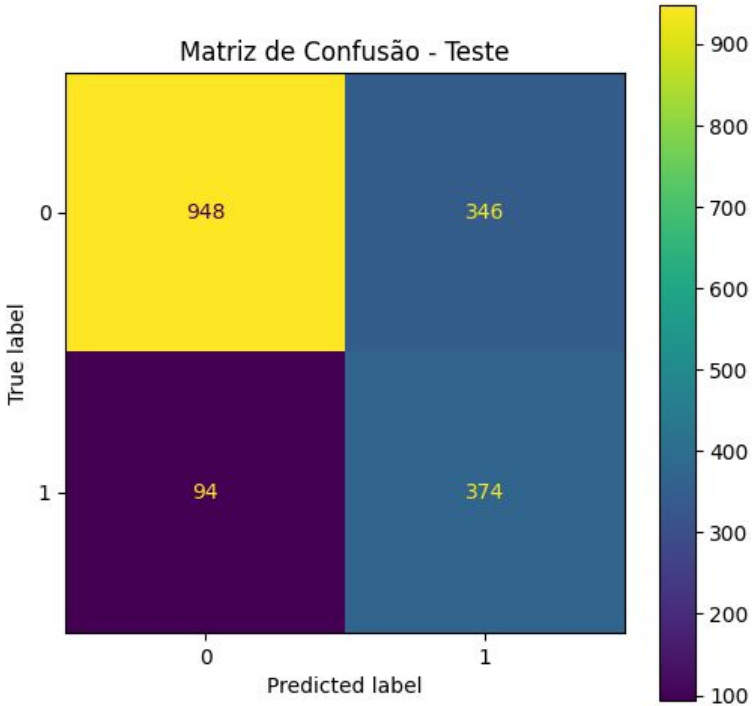

Curva ROC
Verdadeiro Positivo
Falso Positivo
0.0
0.2
0.4
0.6
0.8
1.0

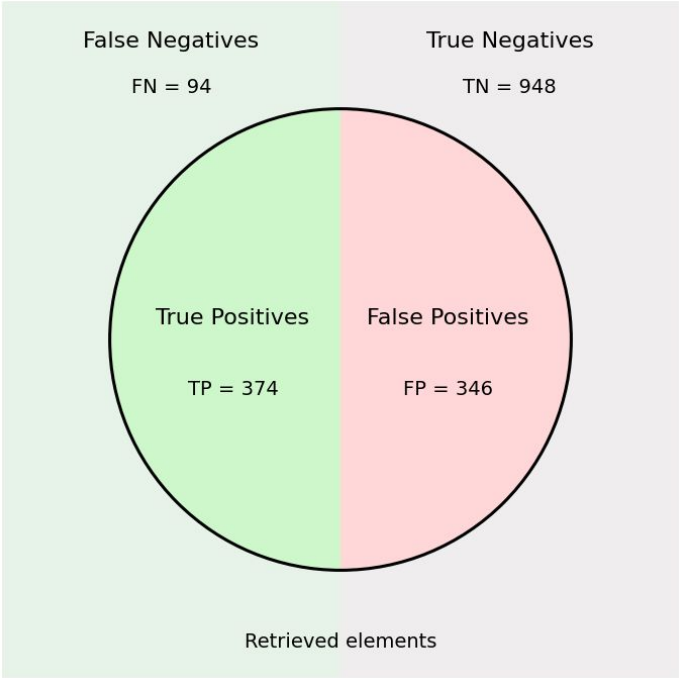
TabKANet


Curva Precision-Recall
Precision
Recall
1.0
0.9
0.8
0.7
0.6
0.5
0.4
0.3
0.0
0.2
0.4
0.6
0.8
1.0


Curva de Aprendizado TabKAN
Treino
Validação
Loss
Épocas
0.65
0.60
0.55
0.50
0.45
0.40
0
5
10
15
20

TabKANet


Matriz de Confusão - Teste
948
346
94
374
0
1
True label
0
1
Predicted label
900
800
700
600
500
400
300
200
100


False Negatives
FN = 94
True Negatives
TN = 948
True Positives
TP = 374
False Positives
FP = 346
Retrieved elements

TabKANet

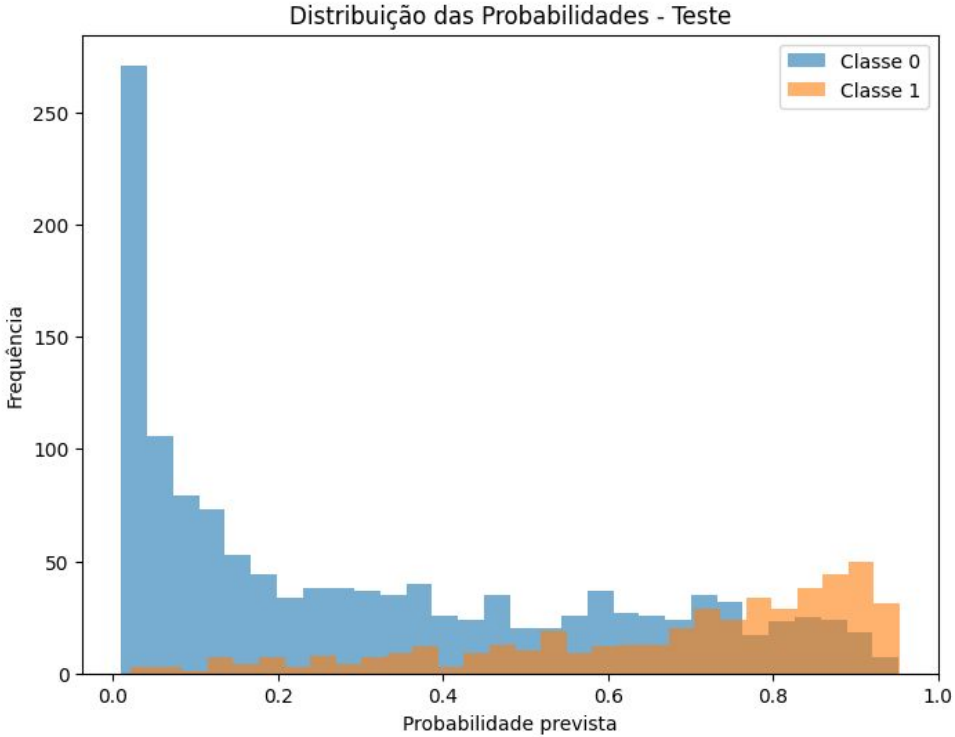

Distribuição das Probabilidades - Teste
Classe 0
Classe 1
Frequência
Probabilidade prevista
0
50
100
150
200
250
0.0
0.2
0.4
0.6
0.8
1.0

Tabela Comparativa Geral

Parâmetros	MLP	XGBoost	STAB	TabPFN	Mitra	KAN	TabKANet
Precision	0.519650655021834	0.8020	0.512	0.7958	0.53	0.5245441795231417	0.52
Recall	0.7628205128205128	0.7384	0.8205128205128205	0.7491	0.76	0.7991452991452992	0.80
F1-Score	0.6181818181818182	0.7526	0.6305418719211823	0.7613	0.62	0.6333615580016935	0.63
Accuracy	0.7493	0.74	0.7442	0.75	0.75	0.75	0.75
MSE	0.25071063104036384	0.1717	0.2558271745309835	0.2508	0.2451	0.24616259336471558	0.2497
Log Loss	0.4767886784547145	0.5104	0.5047930714677319	0.4869	0.4807	0.49858893585281394	0.4932
KS	0.5368808461330588	0.5421	0.5486353789303027	0.5328	0.5407	0.5443334611332931	0.5322
AUC	0.8418497222718757	0.8420	0.8375257370222514	0.8416	0.8424	0.842054956404298	0.8417

Obrigado.